



**UNIVERSITAT POLITÈCNICA DE CATALUNYA
BARCELONATECH**

Facultat d'Informàtica de Barcelona



COMPRESIÓN SELECTIVA E INTERPRETABILIDAD MECÁNICA DE UN MODELO TRANSFORMER PARA CLASIFICACIÓN DE EMOCIONES

GUIDO BIOSCA LASA

Director/a

LLUIS PADRO CIRERA (Departamento de Ciencias de la Computación)

Titulación

Grado en Ingeniería Informática (Computación)

Memoria del trabajo de fin de grado

Facultat d'Informàtica de Barcelona (FIB)

Universitat Politècnica de Catalunya (UPC) - BarcelonaTech

01/07/2026

Resum

Els models de llenguatge moderns, com BERT, tenen centenars de milions de paràmetres i resulten costosos de desplegar a gran escala. Una via per alleujar aquest cost és la compressió: reduir la mida del model eliminant components que contribueixen poc al seu rendiment. Aquest treball parteix d'una pregunta senzilla: quan es comprimeix un model entrenat per reconèixer emocions en text, què deixa de funcionar primer, i què ens ensenya això sobre com el model organitza per dins el que ha après? La idea central és fer servir una eina matemàtica de compressió, la descomposició en valors singulars (SVD), no només per fer el model més petit, sinó com un instrument de mesura: com més empitjora el model en eliminar una peça, més important era aquesta peça per al seu funcionament.

Partint de BERT-base ajustat per classificar emocions sobre un conjunt de dades públic, es comprimeixen sistemàticament un a un els diferents components interns del model i es contrasten els resultats amb cinc tècniques d'interpretabilitat (mètodes per observar què passa dins del model): *probing* lineal, *logit lens*, *activation patching*, ablació de capçaleres d'atenció i anàlisi de selectivitat neuronal. Les cinc coincideixen en una mateixa imatge: les primeres capes extreuen pistes a partir de les paraules, les capes intermèdies treballen en una representació interna pròpia, i les últimes capes reorganitzen aquesta informació perquè el classificador final pugui llegir-la.

La coincidència de les cinc tècniques permet distingir tres coses que la literatura sovint tracta com equivalents: que una informació estigui present en una capa, que es trobi en un format que el classificador pugui aprofitar, i que aquesta capa basti per si sola perquè el model funcioni. Un algorisme senzill que decideix què comprimir basant-se en mesures de sensibilitat aconsegueix el millor equilibri entre mida i rendiment de totes les estratègies avaluades. Més interessant és el que no funciona: guiar-se per intuïcions generals sobre el model, sense mesurar quanta compressió suporta cada part, no millora les estratègies convencionals. Entendre un model no n'hi ha prou per comprimir-lo bé si aquesta comprensió no es tradueix en números. Es proposen a més quatre prediccions contrastables en altres models i tasques. **Paraules clau:** interpretabilitat mecànica de Transformers, compressió SVD, BERT, classificació d'emocions.

Resumen

Los modelos de lenguaje modernos, como BERT, tienen centenares de millones de parámetros y resultan costosos de desplegar a gran escala. Una vía para aliviar este coste es la compresión: reducir el tamaño del modelo eliminando componentes que contribuyen poco a su rendimiento. Este trabajo parte de una pregunta sencilla: cuando se comprime un modelo entrenado para reconocer emociones en texto, ¿qué deja de funcionar primero, y qué nos enseña eso sobre cómo el modelo organiza por dentro lo que ha aprendido? La idea central es usar una herramienta matemática de compresión, la descomposición en valores singulares (SVD), no solo para hacer el modelo más pequeño, sino como un instrumento de medida: cuanto más empeora el modelo al eliminar una pieza, más importante era esa pieza para su funcionamiento.

Partiendo de BERT-base ajustado para clasificar emociones sobre un conjunto de datos público, se comprimen sistemáticamente uno a uno los distintos componentes internos del modelo y se contrastan los resultados con cinco técnicas de interpretabilidad (métodos para observar qué ocurre dentro del modelo): *probing* lineal, *logit lens*, *activation patching*, ablación de cabezas de atención y análisis de selectividad neuronal. Las cinco coinciden en una misma imagen: las primeras capas extraen pistas a partir de las palabras, las capas intermedias trabajan en una representación interna propia, y las últimas capas reorganizan esa información para que el clasificador final pueda leerla.

La coincidencia de las cinco técnicas permite distinguir algo que la literatura suele tratar como equivalente: que la información esté presente en una capa, que esté en un formato que el clasificador pueda aprovechar, y que esa capa baste por sí sola para que el modelo funcione son tres cosas distintas. Un algoritmo sencillo que decide qué comprimir a partir de mediciones de sensibilidad logra el mejor equilibrio entre tamaño y rendimiento de todas las estrategias evaluadas. Más interesante es lo que no funciona: guiarse por intuiciones generales sobre el modelo, sin medir cuánto aguanta la compresión cada parte, no mejora a las estrategias convencionales. Entender un modelo no basta para comprimirlo bien si esa comprensión no se traduce en números. Se proponen además cuatro predicciones contrastables en otros modelos y tareas. **Palabras clave:** interpretabilidad mecánica de Transformers, compresión SVD, BERT, clasificación de emociones.

Abstract

Modern language models such as BERT have hundreds of millions of parameters and are costly to deploy at scale. One way to ease this cost is compression: shrinking the model by removing components that contribute little to its performance. This work starts from a simple question: when a model trained to recognise emotions in text is compressed, what stops working first, and what does that teach us about how the model internally organises what it has learned? The central idea is to use a mathematical compression tool, singular value decomposition (SVD), not only to make the model smaller but as a measuring instrument: the more the model degrades when a piece is removed, the more important that piece was.

Starting from a fine-tuned BERT-base that classifies emotions on a public dataset, the different internal components of the model are compressed systematically one by one and the results are cross-checked with five interpretability techniques (methods for observing what happens inside the model): linear probing, logit lens, activation patching, attention-head ablation, and neuron selectivity analysis. All five agree on the same picture: early layers extract cues from the words, middle layers work in their own internal representation, and late layers rearrange that information so the final classifier can read it.

The agreement across five complementary, methodologically distinct techniques allows a distinction that the literature often collapses: that information is present in a layer, that it is in a format the classifier can use, and that the layer alone is enough for the model to work are three different things. A simple algorithm that decides what to compress based on sensitivity measurements achieves the best size/performance trade-off of all evaluated strategies. More instructive is what does not work: relying on general intuitions about the model, without measuring how much compression each part can tolerate, does not beat conventional strategies. Understanding a model is not enough to compress it well if that understanding is not translated into numbers. Four testable predictions are proposed for checking on other models and tasks. **Keywords:** mechanistic interpretability of Transformers, SVD compression, BERT, emotion classification.

Índice general

Índice general	5
Índice de figuras	10
Índice de tablas	13
Glosario de acrónimos	16
1 Introducción	17
1.1 Contexto y motivación	17
1.2 Objetivos	19
1.3 Contribuciones	19
1.4 Marco del proyecto en la FIB	20
1.5 Alcance y limitaciones	21
1.6 Estructura de la memoria	21
2 Gestión del proyecto	22
2.1 Contexto y actores	22
2.2 Alcance: objetivos y requisitos	22
2.2.1 Sub-objetivos	22
2.2.2 Requisitos	23
2.2.3 Obstáculos y riesgos	24
2.3 Metodología y rigor	24
2.3.1 Herramientas	25
2.3.2 Métodos de validación	25
2.4 Planificación temporal	25
2.4.1 Datos globales	25
2.4.2 Descripción de las fases	25
2.4.3 Tabla resumen de tareas	27
2.4.4 Gestión del riesgo: planes alternativos	28
2.4.5 Diagrama de Gantt	29
2.5 Gestión económica (presupuesto)	31
2.5.1 Costes por hora por perfil profesional	31
2.5.2 Costes de personal por actividad (CPA)	31
2.5.3 Costes genéricos (CG)	32
2.5.4 Contingencia e imprevistos	33

2.5.5	Presupuesto total	33
2.5.6	Control de gestión	33
2.6	Ejecución real frente a planificación	34
2.6.1	Ajustes de alcance respecto a la planificación inicial	34
2.6.2	Resumen del balance de horas	35
2.6.3	Planes B activados	35
2.6.4	Indicadores de control finales	35
3	Estado del arte y marco teórico	36
3.1	Del procesamiento secuencial al Transformer	36
3.2	La arquitectura Transformer	37
3.2.1	Codificación posicional	37
3.2.2	Atención multi-cabeza	38
3.2.3	El bloque feed-forward	38
3.2.4	Conexiones residuales y flujo residual	39
3.3	BERT	39
3.3.1	Pre-entrenamiento bidireccional	40
3.3.2	El token [CLS] y el fine-tuning	41
3.4	Fundamentos de la descomposición en valores singulares	41
3.4.1	Definición e interpretación geométrica	41
3.4.2	Aproximación de bajo rango y el teorema de Eckart-Young	42
3.4.3	Energía espectral y compresión efectiva	42
3.5	Clasificación de emociones en NLP	42
3.5.1	Del análisis de sentimientos a la detección de emociones	42
3.5.2	Clasificación multi-etiqueta	42
3.5.3	Desafíos de la clasificación emocional	43
3.6	Compresión de modelos Transformer	43
3.6.1	Poda	43
3.6.2	Cuantización	44
3.6.3	Destilación	44
3.6.4	Factorización de bajo rango	44
3.6.5	Justificación del enfoque SVD	45
3.7	Interpretabilidad mecánica	45
3.7.1	Probing de representaciones	45
3.7.2	Activation patching	46
3.7.3	Logit lens y proyecciones intermedias	47
3.7.4	Ablación de cabezas de atención	47
3.7.5	Análisis de neuronas FFN	48
3.7.6	Superposition y sus implicaciones para la compresión	48
3.8	Posicionamiento de este trabajo	48
4	Metodología	50

4.1	Dataset: GoEmotions	50
4.1.1	Filtrado de emociones	51
4.1.2	Splits y preprocesamiento	52
4.2	Modelo: BERT-base	53
4.2.1	Arquitectura	53
4.2.2	Fine-tuning	53
4.3	Compresión SVD	54
4.3.1	Fundamento teórico	54
4.3.2	Rango de break-even	54
4.3.3	Implementación	54
4.3.4	Métricas espectrales	54
4.3.5	Estrategias de compresión evaluadas	55
4.4	Técnicas de interpretabilidad mecánica	56
4.4.1	Probing lineal	56
4.4.2	Logit lens	57
4.4.3	Activation patching	57
4.4.4	Ablación de cabezas de atención	58
4.4.5	Análisis de neuronas FFN	58
4.5	Métricas de evaluación	59
4.6	Semillas y reproducibilidad	59
5	Resultados de compresión SVD	60
5.1	Análisis espectral de las matrices de peso	60
5.1.1	Asimetría self-attention vs. feed-forward	60
5.1.2	Perfil de decaimiento espectral	61
5.1.3	Solapamiento de subespacios Q-K-V	62
5.1.4	Predicciones a partir del análisis espectral	62
5.2	Compresión uniforme y transición de fase	63
5.2.1	Degradación global	63
5.2.2	Vulnerabilidad emocional diferencial	63
5.3	Sensibilidad por componente y profundidad	65
5.3.1	Sensibilidad por tipo de componente	65
5.3.2	Tres regímenes de compresibilidad	66
5.3.3	Sensibilidad por profundidad	67
5.4	Compresión adaptativa y recetas mixtas	68
5.4.1	Resultados de compresión adaptativa	68
5.4.2	Distribución de rangos asignados	69
5.4.3	Caveat: ratio de compresión y simplificación de rango	69
5.5	Síntesis del capítulo	69
6	Resultados de interpretabilidad mecánica	71
6.1	Probing: cristalización emocional por capas	71

6.1.1	Tres regímenes de cristalización	71
6.1.2	Ganancia informativa por capa	73
6.1.3	La frecuencia no predice la profundidad	74
6.2	Logit lens: la brecha entre información disponible e información leíble	76
6.2.1	Diseño experimental y motivación	76
6.2.2	Patrón agregado: tres regímenes geométricos	76
6.2.3	Conexión con activation patching	78
6.3	Activation patching: localización del conocimiento emocional	78
6.3.1	Diseño experimental	78
6.3.2	Patching por capa completa	79
6.3.3	La FFN como componente suficiente para la recuperación	79
6.3.4	Restauración diferencial por emoción	80
6.4	Ablación de cabezas de atención	81
6.4.1	Diseño experimental	81
6.4.2	Taxonomía funcional	81
6.4.3	Gradiente de criticidad por profundidad	82
6.4.4	Cabezas interferentes	83
6.4.5	Especialización emocional	83
6.5	Análisis neuronal de las redes feed-forward	84
6.5.1	Diseño experimental	84
6.5.2	Especialización concentrada en capas profundas	84
6.5.3	Asimetría radical entre emociones	84
6.5.4	La hipótesis SVD-neuronas: un resultado nulo informativo	85
6.5.5	La norma de selectividad como predictor de vulnerabilidad	86
6.5.6	Clusters emocionales emergentes	86
6.6	Síntesis del capítulo	87
7	Síntesis: compresión informada por interpretabilidad	88
7.1	La cristalización predice la vulnerabilidad	88
7.1.1	Correlación cristalización-vulnerabilidad	88
7.1.2	Tres principios de compresión informada	91
7.2	Estrategia heurística: un resultado negativo informativo	91
7.2.1	Diseño de las tres variantes	91
7.2.2	Resultados	92
7.2.3	Diagnóstico del fracaso	92
7.3	Algoritmo greedy: compresión guiada por datos	93
7.3.1	Por qué greedy y no otra estrategia	93
7.3.2	Diseño del algoritmo	94
7.3.3	Secuencia de decisiones	94
7.3.4	Dominancia en la frontera de Pareto	95
7.3.5	Comparación cualitativa con destilación	97
7.4	Recuperación mediante fine-tuning	97

7.4.1	Resultado agregado	97
7.4.2	Análisis por emoción	98
7.5	Discusión y síntesis de hallazgos	99
7.5.1	La interpretabilidad mecánica tiene valor aplicado, pero requiere cuantificación	99
7.5.2	Convergencia entre compresión e interpretabilidad	99
7.5.3	La regularización implícita: hipótesis no respaldada por el control	99
8	Conclusiones y trabajo futuro	101
8.1	Contribuciones principales	102
8.1.1	Cartografía funcional del modelo	102
8.1.2	Compresión como instrumento de diagnóstico	103
8.1.3	Compresión informada por interpretabilidad	104
8.2	Limitaciones	104
8.2.1	Generalización: un modelo, una tarea	104
8.2.2	Sesgos del dataset	105
8.2.3	Compresión post-hoc	105
8.2.4	Limitaciones de las técnicas de interpretabilidad	105
8.2.5	Potencia estadística	106
8.3	Trabajo futuro	106
8.4	Predicciones falsables del framework	107
8.5	Consideración final	107
9	Análisis de sostenibilidad e implicaciones éticas	109
9.1	Autoevaluación	109
9.2	Dimensión económica	109
9.3	Dimensión ambiental	110
9.4	Dimensión social	110
9.5	Vinculación con los Objetivos de Desarrollo Sostenible	111
9.6	Implicaciones éticas	111
	Referencias	113

Índice de figuras

2.1	Diagrama de Gantt actualizado. T20bis (logit lens) y T26 (fine-tuning) reflejan los cambios respecto a la planificación inicial. Grises: opcionales no ejecutados. Flechas: cadena crítica. Fuente: elaboración propia.	30
3.1	Arquitectura Transformer original [1]. Encoder a la izquierda, decoder a la derecha, bloques apilados N veces.	37
3.2	Arquitectura de un bloque encoder de BERT-base. Cada bloque contiene un sub-bloque de atención multi-cabeza (con 12 cabezas de dimensión 64) y un sub-bloque feed-forward (con expansión $768 \rightarrow 3072 \rightarrow 768$), ambos con conexión residual (líneas discontinuas) y layer normalization. Las 6 matrices de pesos anotadas ($W_Q, W_K, W_V, W_O, W_{\text{int}}, W_{\text{out}}$) son el objetivo de la compresión SVD. BERT-base apila 12 de estos bloques. Fuente: elaboración propia.	40
3.3	Masked Language Modeling. El modelo predice los tokens enmascarados usando el contexto bidireccional completo. Fuente: elaboración propia.	41
3.4	Probing de representaciones. Se entrena un clasificador lineal (regresión logística) sobre el token [CLS] de cada capa intermedia. El F1 del probe indica cuánta información emocional es linealmente accesible en esa capa. Los valores mostrados son ilustrativos. Fuente: elaboración propia.	46
3.5	Activation patching en este trabajo. Se parte de un modelo colapsado por compresión ($F1 = 0$) y se restauran los pesos originales de un componente. La recuperación del F1 indica responsabilidad causal. Fuente: elaboración propia.	47
4.1	Pipeline experimental. El modelo baseline se somete a compresión SVD y a cinco técnicas de interpretabilidad mecánica con granularidad creciente (de capa completa a neurona individual). Los hallazgos retroalimentan el diseño de estrategias de compresión informadas (línea discontinua). El ciclo se cierra con fine-tuning del modelo comprimido. Fuente: elaboración propia.	50
5.1	Decaimiento espectral por tipo de componente: eje horizontal, índice del valor singular ($i = 1, \dots, 768$); eje vertical, magnitud σ_i normalizada, promediada sobre las 12 capas $\pm$ desviación estándar (banda sombreada). Q y K decaen rápido; FFN Intermediate y Output mantienen valores singulares elevados a lo largo de todo el espectro. Fuente: elaboración propia.	61

5.2	F1 por emoción para cada nivel de compresión uniforme. Las emociones están ordenadas por su F1 en el baseline. Las emociones frecuentes y léxicamente simples (arriba) sobreviven más que las infrecuentes y semánticamente complejas (abajo). Fuente: elaboración propia.	64
5.3	Retención de F1 al comprimir solo un tipo de componente a rango $r = 128$ (manteniendo el resto del modelo intacto). Q y K (azules) son casi inmunes (retención > 98 %); V y Attn Output (naranjas) sufren una pérdida moderada; las FFN (verdes) presentan pérdidas severas. Las dos últimas filas (Attention all, FFN all) muestran el efecto de comprimir todos los componentes de un bloque a la vez. Fuente: elaboración propia.	66
5.4	Sensibilidad por grupo de profundidad. Cada barra representa la retención de F1 macro al comprimir todas las matrices de un grupo de capas a un rango dado, manteniendo el resto intacto. Las capas tardías (rojo) son las únicas que colapsan por completo a $r = 128$; las tempranas (verde) y medias (azul) retienen capacidad funcional. Fuente: elaboración propia.	67
5.5	Distribución de rangos asignados por la compresión adaptativa para cada umbral de energía, desglosada por tipo de componente. Q y K reciben rangos consistentemente menores que FFN. Fuente: elaboración propia.	69
6.1	Heatmap de F1 de los probes (23 emociones $\times$ 13 capas). El marcador indica la capa de cristalización de cada emoción. Las emociones se ordenan por profundidad de cristalización creciente. Fuente: elaboración propia.	72
6.2	Proyecciones t-SNE de las representaciones del token [CLS] en cuatro capas del modelo (embedding, L4, L8, L11). Los puntos son ejemplos individuales del conjunto de test; los rombos, centroides por emoción. Los colores agrupan las emociones por similitud semántica. Fuente: elaboración propia.	73
6.3	Ganancia informativa incremental por capa, medida como el aumento en F1 macro medio respecto a la capa anterior. La capa L0 absorbe el 61 % de la separabilidad final del modelo. Fuente: elaboración propia.	74
6.4	Izquierda: capa de cristalización vs. F1 máximo ($\rho = -0,673, p < 0,001$). Derecha: frecuencia en el dataset vs. capa de cristalización ($\rho = -0,265, p = 0,22$). Fuente: elaboración propia.	75
6.5	Logit lens agregado sobre 2 300 ejemplos del conjunto de test. Tres curvas: top-1 sigmoid (probabilidad media de la emoción más probable), gold sigmoid (probabilidad media de la emoción correcta), y suma de las 23 sigmoids (masa total de probabilidad). El patrón en U distingue tres regímenes geométricos sucesivos. Fuente: elaboración propia.	77
6.6	Distribución de categorías de cabezas por capa. La proporción de cabezas críticas (especialistas + generalistas) crece con la profundidad. La capa 11 no contiene ninguna cabeza dispensable. Fuente: elaboración propia.	82

- 7.1 Mapa emocional del modelo. Cada punto representa una de las 23 emociones, situada según su capa de cristalización por probing (eje horizontal en convención $1=L0, 2=L1, \dots, 10=L9$, derivado del Capítulo 6) y su norma de selectividad neuronal (eje vertical, intensidad total con la que el modelo codifica esa emoción a través de sus neuronas FFN). Los colores agrupan las emociones por cluster semántico. Las bandas verticales sombreadas marcan los tres bloques de profundidad: temprano ($L0-L3$), medio ($L4-L7$) y tardío ($L8-L11$). Las emociones léxicas (*gratitude, love, amusement*) ocupan la región superior izquierda; las contextuales (*annoyance, disappointment*) la inferior derecha. Nota: el cluster etiquetado en la leyenda como “Epistémicas” se denomina “Cognitivas” en el texto (mismo grupo). Fuente: elaboración propia. 90
- 7.2 Frontera de Pareto para las cuatro familias de estrategias de compresión. Los puntos sobre la curva envolvente representan configuraciones Pareto-óptimas. 8 de los 9 puntos Pareto-óptimos corresponden a estrategias greedy. La única estrategia no-greedy en la frontera es *uniform_r32*, que aparece solo por tener el menor ratio absoluto pero con $F1 = 0$ (el modelo está colapsado). Fuente: elaboración propia. 96

Índice de tablas

2.1	Principales obstáculos y riesgos del proyecto.	24
2.2	Parámetros temporales del proyecto.	25
2.3	Tabla resumen de tareas.	27
2.4	Planes alternativos asociados a los riesgos R1–R7.	29
2.5	Coste por hora estimado por perfil profesional.	31
2.6	Costes de personal por actividad (CPA).	31
2.7	Costes genéricos del proyecto.	32
2.8	Partidas de imprevistos.	33
2.9	Resumen del presupuesto total del proyecto.	33
2.10	Comparativa entre la planificación inicial y la ejecución real.	35
3.1	Comparativa de técnicas de compresión para Transformers. Fuente: elaboración propia.	45
3.2	Posicionamiento respecto al estado del arte. Fuente: elaboración propia a partir de las referencias citadas.	49
4.1	Las 23 emociones del dataset final, con F1 en el baseline.	52
4.2	Capas lineales del encoder de BERT-base (por capa).	53
4.3	Hiperparámetros de fine-tuning.	53
5.1	Rango medio k_{95} por tipo de componente (media sobre las 12 capas). Fuente: elaboración propia.	60
5.2	Rango de solapamiento entre subespacios (top-32 y top-64 vectores singulares). Fuente: elaboración propia.	62
5.3	Resultados de compresión uniforme sobre el conjunto de test. El ratio de parámetros se define como $\text{params}_{\text{comprimido}}/\text{params}_{\text{original}}$: valores < 1 indican compresión real; valores > 1 , expansión paramétrica. La retención es el cociente $F1_{\text{comprimido}}/F1_{\text{baseline}}$, expresado en porcentaje. Fuente: elaboración propia.	63
5.4	Sensibilidad por componente a $r = 128$. La sensibilidad normalizada se calcula como $S = (F1_{\text{baseline}} - F1_{\text{comprimido}}) \times 100/\Delta \% \text{params}$, donde $\Delta \% \text{params}$ es el porcentaje de parámetros eliminados al comprimir solo ese componente (en pp del total del encoder). Fuente: elaboración propia.	65
5.5	Retención de F1 por grupo de profundidad y rango de compresión. Fuente: elaboración propia.	67

5.6	Resultados de compresión adaptativa y recetas mixtas. $\text{Ratio params.} = \text{params}_{\text{comprimido}} / \text{params}_{\text{original}}$, donde < 1 es compresión real y > 1 expansión paramétrica (ver §5.4.3). Fuente: elaboración propia.	68
6.1	Grupos de cristalización emocional. La capa indica la primera capa donde el F1 del probe alcanza el 80 % de su máximo. La columna "F1 en cap." muestra el F1 del probe en la capa de cristalización. Fuente: elaboración propia.	71
6.2	Correlaciones de Spearman entre propiedades de las emociones ($n = 23$). Solo la correlación entre profundidad de cristalización y F1 máximo es significativa. Fuente: elaboración propia.	74
6.3	Restauración del F1 macro al parchear una sola capa del modelo comprimido (rango 64). Se omiten las capas con restauración nula (0–7). Fuente: elaboración propia.	79
6.4	Restauración del F1 macro al parchear un solo componente (atención o FFN) de las capas 8–11 del modelo comprimido. Fuente: elaboración propia.	79
6.5	Restauración del F1 por emoción al parchear solo la atención de la capa 11. Se muestran las 5 emociones mejor y peor restauradas. Fuente: elaboración propia.	80
6.6	Taxonomía de cabezas de atención basada en importancia y selectividad. La baja correlación entre ambas dimensiones ($r = -0,055$) valida la clasificación. Fuente: elaboración propia.	81
6.7	Distribución de cabezas críticas y dispensables por bloque de profundidad. La capa 11 no contiene ninguna cabeza dispensable. Fuente: elaboración propia.	82
6.8	Cabeza más importante para cada emoción (top 10 por magnitud de impacto). La caída de F1 indica cuánto pierde esa emoción al ablacionar su cabeza más crítica. Fuente: elaboración propia.	83
6.9	Distribución de neuronas especializadas ($ d > 2,0$) por bloque de profundidad. El 84 % de las neuronas significativas se concentra en las capas 8–11. Fuente: elaboración propia.	84
6.10	Neuronas significativas y selectividad máxima por emoción (selección). Tres emociones no tienen ninguna neurona con $ d > 2,0$. Fuente: elaboración propia.	85
6.11	Predictores de la vulnerabilidad emocional a compresión SVD ($n = 23$). La norma de selectividad, que mide la intensidad total de codificación neuronal, es el mejor predictor. Fuente: elaboración propia.	86
6.12	Clusters emocionales emergentes de la estructura neuronal del modelo. Las agrupaciones se obtienen por clustering jerárquico sobre los vectores de selectividad de 36 864 neuronas. Fuente: elaboración propia.	86

7.1	Rendimiento de las estrategias heurísticas informadas frente a baselines de complejidad comparable. Las tres variantes igualan exactamente al baseline uniforme con el mismo ratio de parámetros (<code>informed_aggressive = uniform_r256</code> ; <code>informed_moderate = uniform_r512</code>), o requieren más parámetros que el original sin alcanzar la retención de <code>adaptive_e99</code> (<code>informed_light</code>). Ninguna domina la frontera de Pareto. Fuente: elaboración propia.	92
7.2	Secuencia de decisiones del algoritmo greedy. Cada fila muestra los componentes comprimidos al alcanzar el ratio indicado. El algoritmo opera exclusivamente con datos numéricos de sensibilidad, sin acceso a los hallazgos cualitativos de interpretabilidad. Fuente: elaboración propia.	94
7.3	Comparaciones directas entre estrategias greedy y alternativas a ratios de parámetros comparables. Los intervalos de confianza al 95 % se obtienen mediante bootstrap por emoción (10 000 réplicas, $n = 23$); el p -valor en la columna $\Delta F1$ corresponde a un test <i>paired bootstrap</i> sobre la diferencia por emoción cuando se dispone de datos por emoción para ambas estrategias. Fuente: elaboración propia.	95
7.4	Rendimiento del modelo comprimido (<code>greedy_90</code>) antes y después de fine-tuning, comparado con el baseline sin comprimir y con el grupo de control (<code>baseline + 3</code> épocas adicionales). Fuente: elaboración propia.	97
7.5	Mejora atribuible específicamente a la compresión SVD, por emoción. La columna <code>baseline+FT</code> es el control (<code>baseline + 3</code> épocas); <code>comprimido+FT</code> es <code>greedy_90 + 3</code> épocas. La columna Δ SVD es la diferencia: positivo significa que la SVD ayuda; negativo, que perjudica. Fuente: elaboración propia.	98
7.6	Triangulación de hallazgos: la compresión y las cinco técnicas de interpretabilidad convergen en las mismas conclusiones estructurales. Fuente: elaboración propia.	100
8.1	Cumplimiento de los sub-objetivos planteados en el plan inicial. Sección indica dónde se desarrolla el resultado; evidencia, la métrica clave que documenta el cumplimiento. Fuente: elaboración propia.	102

Glosario de acrónimos

BCE	Binary Cross-Entropy (entropía cruzada binaria)
BERT	Bidirectional Encoder Representations from Transformers
CLS	Classification token (token especial de clasificación)
CPI	Cost Performance Index (índice de rendimiento del coste)
CSV	Comma-Separated Values
FFN	Feed-Forward Network
GeLU	Gaussian Error Linear Unit
GPU	Graphics Processing Unit
KL	Kullback–Leibler (divergencia)
LoRA	Low-Rank Adaptation
MHA	Multi-Head Attention
MLM	Masked Language Modeling
NLP	Natural Language Processing
NSP	Next Sentence Prediction
Q, K, V	Query, Key, Value (proyecciones de atención)
SVD	Singular Value Decomposition (descomposición en valores singulares)
TFG	Trabajo Fin de Grado
t-SNE	t-distributed Stochastic Neighbor Embedding

Capítulo 1

Introducción

1.1. Contexto y motivación

Los modelos de lenguaje basados en la arquitectura Transformer [1] han transformado el procesamiento del lenguaje natural en la última década. BERT [2], con sus 110 millones de parámetros, demostró en 2018 que una sola red pre-entrenada podía alcanzar resultados de referencia en tareas tan diversas como clasificación de texto, extracción de información o respuesta a preguntas. Hoy, 110 millones de parámetros es la talla pequeña: GPT-3 alcanzó los 175 000 millones [3], y los modelos abiertos recientes operan en el rango de 8 000 a 405 000 millones. El coste de desplegarlos en dispositivos móviles, sistemas embebidos o infraestructuras con restricciones de latencia y energía sigue siendo un problema abierto, y proyecciones recientes estiman que la inferencia (no el entrenamiento) concentra el grueso del gasto energético a largo plazo de un modelo desplegado [4, 5].

Frente a este escenario, una pregunta directa orienta este trabajo: ¿se puede hacer un modelo más pequeño sin destruir lo que ha aprendido? La compresión de modelos ha abordado esta pregunta con cuatro herramientas principales: poda, cuantización, destilación y factorización de bajo rango [6]. Aquí se utiliza la última en su variante más clásica: la descomposición en valores singulares (SVD), aplicada de forma selectiva a las distintas capas y componentes de BERT-base. La SVD ofrece tres ventajas para los objetivos de este trabajo: no requiere re-entrenamiento, permite ajustar cuánto se comprime cada matriz por separado, y tiene una garantía matemática útil: para un tamaño objetivo dado, conserva la mejor aproximación posible de la matriz original [7].

La compresión selectiva se usa también como herramienta de análisis: cada configuración comprimida es una intervención controlada que revela la importancia funcional del componente afectado, funcionando como un bisturí experimental. Al observar qué se rompe y qué sobrevive cuando se elimina parte del modelo se obtiene un mapa empírico de cómo está organizada internamente la información. Esta lógica es la de la *interpretabilidad mecánica*, que busca abrir el modelo y caracterizar los circuitos internos responsables de comportamientos específicos [8, 9, 10].

El trabajo combina dos líneas que raramente aparecen juntas: comprimir cada parte del modelo en distinto grado según su tipo y su profundidad, en lugar de aplicar la misma reducción a todo; y cinco técnicas de interpretabilidad mecánica (*probing* lineal, *logit lens*, *activation patching*, ablación

de cabezas de atención y análisis de selectividad neuronal) que examinan la organización interna del modelo desde ángulos distintos. Los hallazgos de esas técnicas alimentan una estrategia de compresión informada por datos que decide cuánto reducir cada componente a partir de mediciones de sensibilidad, frente a las aproximaciones ciegas, que comprimen todo por igual sin atender a la función de cada parte.

La clasificación de emociones permite observar cómo la compresión afecta diferencialmente a clases con perfiles lingüísticos distintos. Los experimentos se realizan sobre GoEmotions [11], un conjunto de datos público en el que cada texto se etiqueta con una o varias de 23 emociones (las 28 originales menos cinco que se filtran por las razones que se detallan en §4.1). Estas emociones son muy distintas entre sí: algunas se reconocen por un vocabulario característico (por ejemplo, *gratitude* aparece junto a palabras como “thanks”), mientras que otras exigen entender el contexto (*disappointment*, *realization*). Esa variedad convierte la tarea en una prueba exigente, porque permite ver cómo la compresión afecta de forma desigual a emociones con perfiles lingüísticos diferentes. Con una tarea binaria (sentimiento positivo/negativo) esa vulnerabilidad selectiva, que es uno de los hallazgos centrales del proyecto, no sería visible.

La compresión SVD se aplica después del entrenamiento, no requiere hardware especializado y es escalable a cualquier modelo con capas lineales. Cuando comprimir un componente destruye una capacidad, la relación es funcional, no solo asociativa; eso da acceso a la organización interna del modelo de un modo que las técnicas puramente observacionales (como el probing) no pueden replicar. Reducir el tamaño del modelo para la inferencia disminuye también su consumo energético [5], en la línea de lo que la literatura denomina Green AI.

Los trabajos previos de compresión SVD en Transformers [12, 13] han privilegiado la compresión uniforme: el mismo grado de reducción para todas las capas y componentes. Esa uniformidad ignora dos asimetrías ya documentadas. Primero, las distintas capas de BERT codifican tipos de información diferentes: las tempranas capturan rasgos léxicos y sintácticos, las tardías capturan rasgos semánticos y específicos de la tarea [14, 15]. Segundo, los componentes de atención y las redes feed-forward desempeñan roles funcionales distintos [16, 17]. La hipótesis de partida es que tratarlos a todos por igual es subóptimo, y que medir cuánto lo es, y por qué, requiere combinar compresión sistemática con interpretabilidad mecánica.

Tres preguntas encadenadas vertebran el trabajo:

P1 (descriptiva). *¿Cómo afecta la compresión SVD selectiva, aplicada por tipo de componente y por profundidad de capa, al rendimiento y a la calidad de las representaciones internas de un modelo Transformer fine-tuned (pre-entrenado y luego ajustado a una tarea concreta) para clasificación de emociones?*

P2 (explicativa). *¿Qué revelan las técnicas de interpretabilidad mecánica sobre la organización interna de la información emocional en el modelo, y qué propiedades estructurales explican la sensibilidad diferencial observada en P1?*

P3 (prescriptiva). *¿Puede el conocimiento mecanicista obtenido en P2 traducirse en estrategias de compresión que mejoren a las aproximaciones ciegas dentro de la familia SVD?*

1.2. Objetivos

El objetivo general del proyecto es:

Producir un mapa funcional de cómo BERT-base fine-tuned organiza internamente la información emocional. La compresión SVD selectiva se usa como instrumento de medida: la magnitud de lo que se rompe al eliminar un componente cuantifica su contribución funcional. Los hallazgos se triangulan con cinco técnicas de interpretabilidad mecánica.

Como aplicación derivada, se diseña una estrategia de compresión informada por estos datos de sensibilidad y se compara con los enfoques uniformes establecidos en la literatura.

Este objetivo se descompone en cinco objetivos específicos que estructuran la contribución y delimitan el alcance:

- O1. Caracterizar la sensibilidad a la compresión** según tipo de componente, profundidad de capa y emoción, construyendo un mapa cuantitativo del compromiso entre tamaño y rendimiento.
- O2. Localizar y mapear la organización interna de la información emocional** mediante cinco técnicas de interpretabilidad mecánica complementarias: probing lineal para identificar a qué profundidad queda codificada cada emoción, logit lens para distinguir información presente de información ya legible por el clasificador, activation patching para identificar dependencias funcionales, ablación de cabezas de atención para mapear la especialización atencional y análisis de selectividad neuronal para caracterizar la codificación en las redes feed-forward.
- O3. Conectar la estructura interna con la fragilidad ante la compresión**, identificando qué propiedades del modelo permiten predecir la caída de rendimiento al comprimir.
- O4. Diseñar y evaluar una estrategia de compresión informada por datos** que traduzca los hallazgos anteriores en un criterio para decidir cuánto comprimir cada componente, y compararla con las aproximaciones ciegas en la frontera de Pareto.
- O5. Evaluar la recuperación mediante fine-tuning** del modelo comprimido, comparándola con un grupo de control sobre el baseline para aislar el efecto específico de la compresión del entrenamiento adicional.

1.3. Contribuciones

Las contribuciones principales de este trabajo son las siguientes:

- C1. Mapa de sensibilidad a la compresión**, desagregado por tipo de componente, profundidad de capa y emoción. Muestra que las partes del modelo no son igual de frágiles: algunas toleran una compresión fuerte casi sin perder rendimiento, mientras que otras se hunden con la misma reducción. Esta asimetría no había sido caracterizada de forma sistemática y conjunta por tipo de componente, profundidad de capa y emoción.

- C2. Triangulación con cinco técnicas de interpretabilidad complementarias.** Sus resultados convergen en una misma imagen del modelo en tres niveles: las capas tempranas extraen señal a partir de las palabras, las intermedias realizan un cómputo interno y las tardías reorganizan la información para que el clasificador final pueda leerla.
- C3. Resolución de una aparente paradoja entre técnicas.** Distintos métodos parecían contradecirse sobre el papel de las capas finales; el trabajo muestra que no se contradicen si se distingue entre que la información esté presente, que esté en un formato legible para el clasificador, y que una capa baste por sí sola para que el modelo funcione.
- C4. Conexión cuantitativa entre interpretabilidad y compresión.** Se identifica qué propiedad interna del modelo predice mejor su fragilidad ante la compresión, y se muestra que aquello que la SVD optimiza es ortogonal a la organización funcional del modelo.
- C5. Algoritmo de compresión informado por datos.** Alimentado con las mediciones de sensibilidad, obtiene el mejor equilibrio entre tamaño y rendimiento entre las estrategias evaluadas. Su secuencia de decisiones, obtenida solo a partir de datos numéricos, coincide con la jerarquía de importancia funcional descrita por las técnicas de interpretabilidad (coherencia entre dos líneas metodológicas distintas).
- C6. Resultado negativo informativo.** Las estrategias basadas solo en intuición cualitativa no superan a las técnicas de compresión convencionales: el conocimiento cualitativo indica qué medir, pero solo las mediciones numéricas permiten decidir cuánto comprimir.
- C7. Compresión casi sin pérdida tras fine-tuning corto.** El modelo comprimido reentrenado tres épocas alcanza un F1 macro prácticamente equivalente al baseline reentrenado el mismo número de épocas, con un 13,6 % menos de parámetros. Un grupo de control sobre el baseline descarta la hipótesis inicial de regularización implícita por SVD: la mejora observada en el modelo comprimido proviene del entrenamiento adicional, no de la compresión. Lo que sí queda como contribución aplicada es la equivalencia funcional con menos parámetros (§7.4).

1.4. Marco del proyecto en la FIB

Este proyecto se enmarca en el Grado en Ingeniería Informática de la Facultat d'Informàtica de Barcelona, dentro de la especialidad de Computación, e integra conocimientos de varias asignaturas del grado: el álgebra lineal y el cálculo matricial fundamentan la descomposición SVD y el análisis espectral; la computación numérica sustenta la estabilidad de las aproximaciones de bajo rango; el diseño y el análisis de complejidad algorítmica respaldan el algoritmo de compresión; el aprendizaje automático sostiene el fine-tuning de BERT y los clasificadores de probing; y la ejecución eficiente en GPU ha sido necesaria para el entrenamiento y la evaluación sobre el dataset completo. La base técnica directa para el trabajo con Transformers e interpretabilidad procede además de las asignaturas de nivel máster cursadas durante el intercambio en la DTU (Dinamarca, Q1 2024–25) en *Machine Learning*, *Deep Learning* y *Graph Neural Networks*.

El proyecto tiene carácter experimental y de investigación: no se desarrolla un producto de software, sino que se estudia mediante experimentos controlados cómo la compresión SVD afecta a los distintos componentes de un Transformer y qué revela esto sobre la organización interna de las representaciones emocionales. La metodología es comparable a la de la investigación empírica en NLP: hipótesis explícitas, experimentos controlados, métricas estándar, análisis estadístico y reporte honesto de resultados, incluidos los negativos.

1.5. Alcance y limitaciones

Los resultados de este trabajo deben interpretarse dentro de un alcance acotado por diseño: un único modelo (BERT-base), una única tarea (clasificación de emociones), compresión posterior al entrenamiento y potencia estadística limitada por el número de emociones. Estas restricciones y sus implicaciones se detallan en el Capítulo 8.

1.6. Estructura de la memoria

La memoria se organiza en nueve capítulos. El Capítulo 2 documenta la gestión del proyecto: metodología de trabajo, alcance operativo, planificación temporal, presupuesto y balance entre lo planificado y lo ejecutado. El Capítulo 3 revisa el estado del arte en compresión de Transformers e interpretabilidad mecánica, sitúa los fundamentos matemáticos de la SVD y posiciona el trabajo respecto a la literatura previa. El Capítulo 4 describe la metodología experimental: dataset, modelo, técnicas de compresión y herramientas de interpretabilidad.

Los tres capítulos siguientes contienen los resultados, en orden de granularidad creciente. El Capítulo 5 presenta los resultados de compresión SVD: análisis espectral, transición de fase bajo compresión uniforme, sensibilidad por componente y profundidad, y compresión adaptativa energética. El Capítulo 6 expone los resultados de las cinco técnicas de interpretabilidad mecánica y argumenta su convergencia en una arquitectura funcional unificada. El Capítulo 7 cierra el bucle: utiliza los hallazgos de los capítulos anteriores para diseñar y evaluar la estrategia greedy de compresión informada, documenta el resultado negativo de la heurística previa y analiza la recuperación mediante fine-tuning.

El Capítulo 8 sintetiza las contribuciones, discute las limitaciones y propone líneas de investigación futura. El Capítulo 9 recoge el análisis de sostenibilidad e implicaciones éticas del proyecto.

Capítulo 2

Gestión del proyecto

Este capítulo documenta la gestión del proyecto: la metodología de trabajo, el alcance operativo, la planificación temporal, el presupuesto y el balance entre lo planificado y lo efectivamente ejecutado. La motivación, la formulación del problema y los objetivos conceptuales del trabajo se presentaron en el Capítulo 1; aquí se concretan en términos de tareas, recursos y plazos. La planificación se elaboró al inicio del proyecto y se contrasta con la ejecución real en la sección final (§2.6).

2.1. Contexto y actores

La motivación del proyecto (el coste de desplegar modelos Transformer y el papel de la compresión) y la justificación de la SVD como técnica elegida se desarrollan en el Capítulo 1 y se sitúan respecto a la literatura en el Capítulo 3. Desde el punto de vista de la gestión, conviene fijar a quién va dirigido el trabajo. Sus beneficiarios primarios son los investigadores e ingenieros de NLP, que pueden aprovechar directamente los mapas de sensibilidad y el algoritmo greedy. En un segundo plano se sitúa la comunidad académica y de código abierto: el código modular basado en Hugging Face Transformers [18] permite reutilizar la metodología sobre otros modelos y tareas. Finalmente, las empresas que despliegan modelos de lenguaje en sus productos (moderación de contenido, análisis de opinión, clasificación de tickets) y que buscan reducir sus costes de infraestructura constituyen el destinatario aplicado del trabajo.

El encuadre del proyecto en el plan de estudios de la FIB (las asignaturas del grado cuyas competencias se movilizan en cada fase) se detalla en §1.4. A efectos de gestión, ese mapa de competencias justifica la asignación de perfiles profesionales a las tareas que se introduce en §2.4.

2.2. Alcance: objetivos y requisitos

El objetivo general del proyecto se enunció en §1.2 y se desglosó en cinco objetivos conceptuales (O1–O5). Esta sección los traduce en doce sub-objetivos verificables (SO1–SO12), que sirven de unidad de planificación y de criterio de cumplimiento (Tabla 8.1 del Capítulo 8).

2.2.1. Sub-objetivos

SO1. Baseline competitivo. Demostrar que BERT-base-uncased alcanza clasificación multi-etiqueta funcional sobre las 23 emociones de GoEmotions tras filtrar las 5 que producen

- $F1 = 0$ o no son emociones (*neutral, grief, nervousness, pride, relief*; ver Cap. 4).
- SO2. Módulo SVD reutilizable.** Implementar `SVDLinear` con soporte para compresión uniforme y selectiva por componente, capa o ambos.
- SO3. Compromiso compresión–rendimiento.** Cuantificar $F1$ macro frente a rangos uniformes {512, 384, 256, 128, 64, 32}.
- SO4. Visualización de la degradación.** Producir proyecciones t-SNE de embeddings [CLS].
- SO5. Sensibilidad por componente.** Revelar qué tipos de capas (Q, K, V, Output, FFN-Inter, FFN-Out) son más vulnerables.
- SO6. Sensibilidad por profundidad.** Identificar si capas tempranas, medias o tardías son más críticas.
- SO7. Compresión adaptativa por energía espectral.** Asignar rangos no uniformes según el perfil de energía y evaluar en la frontera de Pareto.
- SO8. Localizar la cristalización emocional.** Mediante *probing* lineal capa a capa, determinar a qué profundidad cada emoción se vuelve linealmente separable. Se entrenan 23 emociones $\times$ 12 capas = 276 probes activos (los probes sobre la capa de embedding producen $F1 = 0$ uniformemente y se descartan; ver Cap. 6).
- SO9. Evidencia funcional de localización.** Usar *activation patching* y *logit lens* para distinguir información presente, información leíble por el clasificador y componentes suficientes para la recuperación.
- SO10. Mapear especialización a nivel de cabeza y neurona.** Ablación sistemática de las 144 cabezas y análisis de selectividad de las 36 864 neuronas FFN.
- SO11. Compresión informada.** Integrar SO5–SO10 en una asignación de rangos por capa y componente que supere a las estrategias ciegas en la frontera de Pareto.
- SO12. Recuperación por fine-tuning post-SVD.** Evaluar si tres épocas de re-entrenamiento sobre el modelo comprimido recuperan al baseline original con grupo de control (Cap. 7). Originalmente clasificado como objetivo opcional; promovido a objetivo principal tras observar una posible mejora que un control posterior matizó.

2.2.2. Requisitos

El sistema experimental debía cumplir varios requisitos funcionales. El módulo de compresión SVD tenía que poder aplicarse a cualquier subconjunto de capas lineales del encoder, con rangos diferenciados por componente y capa, y admitir un fine-tuning parcial del modelo comprimido. La evaluación debía automatizarse con $F1$ macro y micro y, para el análisis representacional, extraer los embeddings [CLS], generar proyecciones t-SNE conjuntas y calcular el *silhouette score* sobre ellas. Las técnicas de interpretabilidad imponían requisitos adicionales: la extracción de los *hidden states* de todas las capas (para *probing* y *logit lens*), un mecanismo de *activation patching* por capa y componente, y la ablación individual de las 144 cabezas con medición de $F1$ por emoción. Por último, todas las figuras y tablas debían ser exportables.

Entre los requisitos no funcionales, la reproducibilidad se aseguró con semilla fija y versiones de dependencias documentadas; el código se organizó en módulos separados por responsabilidad (datos, modelos, compresión y utilidades), independientes de los notebooks, que debían poder

ejecutarse tanto en local como en la nube. La eficiencia de memoria se garantizó comprimiendo sobre copias del modelo y liberándola tras cada evaluación, y la estabilidad numérica trabajando en precisión simple.

2.2.3. Obstáculos y riesgos

Tabla 2.1: Principales obstáculos y riesgos del proyecto.

Riesgo	Prob.	Imp.	Mitigación
R1 — Recursos computacionales insuficientes (GPU)	Media	Alto	Google Colab Pro; subsampleo para t-SNE; evaluaciones en CPU si es necesario.
R2 — Inestabilidad numérica con rangos muy bajos	Baja	Medio	SVD en float32; validación dimensional pre-evaluación.
R3 — Tiempo de ejecución excesivo	Alta	Medio	Ejecución secuencial con liberación de memoria; priorización.
R4 — Métricas no capturan degradación real	Baja	Alto	F1 + silhouette + visualización cualitativa.
R5 — Bug en selección de capas	Media	Medio	Tests del módulo de filtrado; alternativas documentadas.
R6 — Fine-tuning post-SVD no recupera rendimiento	Media	Medio	Documentar como hallazgo válido; explorar varias configuraciones.
R7 — Desviación del calendario por complejidad imprevista	Media	Alto	SO1–SO11 como núcleo; SO12 y benchmarks como opcionales.

Fuente: elaboración propia.

2.3. Metodología y rigor

Dado el carácter experimental e iterativo del proyecto, se adopta una metodología incremental iterativa, tomando elementos de marcos ágiles como Scrum (estudiados en PROP) adaptados a un contexto unipersonal. Cada fase sigue el ciclo: diseño → implementación → ejecución → análisis → validación, con reuniones quincenales con el director del TFG como puntos formales de revisión.

Esta elección se justifica por la naturaleza exploratoria del proyecto: los resultados de compresión uniforme (G3) motivaron el análisis desagregado por componente (G4); los estudios de lesión (G5) revelaron la necesidad de técnicas causales como activation patching (G6); y la brecha entre probing y patching motivó la incorporación del logit lens (no prevista inicialmente) como técnica adicional de interpretabilidad.

2.3.1. Herramientas

El control de versiones se llevó con Git y GitHub, que sirvió también de sistema de seguimiento de tareas. El ecosistema técnico se construyó sobre Python y PyTorch, con Hugging Face Transformers [18] para los modelos y scikit-learn, matplotlib y seaborn para el análisis y la visualización, con las dependencias fijadas y versionadas. La memoria se redactó en Overleaf (L^AT_EX) y el cómputo se repartió entre un PC personal y la GPU en la nube de Google Colab.

2.3.2. Métodos de validación

La validación combinó cuatro niveles. El nivel cuantitativo se apoyó en el F1 macro y micro sobre el conjunto de test completo, junto al ratio de parámetros. El nivel representacional empleó el silhouette score sobre las proyecciones t-SNE, complementado con una inspección visual mediante scatter y KDE. El nivel funcional o causal recurrió al activation patching, el logit lens y la ablación de cabezas para distinguir computación, alineación y transmisión. Por último, la reproducibilidad se garantizó con semilla fija (42), código modular y notebooks autocontenidos.

2.4. Planificación temporal

2.4.1. Datos globales

Tabla 2.2: Parámetros temporales del proyecto.

Parámetro	Valor	Parámetro	Valor
Fecha de inicio	2 feb. 2026	Horas diarias de trabajo	4 h/día (lectivos)
Fecha de fin prevista	26 jun. 2026	Total horas núcleo	492 h
Duración total	22 semanas	Total horas opcionales	15 h
Fecha prevista de lectura	Julio 2026	Total general	507 h (18 ECTS)

Plan revisado: 492 h de núcleo (incluye T20bis y T26 incorporados durante la ejecución) más T27 opcional no ejecutado (15 h). La ejecución real fue de 492 h (–15 h sobre 507 h planificadas), detallada en §2.6.

Fuente: elaboración propia.

Aunque todas las tareas son ejecutadas por el autor (Guido Biosca Lasa), se asigna a cada tarea el perfil profesional que mejor se ajusta al tipo de trabajo: Jefe de Proyecto (JP), Científico de Datos (CD) o Desarrollador (Dev). Esta diferenciación refleja las competencias requeridas y permite una estimación presupuestaria realista (§2.5).

2.4.2. Descripción de las fases

G0 — Gestión del proyecto (130 h, concurrente). T01–T03 (50 h, JP): tres entregas de gestión inicial (contextualización, planificación, presupuesto y sostenibilidad). T04 (20 h, JP): seguimiento con director (10 reuniones quincenales). T05 (60 h, JP): redacción progresiva de la memoria.

G1 — Configuración y baseline (39 h). T06 (8 h, Dev): repositorio + entorno. T07 (25 h, CD): fine-tuning de BERT-base-uncased sobre GoEmotions, con filtrado a 23 emociones tras descartar *neutral* (no es emoción) y las cuatro de baja frecuencia con $F1 = 0$. T08 (6 h, CD): evaluación baseline ($F1$ macro 0,577).

G2 — Módulo de compresión SVD (30 h). T09 (20 h, Dev): implementación del módulo de compresión SVD reutilizable (capa lineal factorizada y función de aplicación selectiva). T10 (10 h, Dev): tests de validación.

G3 — Compresión uniforme y análisis espectral (50 h). T11 (15 h, CD): experimentos uniformes en 6 rangos. T12 (10 h, CD): perfil de energía espectral de las 72 matrices. T13 (10 h, CD): estrategia adaptativa con 5 umbrales (80 %, 85 %, 90 %, 95 %, 99 %). T14 (15 h, CD): frontera de Pareto y vulnerabilidad por emoción.

G4 — Análisis por componente y profundidad (45 h). T15 (20 h, CD): 24 configuraciones (8 componentes $\times$ 3 rangos) con extracción de embeddings. T16 (15 h, CD): 9 configuraciones (3 bandas de profundidad $\times$ 3 rangos). T17 (10 h, CD): heatmaps, t-SNE conjuntos, silhouette.

G5 — Lesion study (23 h). T18 (15 h, CD): 12 lesiones por capa + 6 por componente. T19 (8 h, CD): mapa emocional, clustering jerárquico, escáner por emoción.

G6 — Interpretabilidad mecánica (65 h). T20 (15 h, CD): probing lineal sobre 13 hidden states; en términos efectivos quedan 23 emociones $\times$ 12 capas = 276 probes activos tras descartar el embedding ($F1$ nulo uniforme). T21 (20 h, CD): activation patching causal a granularidad capa y componente. T22 (10 h, CD): ablación de las 144 cabezas con taxonomía 2 $\times$ 2 (importancia, selectividad). T23 (10 h, CD): selectividad de las 36 864 neuronas FFN. T20bis (10 h, CD): logit lens, incorporación no prevista en la planificación inicial; necesaria para distinguir información presente, leíble y suficiente (§6.2).

G7 — Síntesis informada (55 h). T24 (20 h, CD): estrategia heurística informada (*light*, *moderate*, *aggressive*). T25 (10 h, CD): algoritmo greedy data-driven a partir de las sensibilidades empíricas + comparativa Pareto. T26 (25 h, CD): fine-tuning post-SVD del modelo *greedy_90* (3 epochs) y grupo de control sobre el baseline; originalmente opcional, promovido a tarea principal tras observar una mejora preliminar que el control posterior matizó (ver §7.4).

G8 — Objetivos secundarios opcionales (15 h, no ejecutados). T27 (15 h, CD, opcional): benchmarks de latencia y throughput. No ejecutado en este TFG; documentado como trabajo futuro (§8.3).

G9 — Cierre y síntesis (55 h). T28 (40 h, JP): integración final de la memoria. T29 (15 h, JP): preparación de la presentación oral.

2.4.3. Tabla resumen de tareas

Tabla 2.3: Tabla resumen de tareas.

Cód.	Tarea	Perfil	h	Dependencias	Rec. mat.
G0 — Gestión (130 h)					
T01	Contextualización (E1)	JP	20	—	Overleaf
T02	Planificación (E2)	JP	15	T01	Overleaf
T03	Presupuesto + sostenibilidad (E3)	JP	15	T01	Overleaf
T04	Reuniones director [conc.]	JP	20	T01	Videoconf.
T05	Redacción memoria [conc.]	JP	60	T01	Overleaf
G1 — Baseline (39 h)					
T06	Config. entorno + repo	Dev	8	T01	PC, GitHub
T07	Fine-tuning BERT (23 emociones)	CD	25	T06	GPU
T08	Evaluación baseline	CD	6	T07	PC
G2 — Módulo SVD (30 h)					
T09	Impl. SVDLinear	Dev	20	T08	PC
T10	Tests validación	Dev	10	T09	PC
G3 — Uniforme + espectral (50 h)					
T11	Comp. uniforme (6 rangos)	CD	15	T10	GPU
T12	Análisis espectral 72 matrices	CD	10	T10	PC
T13	Adaptativa (5 umbrales energéticos)	CD	10	T12	PC
T14	Pareto + vulnerabilidad emocional	CD	15	T11,T13	GPU
G4 — Comp. + profundidad (45 h)					
T15	Componente (24 configs)	CD	20	T11	GPU
T16	Profundidad (9 configs)	CD	15	T15	GPU
T17	Heatmaps + t-SNE + silhouette	CD	10	T16	PC
G5 — Lesion study (23 h)					
T18	Lesiones capa (12) + componente (6)	CD	15	T10	GPU

(Tabla 2.3, continuación)

Cód.	Tarea	Perfil	h	Dependencias	Rec. mat.
T19	Mapa emocional + clustering	CD	8	T18	PC
G6 — Interpretabilidad (65 h)					
T20	Probing lineal (276 probes activos)	CD	15	T08	PC
T20bis	Logit lens [no previsto inicialmente]	CD	10	T20	PC
T21	Activation patching	CD	20	T11	GPU
T22	Ablación cabezas (144)	CD	10	T08	GPU
T23	Análisis neuronal FFN (36 864)	CD	10	T08	GPU
G7 — Síntesis informada (55 h)					
T24	Heurística informada (3 variantes)	CD	20	T17,T19–T23	GPU
T25	Greedy data-driven + Pareto comp.	CD	10	T24	PC
T26	Fine-tuning post-SVD [promov. a obligatoria]	CD	25	T25	GPU
G8 — Opcional no ejecutado (15 h)					
T27	Benchmarks latencia/throughput [opt]	CD	15	T25	PC+GPU
G9 — Cierre (55 h)					
T28	Integración + revisión memoria	JP	40	T26	Overleaf
T29	Preparación presentación oral	JP	15	T28	PC
Total núcleo ejecutado			492		
Opcional no ejecutado (T27)			15		
Total ejecutado			492		

[opt]=opcional; [conc.]=concurrente. Rec. humano en todas: Guido Biosca Lasa. Horas según ejecución real; el plan inicial (497 h) y su balance se detallan en §2.6. Fuente: elaboración propia.

2.4.4. Gestión del riesgo: planes alternativos

Los planes B se activan únicamente si el riesgo se materializa (Tabla 2.4).

Tabla 2.4: Planes alternativos asociados a los riesgos R1–R7.

Riesgo	Prob.	Imp.	Plan B	Rec. adic.	Δh
R1 GPU insuf.	Media	Alto	Reducir T15 a 4 componentes; subsamplear t-SNE a 1 500 puntos.	Ninguno	–13 h
R2 Inest. num.	Baja	Medio	Validación numérica adicional (5 h) en float64.	5 h	+5 h
R3 Tiempo excesivo	Alta	Medio	Reducir T15–T16; paralelizar T11/T18.	Ninguno	–15 h
R4 Métricas insuf.	Baja	Alto	Análisis cualitativo (8 h): inspección de errores.	8 h	+8 h
R5 Bug capas	Media	Medio	T10 incluye tests; indexación manual de respaldo (4 h).	4 h	+4 h
R6 FT no recuperable	Media	Medio	Documentar como resultado válido. T26 originalmente opcional.	Ninguno	0 h
R7 Desviación gral.	Media	Alto	Eliminar T27 (–15 h); reducir T22+T23; documentar como trabajo futuro.	Ninguno	–15–40 h

En el peor escenario (R1+R3+R7), el núcleo se reduce a ≈ 370 h, garantizando los sub-objetivos del núcleo (SO1–SO11). Fuente: elaboración propia.

2.4.5. Diagrama de Gantt

La cadena de dependencias crítica es:

T06 → T07 → T08 → T09 → T10 → T11 → T15 → T16 → T17 → T24 → T25 → T26 → T28 → T29.

T04+T05 (gestión, redacción) son concurrentes durante todas las 22 semanas. T12 ejecuta en paralelo con T11. G5 y parte de G6 son ejecutables en paralelo con G3–G4.




Figura 2.1: Diagrama de Gantt actualizado. T20bis (logit lens) y T26 (fine-tuning) reflejan los cambios respecto a la planificación inicial. Grises: opcionales no ejecutados. Flechas: cadena crítica. Fuente: elaboración propia.

2.5. Gestión económica (presupuesto)

El presupuesto se estructura en cuatro partidas: costes de personal por actividad (CPA), costes genéricos (CG), contingencia e imprevistos.

2.5.1. Costes por hora por perfil profesional

Tabla 2.5: Coste por hora estimado por perfil profesional.

Perfil	Bruto anual	Con SS ($\times 1,3$)	Coste/hora
Jefe de proyecto (JP)	32.000 €	41.600 €	24,19 €/h $\approx$ 24 €/h
Científico de datos (CD)	28.000 €	36.400 €	21,16 €/h $\approx$ 21 €/h
Desarrollador (Dev)	25.000 €	32.500 €	18,90 €/h $\approx$ 19 €/h

Fuente: elaboración propia a partir de Hays España 2025 y Glassdoor España. 1.720 horas laborales anuales.

2.5.2. Costes de personal por actividad (CPA)

Tabla 2.6: Costes de personal por actividad (CPA).

Cód.	Tarea	Perfil	h	€/h	Coste
G0 — Gestión (130 h)					3.120 €
T01	Contextualización	JP	20	24	480 €
T02	Planificación	JP	15	24	360 €
T03	Presupuesto + sostenibilidad	JP	15	24	360 €
T04	Reuniones director	JP	20	24	480 €
T05	Redacción memoria	JP	60	24	1.440 €
G1 — Baseline (39 h)					803 €
T06	Config. entorno	Dev	8	19	152 €
T07	Fine-tuning BERT (23 emociones)	CD	25	21	525 €
T08	Eval. baseline	CD	6	21	126 €
G2 — Módulo SVD (30 h)					570 €
T09	Impl. SVDLinear	Dev	20	19	380 €
T10	Tests validación	Dev	10	19	190 €
G3 — Uniforme + espectral (50 h)					1.050 €
T11– T14	Uniforme, espectral, adapt., Pareto	CD	50	21	1.050 €
G4 — Comp. + profundidad (45 h)					945 €

(Tabla 2.6, continuación)

Cód.	Tarea	Perfil	h	€/h	Coste
T15– T17	Componente, profundi- dad, t-SNE	CD	45	21	945 €
G5 — Lesion study (23 h)					483 €
T18– T19	Lesiones + mapa emocio- nal	CD	23	21	483 €
G6 — Interpretabilidad (65 h)					1.365 €
T20	Probing lineal (276 pro- bes)	CD	15	21	315 €
T20bis	Logit lens [no previsto]	CD	10	21	210 €
T21	Activation patching	CD	20	21	420 €
T22	Ablación cabezas	CD	10	21	210 €
T23	Análisis neuronal FFN	CD	10	21	210 €
G7 — Síntesis informada (55 h)					1.155 €
T24	Heurística informada	CD	20	21	420 €
T25	Greedy + Pareto comp.	CD	10	21	210 €
T26	Fine-tuning post-SVD	CD	25	21	525 €
G9 — Cierre (55 h)					1.320 €
T28	Memoria final	JP	40	24	960 €
T29	Presentación oral	JP	15	24	360 €
Total CPA núcleo (sin opcional T27)			492		10.811 €

Fuente: elaboración propia.

2.5.3. Costes genéricos (CG)

Tabla 2.7: Costes genéricos del proyecto.

Concepto	Detalle	Coste total	Vida útil	Imputado
Amortización PC portátil	1.200 €, uso 5 meses	1.200 €	4 años (48 m.)	125 €
Google Colab Pro	11,99 €/mes × 5 meses	—	—	60 €
Electricidad	0,1 kW × 492 h × 0,20 €/kWh	—	—	10 €
Software open source	Python, PyTorch, HF, scikit-learn	—	—	0 €
Overleaf, GitHub	Plan gratuito	—	—	0 €
Internet	Uso parcial conexión doméstica	—	—	25 €
Espacio de trabajo	Uso parcial domicilio (10 m ² , 5 meses)	—	—	50 €
Total costes genéricos				270 €

Amortización: $1,200 \times 5/48 = 125$ €. Trabajo desde domicilio (sin desplazamientos). Fuente: elaboración propia.

2.5.4. Contingencia e imprevistos

Se aplica un ratio de contingencia del 15 % sobre la suma de CPA y CG, dentro del rango habitual del 10–20 % en proyectos informáticos:

$$\text{Contingencia} = (10,811 + 270) \times 0,15 = \mathbf{1.662 \text{ €}}.$$

Las partidas de imprevistos se vinculan a los riesgos identificados, ponderadas por probabilidad:

Tabla 2.8: Partidas de imprevistos.

Riesgo	Prob.	Coste si ocurre	Detalle	Imputado
R1 GPU insuf.	50 %	150 €	Upgrade Colab Pro+ (3 m.)	75 €
R2 Inest. num.	20 %	105 €	5 h extra CD	21 €
R4 Métricas insuf.	20 %	168 €	8 h extra CD	34 €
R5 Bug capas	50 %	76 €	4 h extra Dev	38 €
Total imprevistos				168 €

R3, R6 y R7 se mitigan reduciendo alcance, sin coste adicional. Fuente: elaboración propia.

2.5.5. Presupuesto total

Tabla 2.9: Resumen del presupuesto total del proyecto.

Partida	Importe	%
Costes de personal (CPA)	10.811 €	83,7 %
Costes genéricos (CG)	270 €	2,1 %
Contingencia (15 %)	1.662 €	12,9 %
Imprevistos	168 €	1,3 %
Total presupuesto	12.911 €	100 %

El coste de personal representa ~83,7 % del total, habitual en proyectos de investigación aplicada. Fuente: elaboración propia.

2.5.6. Control de gestión

Para detectar y corregir desviaciones presupuestarias durante la ejecución se definió un procedimiento de control: al finalizar cada fase del Gantt (G1–G9) se registran las horas reales dedicadas a cada tarea y se comparan con las estimadas, y las reuniones quincenales con el director (T04) sirven como puntos formales de revisión.

El seguimiento se apoya en cuatro indicadores. La desviación en horas por tarea, $\Delta h_i = h_i^{\text{real}} - h_i^{\text{est}}$, activa una revisión de la planificación restante cuando supera el 20 % de lo estimado. La desviación en coste por fase dispara el plan B correspondiente si $\Delta C_g > 0,15 \times C_g^{\text{est}}$. El índice de rendimiento del coste, $\text{CPI} = \text{EV}/\text{AC}$, señala sobrecostes que exigen acción correctiva cuando cae por debajo de 0,85. Y si el porcentaje de contingencia consumida supera el 50 % antes de completar el 75 % del proyecto, se priorizan SO1–SO11 y se eliminan las tareas opcionales.

2.6. Ejecución real frente a planificación

Esta sección, redactada al cierre del proyecto, contrasta lo ejecutado con la planificación inicial.

2.6.1. Ajustes de alcance respecto a la planificación inicial

Durante la ejecución se introdujeron cuatro modificaciones de alcance respecto a la planificación inicial, todas en la dirección de ampliar la profundidad del análisis y justificadas por los hallazgos intermedios.

La primera fue el filtrado a 23 emociones (que afecta a O1, O3, T07 y T08): tras el fine-tuning sobre las 28 emociones de GoEmotions, cuatro de ellas (*grief*, *nervousness*, *pride*, *relief*) producían $F1 = 0$ y la categoría *neutral* distorsionaba las métricas macro, de modo que se filtraron las cinco y se trabajó con 23 emociones funcionales (Cap. 4); el filtrado no añadió horas significativas de cómputo. La segunda, consecuencia directa de la anterior, fue la reducción de los probes efectivos de 364 a 276: la planificación estimaba 28 emociones $\times$ 13 capas, pero tras el filtrado a 23 emociones y el descarte de la capa de embedding (donde el F1 lineal es nulo de forma uniforme) el número efectivo de clasificadores entrenados quedó en 276 (Cap. 6), con la consiguiente reducción del coste computacional.

La tercera fue incorporar el logit lens (T20bis, +10 h, no prevista): la brecha entre el probing (información presente) y el activation patching (suficiencia funcional) motivó añadirlo para distinguir información presente de información leíble por la cabeza de clasificación entrenada (§6.2), lo que extendió G6 de 55 a 65 h. La cuarta fue promover el fine-tuning post-SVD (T26), inicialmente opcional dentro de G8, a tarea principal: el reentrenamiento de tres épocas sobre el modelo `greedy_90` produjo un resultado que merecía análisis riguroso, y un experimento de control (baseline más 3 épocas adicionales) refutó la hipótesis de regularización implícita al mostrar que la mejora proviene del entrenamiento adicional y no de la compresión (§7.4); como contrapartida, T27 (benchmarks de latencia) se pospuso como trabajo futuro.

2.6.2. Resumen del balance de horas

Tabla 2.10: Comparativa entre la planificación inicial y la ejecución real.

Fase	Plan revisado (h)	Ejecutado (h)	Δ
G0 Gestión	130	130	0
G1 Baseline	39	39	0
G2 Módulo SVD	30	30	0
G3 Uniforme + espectral	50	50	0
G4 Componente + profundidad	45	45	0
G5 Lesion study	23	23	0
G6 Interpretabilidad	65	65	0
G7 Síntesis informada	55	55	0
G8 Opcionales (T27)	15	0	-15 (T27 no ejecutado)
G9 Cierre	55	55	0
Total	507	492	-15

Plan revisado respecto al plan inicial (497 h): T20bis y T26 incorporados, T27 como único opcional. La única desviación respecto al plan revisado es la cancelación de T27 (-15 h, -3 %). Fuente: elaboración propia.

2.6.3. Planes B activados

De los 7 riesgos identificados, sólo el R3 (tiempo de ejecución excesivo) se materializó parcialmente en G4: el experimento por componente (T15) se ejecutó secuencialmente, con liberación explícita de memoria entre configuraciones para evitar saturar la GPU. No fue necesario reducir el alcance de T15.

2.6.4. Indicadores de control finales

Al cierre, el balance de los indicadores es favorable. La desviación total en horas fue de -15 h sobre 507 h planificadas (-3 %), dentro de tolerancia, con un CPI estimado de $\approx 1,01$ (proyecto en presupuesto). No se consumió contingencia (0 %), ya que no hicieron falta las horas extra ponderadas por riesgo, de modo que el margen del 15 % quedó como holgura. La única tarea opcional cancelada fue T27 (benchmarks de latencia), redirigida a trabajo futuro, mientras que la única tarea no prevista incorporada fue T20bis (logit lens), por una necesidad metodológica detectada en G6.

Capítulo 3

Estado del arte y marco teórico

El trabajo cruza dos líneas de investigación que rara vez dialogan en la literatura: comprensión de modelos e interpretabilidad mecánica. El capítulo cubre la arquitectura Transformer y BERT, los fundamentos matemáticos de la SVD, el problema de la clasificación de emociones, las técnicas de compresión e interpretabilidad disponibles, y la posición de este trabajo respecto a ellas.

3.1. Del procesamiento secuencial al Transformer

El procesamiento del lenguaje natural fue durante décadas un problema fundamentalmente secuencial. Las redes neuronales recurrentes (RNN) [19] procesaban el texto dividido en *tokens* (las unidades mínimas en que se segmenta una frase, normalmente palabras o fragmentos de palabra), uno a uno, manteniendo un vector de estado oculto que acumulaba información de los tokens anteriores. En la práctica, esta información se degradaba exponencialmente con la distancia: las RNN sufrían el problema del desvanecimiento del gradiente [20], que impedía aprender dependencias a larga distancia. Las LSTM [21] mitigaron parcialmente este problema introduciendo mecanismos de puertas que controlan qué información se almacena, se olvida o se transmite, y dominaron el NLP durante la década de 2014–2017.

Sin embargo, las arquitecturas recurrentes tienen una limitación estructural: al procesar los tokens secuencialmente, la computación no es paralelizable (el cálculo de h_t depende de h_{t-1}), lo que limita la velocidad de entrenamiento e impide aprovechar eficientemente las GPUs.

Un primer avance fue el mecanismo de atención de Bahdanau et al. [22], que permitió al decoder de un modelo de traducción atender selectivamente a distintas posiciones del encoder, eliminando el cuello de botella de comprimir toda la frase de origen en un único vector. Pero la recurrencia seguía presente.

La contribución de Vaswani et al. [1] fue radical: el Transformer elimina completamente las operaciones recurrentes y se basa exclusivamente en mecanismos de atención, con tres ventajas:

1. **Paralelismo total:** todas las posiciones se procesan simultáneamente.
2. **Distancia constante:** la atención conecta cualquier par de posiciones en $O(1)$, frente a los $O(n)$ pasos de una RNN.
3. **Escalabilidad:** permitió entrenar modelos significativamente más grandes, lo que dio lugar a los modelos de lenguaje pre-entrenados.

El mecanismo de atención, sin embargo, tiene un coste. Calcula la similitud entre todos los

pares de posiciones de la secuencia, lo que implica una complejidad cuadrática $O(n^2)$ tanto en tiempo como en memoria respecto a la longitud del contexto n . Esto limita la ventana de contexto que el modelo puede manejar: a diferencia de las RNN, que procesaban secuencias arbitrariamente largas (aunque olvidando información lejana), el Transformer requiere cargar toda la secuencia en memoria simultáneamente, y el coste crece de forma cuadrática con su longitud. En la práctica, esto impone un límite máximo de contexto determinado por la memoria disponible durante el entrenamiento.

El impacto fue inmediato en traducción automática, pero el cambio más profundo vino después: la arquitectura Transformer, pre-entrenada sobre grandes corpus, producía representaciones lingüísticas de propósito general transferibles a prácticamente cualquier tarea de NLP. Esto dio lugar a la era de los *foundation models* (BERT [2], GPT [23], T5 [24]).

3.2. La arquitectura Transformer

La arquitectura Transformer original [1] se compone de dos bloques apilados (encoder y decoder) conectados mediante atención cruzada (Figura 3.1). Los modelos generativos usan el decoder; los orientados a producir representaciones reutilizables (como BERT) se basan en el encoder. Los componentes comunes se describen a continuación; las particularidades de BERT se tratan en la Sección 3.3.




Figura 3.1: Arquitectura Transformer original [1]. Encoder a la izquierda, decoder a la derecha, bloques apilados N veces.

3.2.1. Codificación posicional

La atención no tiene noción intrínseca de orden (trata la entrada como un conjunto), así que el Transformer suma a cada embedding una codificación posicional de la misma dimensión. La

formulación original [1] usa funciones sinusoidales

$$\text{PE}_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d}}\right), \quad \text{PE}_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d}}\right), \quad (3.1)$$

que permiten representar posiciones relativas y extrapolar a longitudes no vistas durante el entrenamiento. BERT, en cambio, aprende estas codificaciones como parámetros (§3.3).

3.2.2. Atención multi-cabeza

El mecanismo central del Transformer es la atención escalada por producto escalar (*scaled dot-product attention*). Dada una secuencia de n tokens $X \in \mathbb{R}^{n \times d}$, cada cabeza h (de un total de H) computa tres proyecciones lineales $Q_h = XW_Q^h$, $K_h = XW_K^h$, $V_h = XW_V^h$ con $W_Q^h, W_K^h, W_V^h \in \mathbb{R}^{d \times d_k}$ y $d_k = d/H$. La salida es

$$\text{head}_h = \text{softmax}\left(\frac{Q_h K_h^\top}{\sqrt{d_k}}\right) V_h, \quad \text{MultiHead}(X) = [\text{head}_1; \dots; \text{head}_H] W_O, \quad (3.2)$$

con $W_O \in \mathbb{R}^{d \times d}$. El factor $1/\sqrt{d_k}$ estabiliza los gradientes a través de la softmax.

Cada cabeza opera en un subespacio de dimensión d_k y puede especializarse. Trabajos posteriores [17, 25] confirmaron que esta especialización emerge espontáneamente: algunas cabezas atienden a posiciones sintácticas, otras a tokens semánticamente relacionados, otras a patrones posicionales fijos.

3.2.3. El bloque feed-forward

Cada capa incluye un bloque feed-forward (FFN) que se aplica posición por posición:

$$\text{FFN}(x) = \text{GELU}(x W_{\text{int}} + b_1) W_{\text{out}} + b_2, \quad (3.3)$$

con $W_{\text{int}} \in \mathbb{R}^{d \times d_{\text{ff}}}$, $W_{\text{out}} \in \mathbb{R}^{d_{\text{ff}} \times d}$ y dimensión interna expandida $d_{\text{ff}} = 4d$. La activación GELU [26] es una versión suave de ReLU que permite gradientes no nulos para valores negativos pequeños. La no linealidad es necesaria: sin ella, las dos multiplicaciones colapsarían en una sola transformación lineal.

El espacio expandido $d_{\text{ff}} = 4d$ permite al modelo computar transformaciones complejas antes de proyectar de vuelta. Geva et al. [16] interpretan las neuronas de esta capa como *memorias clave-valor*: cada neurona almacena un patrón de activación (clave, en W_{int}) y un vector de actualización del espacio residual (valor, en W_{out}). Esta perspectiva es directamente relevante para el análisis neuronal del Capítulo 6.

3.2.4. Conexiones residuales y flujo residual

La salida de cada sub-bloque se combina con su entrada mediante una conexión residual [27] seguida de *layer normalization* [28]:

$$h' = \text{LayerNorm}(x + \text{MultiHead}(x)) \quad (3.4)$$

$$h'' = \text{LayerNorm}(h' + \text{FFN}(h')) \quad (3.5)$$

Las conexiones residuales crean un *flujo residual* (*residual stream*) que atraviesa todas las capas. Elhage et al. [8] formalizaron esta perspectiva: conceptualmente, cada capa lee del flujo, computa una actualización, y la escribe de vuelta sumándola. La representación final de un token es la suma acumulada de todas las contribuciones:

$$x_L = x_0 + \sum_{l=1}^L \Delta_l^{\text{attn}} + \sum_{l=1}^L \Delta_l^{\text{ffn}} \quad (3.6)$$

Esta arquitectura tiene una implicación directa para la compresión: cuando se comprime una capa intermedia, la señal corrupta se propaga por el flujo residual a todas las capas posteriores, generando un efecto en cascada que amplifica el daño.

3.3. BERT

BERT (*Bidirectional Encoder Representations from Transformers*) [2] demostró el poder del paradigma *pre-train + fine-tune*: un Transformer encoder pre-entrenado sobre grandes corpus produce representaciones transferibles a tareas específicas con un fine-tuning mínimo. BERT utiliza exclusivamente la torre del encoder del Transformer, descartando el decoder por completo, ya que su objetivo no es generar secuencias sino producir representaciones bidireccionales reutilizables.

BERT-base consta de $L = 12$ capas de encoder, con $d = 768$, $H = 12$ cabezas ($d_k = 64$), y $d_{ff} = 3072$, sumando 110 millones de parámetros. De estos, 84,9 millones corresponden a las 72 capas lineales del encoder (6 matrices por capa $\times$ 12 capas), que son el objetivo de la compresión SVD. La Figura 3.2 detalla la estructura interna de uno de estos bloques encoder, una vez explicados sus componentes en la sección anterior.




Figura 3.2: Arquitectura de un bloque encoder de BERT-base. Cada bloque contiene un sub-bloque de atención multi-cabeza (con 12 cabezas de dimensión 64) y un sub-bloque feed-forward (con expansión $768 \rightarrow 3072 \rightarrow 768$), ambos con conexión residual (líneas discontinuas) y layer normalization. Las 6 matrices de pesos anotadas ($W_Q, W_K, W_V, W_O, W_{int}, W_{out}$) son el objetivo de la compresión SVD. BERT-base apila 12 de estos bloques. Fuente: elaboración propia.

3.3.1. Pre-entrenamiento bidireccional

BERT se pre-entrena sobre BookCorpus + Wikipedia (3.300 millones de palabras) mediante *Masked Language Modeling* (MLM): se enmascara aleatoriamente el 15 % de los tokens y el modelo debe predecirlos a partir del contexto bidireccional. A diferencia de los modelos autoregresivos como GPT [23], que solo ven el contexto izquierdo, BERT accede simultáneamente al contexto izquierdo y derecho, lo que produce representaciones más ricas. Para la clasificación de emociones, donde el tono emocional puede depender de partículas negativas al final de la frase (“no estoy enfadado en absoluto”), esta bidireccionalidad tiene una utilidad directa.

BERT también incluye un segundo objetivo de pre-entrenamiento, *Next Sentence Prediction* (NSP), que entrena al modelo a predecir si dos frases son consecutivas en el texto original. Aunque trabajos posteriores como RoBERTa [29] demostraron que NSP no es necesario e incluso puede ser contraproducente, forma parte del diseño original de BERT-base, que es el modelo utilizado en este trabajo.




Figura 3.3: Masked Language Modeling. El modelo predice los tokens enmascarados usando el contexto bidireccional completo. Fuente: elaboración propia.

3.3.2. El token [CLS] y el fine-tuning

BERT añade un token especial [CLS] al inicio de cada secuencia. Al no corresponder a ninguna palabra real, [CLS] no tiene significado léxico propio; es un recolector de información global que, en las 12 capas, acumula información de toda la secuencia a través del mecanismo de atención. Su representación en la última capa se usa como input al clasificador de la tarea.

El fine-tuning consiste en añadir una capa lineal sobre [CLS] y entrenar el modelo completo sobre la tarea objetivo. Esto transfiere el conocimiento lingüístico del pre-entrenamiento a la tarea específica con un coste significativamente menor que entrenar desde cero.

La propiedad de [CLS] como agregador lo convierte en el punto de lectura natural para los *probing classifiers* de este trabajo: su activación en cada capa intermedia captura el estado de procesamiento del modelo en ese punto de la jerarquía.

3.4. Fundamentos de la descomposición en valores singulares

La SVD es la herramienta matemática central del proyecto. Se cubren aquí su definición, la aproximación de bajo rango y la noción de energía espectral que se retoma en los capítulos de resultados.

3.4.1. Definición e interpretación geométrica

Toda matriz $W \in \mathbb{R}^{m \times n}$ admite una descomposición $W = U\Sigma V^T$, donde $U \in \mathbb{R}^{m \times m}$ y $V \in \mathbb{R}^{n \times n}$ son ortogonales y Σ contiene los valores singulares $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ con $r = \text{rank}(W)$. Geométricamente, W se descompone en una rotación (V^T), un escalado por los valores singulares (Σ) y otra rotación (U): la esfera unitaria se convierte en un elipsoide con semiejes σ_i .

En el contexto de BERT, las direcciones con valores singulares grandes son las que el modelo usa con más intensidad. Las direcciones con valores singulares pequeños pueden ser ruido, redundancia o señales funcionales débiles pero relevantes; cuál de las tres se da en cada caso es lo que investiga este trabajo.

3.4.2. Aproximación de bajo rango y el teorema de Eckart-Young

La aproximación truncada de rango k conserva los k primeros valores singulares, $W_k = \sum_{i=1}^k \sigma_i u_i v_i^\top$. El teorema de Eckart-Young-Mirsky [7] establece que es la aproximación óptima bajo la norma de Frobenius:

$$W_k = \arg \min_{\text{rank}(\hat{W}) \leq k} \|W - \hat{W}\|_F, \quad \|W - W_k\|_F^2 = \sum_{i=k+1}^r \sigma_i^2. \quad (3.7)$$

La optimalidad es algebraica, no funcional: dos matrices con el mismo error de Frobenius pueden producir efectos muy distintos en el rendimiento del modelo según si los valores singulares eliminados codifican redundancia o información crítica. Esta discrepancia motiva el uso de interpretabilidad para guiar la compresión.

3.4.3. Energía espectral y compresión efectiva

La fracción de energía retenida mide la calidad de la aproximación:

$$E(k) = \frac{\sum_{i=1}^k \sigma_i^2}{\sum_{i=1}^r \sigma_i^2}. \quad (3.8)$$

Matrices con decaimiento espectral rápido admiten compresión agresiva; matrices con espectro plano resisten cualquier truncamiento.

En la práctica, la aproximación reemplaza una capa W de dimensión $m \times n$ por dos capas, $V_k^\top$ y $U_k \Sigma_k$, reduciendo los parámetros de mn a $k(m+n)$. La compresión solo es efectiva cuando $k < mn/(m+n)$, lo que da rangos de equilibrio (*break-even*) de 384 para las matrices de atención (768×768) y 614 para las FFN (768×3072).

3.5. Clasificación de emociones en NLP

3.5.1. Del análisis de sentimientos a la detección de emociones

El análisis de sentimientos, clasificar textos como positivos, negativos o neutros [30], fue una de las primeras aplicaciones exitosas del NLP, pero su granularidad de tres categorías es insuficiente para muchas aplicaciones. La detección de emociones aborda esta limitación usando taxonomías más ricas, como las seis emociones básicas de Ekman [31] o el modelo de ocho emociones de Plutchik [32]. El dataset GoEmotions [11], con 28 categorías emocionales (27 emociones + *neutral*) sobre 58.009 comentarios de Reddit, representa el estándar actual para esta tarea.

3.5.2. Clasificación multi-etiqueta

Un mismo texto puede expresar múltiples emociones simultáneamente, lo que convierte el problema en clasificación multi-etiqueta. A diferencia de la clasificación multi-clase, donde softmax distribuye una probabilidad total de 1 entre las clases (forzando que una domine),

la clasificación multi-etiqueta aplica sigmoid a cada clase independientemente, permitiendo múltiples clases activas. La función de pérdida correspondiente es la *binary cross-entropy*:

$$\mathcal{L} = -\frac{1}{C} \sum_{c=1}^C [y_c \log(\hat{p}_c) + (1 - y_c) \log(1 - \hat{p}_c)] \quad (3.9)$$

donde $C = 23$, $y_c \in \{0, 1\}$, y $\hat{p}_c = \sigma(z_c)$.

3.5.3. Desafíos de la clasificación emocional

La clasificación de emociones presenta desafíos específicos relevantes para interpretar los resultados de este proyecto:

Ambigüedad semántica. Emociones como *annoyance* y *anger* ocupan regiones cercanas del espacio semántico y se distinguen solo por intensidad o contexto pragmático. Esta ambigüedad explica por qué algunas emociones necesitan más capas de procesamiento: el modelo debe integrar información contextual que las primeras capas no capturan.

Desequilibrio de clases. En GoEmotions, *admiration* tiene 4.130 ejemplos mientras que *embarrassment* tiene 303, un factor de 13,6×. Este desequilibrio afecta tanto al rendimiento como a la robustez frente a la compresión.

Señal léxica vs. contextual. Algunas emociones tienen marcadores léxicos claros (“gracias” → *gratitude*), mientras que otras dependen enteramente del contexto. Esta distinción, que el probing captura como cristalización temprana vs. tardía, tiene consecuencias directas para la compresión: las emociones léxicas son robustas (su señal se captura en capas tempranas, redundantes y compresibles), mientras que las contextuales dependen de las capas tardías (frágiles bajo SVD).

3.6. Compresión de modelos Transformer

La compresión de modelos busca reducir el tamaño y el coste computacional sin destruir lo aprendido [6]. En los Transformers, esto resulta determinante para el despliegue en entornos con restricciones de memoria, latencia o energía [4].

3.6.1. Poda

La poda elimina pesos o estructuras completas cuya contribución es marginal [33]. Wang et al. [34] mostraron que es posible eliminar hasta el 40 % de las cabezas de BERT sin pérdida significativa. Michel et al. [35] confirmaron que en muchos casos una sola cabeza por capa es suficiente. El inconveniente es que típicamente requiere re-entrenamiento.

3.6.2. Cuantización

La cuantización reduce la precisión numérica de los pesos (de float32 a int8 o menos) [36]. Dettmers et al. [37] combinaron cuantización a 4 bits con adaptadores de bajo rango (QLoRA). La limitación es la dependencia de hardware con soporte para operaciones de baja precisión.

3.6.3. Destilación

En la destilación de conocimiento [38], un modelo pequeño (estudiante) aprende a reproducir el comportamiento de uno grande (profesor): se entrena con las etiquetas reales y con las distribuciones de probabilidad “blandas” que produce el modelo grande, que transmiten información sobre la similitud relativa entre clases. DistilBERT [39] aplicó esta idea para reducir BERT a 6 capas conservando alrededor del 97 % del rendimiento, y variantes posteriores como TinyBERT [40] destilan además las representaciones internas y los mapas de atención. El principal inconveniente es que la destilación exige un ciclo completo de entrenamiento del modelo estudiante.

3.6.4. Factorización de bajo rango

La SVD (§3.4) es el método más directo. Noach y Goldberg [12] la aplicaron a BERT con compresión uniforme. Hsu et al. [13] propusieron una variante ponderada por la información de Fisher que prioriza las direcciones más relevantes para la tarea. LoRA [41] aborda el problema inverso: en lugar de comprimir un modelo existente, añade adaptadores de bajo rango para fine-tuning eficiente. La literatura ha analizado también las propiedades estructurales de bajo rango en los Transformers desde dos ángulos complementarios: Bhojanapalli et al. [42] demostraron que las cabezas de atención presentan un cuello de botella de bajo rango cuando la dimensión por cabeza es inferior a la longitud de secuencia, resultado que conecta directamente con la asimetría espectral entre componentes Q/K y FFN documentada en este trabajo. Por su parte, Wang et al. [43] (Linformer) explotaron explícitamente la naturaleza de bajo rango de la matriz de atención $\text{softmax}(QK^T)$ para reducir su complejidad de $O(n^2)$ a $O(n)$. Estos trabajos sugieren que la atención es estructuralmente comprimible, lo que es consistente con la robustez de Q/K bajo SVD que documentaremos en el Capítulo 5.

La línea de SVD para LLMs se ha mantenido activa desde 2023. Las variantes recientes corrigen la SVD clásica de dos maneras complementarias: con información sobre las activaciones (ASVD [44] pondera los valores singulares por la magnitud típica de las activaciones de entrada) o sobre el error de salida (SVD-LLM [45] minimiza el error en el espacio de salida y reporta resultados competitivos hasta el 60 % de compresión). En paralelo, ShortGPT [46] aborda una pregunta ortogonal (qué capas enteras son prescindibles) y muestra que en LLaMA-2-13B se pueden eliminar hasta 9 de las 40 capas con caída moderada. Y SparseGPT [47] demuestra que la poda no estructurada *one-shot* sin re-entrenamiento es viable a escala de 175 000 M de parámetros. La Tabla 3.1 resume las cinco familias de técnicas; los trabajos recientes operan dentro de la familia “SVD” pero con variantes algorítmicas más sofisticadas que la truncación clásica empleada en este TFG.

Tabla 3.1: Comparativa de técnicas de compresión para Transformers. Fuente: elaboración propia.

	Poda	Cuantiz.	Destilación	SVD	LoRA
Re-entrenamiento	Sí/Parcial	No/Parcial	Sí (completo)	No *	Sí (parcial)
Granularidad	Media	Baja	Baja	Alta	Alta
Garantías teóricas	No	Parcial	No	Sí	Parcial
Aplicable post-hoc	Parcial	Sí	No	Sí	No
Hardware especial	No	Sí	No	No	No

*No requiere re-entrenamiento para su aplicación inicial; el efecto de un fine-tuning posterior se evalúa empíricamente en el Capítulo 7.

3.6.5. Justificación del enfoque SVD

La SVD encaja con los objetivos del proyecto por cuatro razones. Primero, no requiere re-entrenamiento, lo que permite evaluar decenas de configuraciones a bajo coste y desacoplar el efecto de la compresión del del re-entrenamiento. Segundo, ofrece granularidad máxima (rango específico por capa). Tercero, el teorema de Eckart-Young (§3.4.2) garantiza optimalidad respecto a la norma de Frobenius. Cuarto, el espectro de valores singulares aporta interpretabilidad directa sobre la estructura de cada matriz de pesos. La posibilidad de combinar la SVD con un fine-tuning posterior se evalúa empíricamente en el Capítulo 7.

Un aspecto común a todas las técnicas anteriores es que son ciegas respecto a la función del modelo: la poda elimina pesos de baja magnitud, la cuantización reduce precisión, la SVD trunca valores singulares pequeños, pero ninguna utiliza información sobre qué computan los componentes. La posibilidad de guiar la compresión con conocimiento funcional (proteger los componentes que el modelo realmente necesita y comprimir los redundantes) está poco explorada en la literatura. Este trabajo investiga precisamente esta dirección.

3.7. Interpretabilidad mecánica

La interpretabilidad mecánica busca entender cómo procesan información las redes neuronales, identificando los circuitos internos responsables de comportamientos específicos. A diferencia de métodos post-hoc como LIME [48] o SHAP [49], que tratan al modelo como caja negra, la interpretabilidad mecánica abre el modelo y examina sus componentes.

3.7.1. Probing de representaciones

Los probing classifiers [50, 51] son clasificadores simples (regresiones logísticas) entrenados sobre las representaciones intermedias de un modelo para detectar qué información está codificada en cada capa.

La restricción a clasificadores lineales es deliberada: un probe no-lineal complejo podría extraer información de cualquier representación, pero un probe lineal solo detecta información que ya está separada linealmente en el espacio de activaciones. Si un probe lineal clasifica una propiedad con alto F1 a partir de la capa l , esa propiedad está codificada de forma linealmente accesible en

dicha capa.

Tenney et al. [14] documentaron una jerarquía en BERT: capas tempranas codifican información léxica, intermedias capturan relaciones semánticas, y tardías se especializan en la tarea. Hewitt y Liang [52] establecieron que los probes deben mantenerse simples ($C = 1,0$, sin tuning) para medir la representación, no la capacidad del clasificador.

La distinción entre información *presente* en una representación e información efectivamente *utilizable* por un clasificador ha sido formalizada desde varios ángulos. El *amnesic probing* de Elazar et al. [53] elimina por proyección la información de un atributo y mide el impacto en el comportamiento del modelo, separando lo que está codificado de lo que el modelo realmente usa. La *V-usable information* [54, 55] cuantifica la información extraíble bajo una familia de modelos de capacidad acotada, distinguiendo lo presente de lo accesible computacionalmente. Belinkov [56] revisa críticamente las promesas y los límites del probing como herramienta interpretativa. Este trabajo no introduce un formalismo nuevo de esta familia, sino que *operacionaliza empíricamente* la distinción en el dominio emocional, combinando probing (presencia), *logit lens* (legibilidad geométrica) y *activation patching* (suficiencia funcional) sobre un mismo modelo (§6.2).




Figura 3.4: Probing de representaciones. Se entrena un clasificador lineal (regresión logística) sobre el token [CLS] de cada capa intermedia. El F1 del probe indica cuánta información emocional es linealmente accesible en esa capa. Los valores mostrados son ilustrativos. Fuente: elaboración propia.

En este trabajo se entrenan probes sobre [CLS] para cada capa y emoción. El concepto de *cristalización*, la primera capa donde una emoción alcanza el 80 % de su F1 máximo, conecta profundidad de procesamiento con complejidad semántica.

3.7.2. Activation patching

El probing es correlacional: detecta qué información está presente, pero no si la capa la computa o solo la transmite por el flujo residual. Las intervenciones causales resuelven esto: si manipulamos un componente y observamos un cambio en el comportamiento, ese componente es causalmente responsable.

El análisis de mediación causal fue introducido en NLP por Vig et al. [57] para estudiar sesgos de género en modelos de lenguaje, formalizando la distinción entre efecto directo (la información fluye hacia la salida sin pasar por el componente intervenido) y efecto indirecto. Sobre esta base, Meng et al. [9] introdujeron el *causal tracing*: (1) ejecutar el modelo normalmente (*clean run*), (2) corromper las representaciones (*corrupted run*), y (3) restaurar selectivamente un componente (*patching*) para ver si el comportamiento se recupera. Descubrieron que los hechos factuales se

localizan en las capas FFN, no en la atención. Conmy et al. [10] formalizaron el framework para descubrir circuitos computacionales completos.




Figura 3.5: Activation patching en este trabajo. Se parte de un modelo colapsado por compresión ($F1 = 0$) y se restauran los pesos originales de un componente. La recuperación del F1 indica responsabilidad causal. Fuente: elaboración propia.

En este trabajo, la compresión SVD a rango 64 es la herramienta de corrupción, lo que permite estudiar simultáneamente la localización emocional y la interacción entre compresión y estructura funcional. El alcance epistémico de este uso requiere una precisión: la corrupción mediante SVD truncada no es neutral en sentido estadístico, a diferencia del causal tracing clásico de Meng et al. (que emplea ruido gaussiano sobre los embeddings), sino una distorsión estructurada. Esto significa que las conclusiones de patching extraídas en este trabajo son de naturaleza funcional (qué componentes son suficientes para reactivar el modelo desde el colapso) más que estrictamente causal en el sentido de Pearl. La distinción se discute con detalle en §6.3.

3.7.3. Logit lens y proyecciones intermedias

El probing detecta información presente; el activation patching identifica componentes suficientes. El logit lens [58] aborda una pregunta intermedia: ¿qué información de las capas intermedias es leíble directamente por la cabeza de clasificación del modelo? Aplica la proyección final (la cabeza de clasificación entrenada de la última capa) a las representaciones de capas intermedias, sin re-entrenamiento, y observa las predicciones que emitiría el modelo si decidiese desde cada capa.

Esto permite distinguir dos fenómenos que el probing no separa: información geoméricamente alineada con la base del clasificador frente a información presente pero rotada hacia bases internas del modelo no proyectables sobre el clasificador. Tiene una limitación de calibración conocida: la cabeza fue entrenada exclusivamente sobre activaciones de la última capa, lo que descalibra las magnitudes absolutas en capas intermedias, limitación que Belrose et al. [59] mitigaron con *tuned lens*: una transformación lineal por capa que corrige el desajuste de distribución. En este trabajo se aplica el logit lens estándar con interpretación cualitativa de los patrones (§6.2); la extensión a *tuned lens* se discute como trabajo futuro (§8.3).

3.7.4. Ablación de cabezas de atención

Voita et al. [17] identificaron cabezas especializadas en relaciones posicionales, sintácticas y de tokens infrecuentes. Clark et al. [25] documentaron patrones de atención a gran escala. Michel et al. [35] mostraron que la mayoría de cabezas son redundantes, pero la importancia varía entre capas y tareas.

Este trabajo extiende la ablación al dominio emocional, anulando cada una de las 144 cabezas de BERT y midiendo el impacto por emoción, construyendo una taxonomía bidimensional basada en importancia y selectividad emocional.

3.7.5. Análisis de neuronas FFN

Como se introdujo en la Sección 3.2.3, Geva et al. [16] propusieron que las capas FFN funcionan como memorias clave-valor. Sobre esa base, Dai et al. [60] identificaron *knowledge neurons* que se activan selectivamente para hechos factuales específicos: suprimirlas o amplificarlas modifica el conocimiento del modelo.

Este trabajo extiende el concepto al dominio emocional, analizando las 36.864 neuronas FFN de BERT mediante scores de selectividad (Cohen's d) e investigando si la compresión SVD daña selectivamente las neuronas especializadas.

3.7.6. Superposition y sus implicaciones para la compresión

Elhage et al. [61] formalizaron el concepto de *superposition*: cuando el modelo necesita representar más conceptos que dimensiones disponibles ($d = 768$), distribuye la información en direcciones casi-ortogonales, aceptando pequeñas interferencias a cambio de mayor capacidad representacional. En alta dimensión, es posible colocar del orden de d^2 vectores con ángulos mutuos cercanos a 90 grados.

Esto plantea un dilema para la compresión SVD: ¿descarta redundancia o información funcional codificada en direcciones de baja energía que la norma de Frobenius no identifica como importante? Este trabajo investiga empíricamente la tensión. Los resultados (Capítulo 6) muestran que la SVD no discrimina selectivamente entre señales emocionales, pero las emociones con codificación neuronal más intensa son más vulnerables a perturbaciones generales de los pesos.

3.8. Posicionamiento de este trabajo

De la revisión anterior emergen tres brechas que este trabajo aborda.

En compresión. Los trabajos de compresión SVD en Transformers [12, 13] la analizan de forma agregada, sin distinguir entre componentes (Q, K, V, FFN) ni profundidades, y sin complementar los resultados con evidencia causal.

En interpretabilidad. El probing [14], el activation patching [9], la ablación [17] y el logit lens [58] se han aplicado mayoritariamente a tareas sintácticas o factuales (sujeto-verbo, recuperación de hechos, generación). Su aplicación coordinada al dominio emocional, triangulando cinco técnicas sobre el mismo modelo y dataset, está poco explorada.

En la intersección. No conocemos trabajos previos que usen interpretabilidad mecánica *multi-técnica* para guiar la compresión SVD selectiva (por componente, capa y emoción). Trabajos

como Hsu et al. [13] ponderan la SVD con un único criterio funcional (información de Fisher), pero no triangulan varias técnicas de interpretabilidad mecánica ni desagregan por componente. La conexión cuantitativa entre cristalización y vulnerabilidad a la SVD es, en este marco, una contribución original.

La Tabla 3.2 resume el posicionamiento.

Tabla 3.2: Posicionamiento respecto al estado del arte. Fuente: elaboración propia a partir de las referencias citadas.

	Compr.	Interp.	Desagregado	Causal
Noach & Goldberg (2020)	SVD	—	No	No
Hsu et al. (2022)	SVD pond.	—	Parcial	No
Tenney et al. (2019)	—	Probing	Sí (capa)	No
Meng et al. (2022)	—	Patching	Sí (FFN)	Sí
Voita et al. (2019)	—	Ablación	Sí (cabezas)	Parcial
Clark et al. (2019)	—	Atención	Sí (cabezas)	No
Dai et al. (2022)	—	Neuronas	Sí (FFN)	Sí
<i>Este trabajo</i>	<i>SVD select.</i>	<i>5 técnicas</i>	<i>Sí (comp.+capa+em.)</i>	<i>Parcial*</i>

*Las conclusiones del activation patching de este trabajo son de naturaleza *funcional* (suficiencia de un componente para recuperar al modelo del colapso por SVD), no causales en el sentido estricto de Pearl: la corrupción empleada es SVD estructurada, no ruido gaussiano sobre activaciones. La distinción se detalla en §3.7.2 y en §6.3.

Capítulo 4

Metodología

Este capítulo describe el diseño experimental del proyecto: el dataset y su preprocesamiento (§4.1), el modelo base y su fine-tuning (§4.2), el componente de compresión SVD (§4.3), las cinco técnicas de interpretabilidad mecánica empleadas (§4.4) y las métricas de evaluación (§4.5). La Figura 4.1 muestra el flujo experimental completo.




Figura 4.1: Pipeline experimental. El modelo baseline se somete a compresión SVD y a cinco técnicas de interpretabilidad mecánica con granularidad creciente (de capa completa a neurona individual). Los hallazgos retroalimentan el diseño de estrategias de compresión informadas (línea discontinua). El ciclo se cierra con fine-tuning del modelo comprimido. Fuente: elaboración propia.

4.1. Dataset: GoEmotions

El dataset GoEmotions [11] contiene 58.009 comentarios de Reddit anotados por tres evaluadores con una taxonomía de 28 categorías emocionales (27 emociones + *neutral*). A diferencia de la clasificación de sentimientos estándar (positivo/negativo), GoEmotions es un dataset de clasificación multi-etiqueta: cada texto puede expresar múltiples emociones simultáneamente (por ejemplo, admiración y alegría), lo que impone al modelo la necesidad de resolver co-ocurrencias con matices semánticos cercanos.

4.1.1. Filtrado de emociones

Del conjunto original de 28 categorías, se eliminaron cinco que presentaban problemas de rendimiento o representatividad:

- *neutral*: excluida por no ser una emoción propiamente dicha y por prevalecer en exceso en el dataset (más de 14.000 ejemplos), lo que distorsionaba las métricas macro-promediadas.
- *grief*, *nervousness*, *pride*, *relief*: excluidas por producir $F1 = 0$ en el baseline, dada su escasa frecuencia (menos de 100 ejemplos en entrenamiento). La presencia de emociones con F1 nulo degradaba el F1 macro sin permitir evaluar la capacidad discriminativa del modelo para las emociones representadas.

El filtrado se realizó en el pipeline de datos: se eliminaron las cinco columnas correspondientes del vector de etiquetas (pasando de 28 a 23 dimensiones) y se descartaron los ejemplos cuyo vector resultante quedaba vacío (aquellos anotados exclusivamente con alguna de las emociones excluidas). El resultado es un dataset de 23 emociones donde todas las categorías producen un F1 funcional (mínimo: 0,267 para *embarrassment*). El baseline resultante (F1 macro = 0,577 sobre 23 emociones) no es directamente comparable con los valores reportados en la literatura para GoEmotions con 27 o 28 categorías.

La Tabla 4.1 lista las 23 emociones del dataset final, ordenadas por F1 en el baseline.

Tabla 4.1: Las 23 emociones del dataset final, con F1 en el baseline.

Emoción	F1 baseline	Ejs. train	Grupo semántico
gratitude	0,927	2 662	Positiva social
amusement	0,853	2 328	Positiva energética
love	0,816	2 086	Positiva social
admiration	0,757	4 130	Positiva social
fear	0,710	596	Negativa interna
curiosity	0,707	2 191	Epistémica
remorse	0,672	545	Negativa interna
joy	0,635	1 452	Positiva energética
sadness	0,632	1 326	Negativa interna
optimism	0,573	1 581	Positiva orientada
surprise	0,571	1 060	Epistémica
approval	0,555	2 939	Positiva social
anger	0,550	1 567	Negativa reactiva
caring	0,542	1 087	Positiva orientada
desire	0,535	641	Positiva orientada
disapproval	0,527	2 022	Negativa reactiva
disgust	0,521	793	Negativa reactiva
confusion	0,515	1 368	Epistémica
excitement	0,454	853	Positiva energética
annoyance	0,411	2 470	Negativa reactiva
disappointment	0,275	1 269	Negativa interna
realization	0,271	1 110	Epistémica
embarrassment	0,267	303	Negativa interna
F1 macro promedio			0,577

Grupos semánticos con fines expositivos (agrupación orientativa manual); los clusters emergentes de la estructura neuronal del modelo se presentan en la Tabla 6.12 del Capítulo 6. Fuente: elaboración propia sobre GoEmotions [11].

4.1.2. Splits y preprocesamiento

Se partió de los splits oficiales de GoEmotions (entrenamiento 43.410 ejemplos, validación 5.426, test 5.427); tras descartar los ejemplos cuyo vector de etiquetas quedaba vacío al eliminar *neutral* y las demás emociones excluidas, las particiones resultaron en aproximadamente 40.400, 5.050 y 5.050 ejemplos (entrenamiento, validación y test), representando alrededor del 93 % del total original. El preprocesamiento se limita a la tokenización con el tokenizer de BERT-base-uncased, con una longitud máxima de 128 tokens y padding dinámico. No se aplican técnicas de aumento de datos.

4.2. Modelo: BERT-base

4.2.1. Arquitectura

BERT-base-uncased [2] consta de 12 capas de encoder Transformer, cada una con un bloque de atención multi-cabeza (12 cabezas) y un bloque feed-forward. El modelo tiene 110 millones de parámetros, de los cuales 84,9 millones corresponden a las 72 capas lineales del encoder (6 matrices por capa $\times$ 12 capas), que constituyen el objetivo de la compresión SVD. La Tabla 4.2 detalla las dimensiones de cada tipo de componente.

Tabla 4.2: Capas lineales del encoder de BERT-base (por capa).

Bloque	Componente	Dimensiones	Parámetros
Atención	Query (W_Q)	768×768	589.824
Atención	Key (W_K)	768×768	589.824
Atención	Value (W_V)	768×768	589.824
Atención	Output (W_O)	768×768	589.824
FFN	Intermediate (W_{int})	768×3072	2.359.296
FFN	Output (W_{out})	3072×768	2.359.296
Total por capa del encoder			7.077.888
Total 12 capas			84.934.656

Fuente: elaboración propia.

4.2.2. Fine-tuning

El modelo se fine-tuneó sobre el dataset GoEmotions (23 emociones) añadiendo una capa de clasificación lineal sobre el token [CLS] de la última capa del encoder. La clasificación multi-etiqueta se implementa con una función de pérdida BCEWithLogitsLoss (binary cross-entropy con logits), que trata cada emoción como una predicción binaria independiente.

Los hiperparámetros de fine-tuning se resumen en la Tabla 4.3.

Tabla 4.3: Hiperparámetros de fine-tuning.

Parámetro	Valor
Optimizador	AdamW
Learning rate	2×10^{-5}
Epochs	4
Batch size	32
Warmup	10 % de los steps
Weight decay	0,01
Max sequence length	128 tokens
Semilla aleatoria	42

Fuente: elaboración propia.

El modelo resultante alcanza un F1 macro de 0,577 y un F1 micro de 0,627 sobre el conjunto de

test, lo que constituye el baseline contra el que se mide toda degradación posterior.

4.3. Compresión SVD

4.3.1. Fundamento teórico

Los fundamentos de la SVD y la garantía de optimalidad del teorema de Eckart-Young se presentaron en la Sección 3.4.2; aquí solo se recogen los elementos estrictamente necesarios para la metodología. Partiendo de la factorización $W = U\Sigma V^T$ de una matriz de pesos y de su truncación al rango k , la SVD induce una descomposición ortogonal del espacio de salida $\mathbb{R}^m$:

$$\mathbb{R}^m = \mathcal{S}_k \oplus \mathcal{S}_k^\perp, \quad \mathcal{S}_k = \text{span}\{u_1, \dots, u_k\} \quad (4.1)$$

donde $\mathcal{S}_k$ es el subespacio conservado (asociado a los k mayores valores singulares) y $\mathcal{S}_k^\perp$ el subespacio eliminado. El operador de proyección sobre $\mathcal{S}_k^\perp$ es $P_k^\perp = I - U_k U_k^T$, y la fracción de señal $x \in \mathbb{R}^m$ eliminada por la compresión a rango k es $\|P_k^\perp x\|_2 / \|x\|_2$. Esta cantidad se utiliza en §6.5 para evaluar si la SVD discrimina selectivamente entre direcciones funcionalmente significativas (vectores de selectividad neuronal) o si elimina señal uniformemente.

En la práctica, una capa lineal W de dimensión $m \times n$ se reemplaza por dos capas: V_k^T ($k \times n$) y $U_k \Sigma_k$ ($m \times k$), reduciendo los parámetros de mn a $k(m + n)$.

4.3.2. Rango de break-even

La compresión SVD solo reduce parámetros si el rango elegido es menor que $mn/(m + n)$. Para BERT-base:

- Componentes de atención (768×768): *break-even* en rango 384.
- Componentes FFN (768×3072): *break-even* en rango 614.

Rangos superiores a estos umbrales aumentan el número total de parámetros. Este detalle técnico es relevante para interpretar correctamente las estrategias adaptativas de alta energía (Capítulo 5).

4.3.3. Implementación

Cada capa lineal seleccionada se sustituye por su factorización de rango k , de modo que el paso hacia delante se realiza como dos multiplicaciones sucesivas en lugar de una. El procedimiento admite una especificación de rango independiente para cada capa y cada componente. La descomposición se calcula siempre en precisión de 32 bits para evitar inestabilidades numéricas, con independencia de la precisión en la que opere el modelo.

4.3.4. Métricas espectrales

Se definen dos métricas que se usan a lo largo del Capítulo 5 para caracterizar la geometría de matrices y activaciones:

Rango mínimo k_τ . Para una matriz W con valores singulares $\sigma_1 \geq \sigma_2 \geq \dots, k_\tau$ es el menor k tal que $E(k) \geq \tau$, con $E(k)$ la energía acumulada definida en la Ecuación 3.8 de §3.4.3. En este trabajo se utiliza principalmente k_{95} (energía acumulada del 95 %) como medida de concentración espectral.

Rango efectivo de activaciones. Para una matriz de activaciones A con valores singulares $\{\sigma_i\}$, se define la entropía espectral $H(A) = -\sum_i p_i \log p_i$ con $p_i = \sigma_i^2 / \sum_j \sigma_j^2$, y el rango efectivo como $r_{\text{eff}}(A) = \exp(H(A))$. Cuantifica el número efectivo de direcciones significativas en A .

4.3.5. Estrategias de compresión evaluadas

Se evaluaron cuatro familias de estrategias:

1. **Uniforme:** mismo rango $k \in \{32, 64, 128, 256, 384, 512\}$ para las 72 matrices del encoder.
2. **Adaptativa (energía):** rango por matriz determinado por un umbral de energía espectral ($E(k) \geq \{80\%, 85\%, 90\%, 95\%, 99\%\}$), donde $E(k)$ es la energía acumulada definida en la Ecuación 3.8. Los cinco umbrales se reportan en el Capítulo 5; la comparación de estrategias en la frontera de Pareto (§7.3) emplea las cuatro representativas $\{80\%, 90\%, 95\%, 99\%\}$.
3. **Informada heurística:** rangos asignados manualmente a partir de reglas derivadas de los resultados de interpretabilidad (proteger capas tardías, comprimir agresivamente Q/K). Tres niveles de agresividad (*light, moderate, aggressive*).
4. **Greedy (data-driven):** construye un conjunto finito de movimientos de compresión (“comprimir componente X en capas Y al rango Z ”), los ordena por eficiencia (parámetros ahorrados / F1 perdido) y los aplica del más al menos eficiente hasta alcanzar el ratio objetivo. Los costes en F1 provienen del análisis de sensibilidad empírico por componente y profundidad. El pseudocódigo completo está en el Algoritmo 1; los resultados de aplicarlo se presentan en el Capítulo 7.

Algorithm 1 Compresión SVD greedy informada por sensibilidad

Require: Modelo M , ratio objetivo de parámetros r_{tgt} , tabla de retención $S[c][k]$, fracciones de profundidad $f[d]$, cap de coste τ

Ensure: Asignación de rangos $\sigma : (c, d) \rightarrow \text{rank} \cup \{\text{full}\}$

```

1: moves  $\leftarrow \emptyset$ 
2: for cada componente  $c$  do
3:   for cada par consecutivo  $(k_{\text{prev}}, k)$  en  $S[c]$  do
4:     for cada banda de profundidad  $d \in \{\text{early}, \text{mid}, \text{late}\}$  do
5:        $\Delta F1 \leftarrow (S[c][k_{\text{prev}}] - S[c][k]) \cdot f[d]$ 
6:       saved  $\leftarrow |d| \cdot (k_{\text{prev}}(m+n) - k(m+n))$ 
7:        $\text{eff} \leftarrow \begin{cases} +\infty & \Delta F1 \leq 0 \\ \text{saved}/\Delta F1 & \text{en caso contrario} \end{cases}$ 
8:       moves.add( $\langle c, d, k_{\text{prev}} \rightarrow k, \Delta F1, \text{saved}, \text{eff} \rangle$ )
9:     end for
10:   end for
11: end for
12: ordenar moves por eff descendente
13:  $\sigma[c, d] \leftarrow \text{full}$  para todo  $(c, d)$ 
14: for  $m \in \text{moves}$  do
15:   if  $\sigma[m.c, m.d] \neq m.k_{\text{prev}}$  then continue
16:   end if
17:   if  $m.\Delta F1 > \tau$  then continue
18:   end if
19:    $\sigma[m.c, m.d] \leftarrow m.k$ 
20:   if  $\text{params\_ratio}(\sigma) \leq r_{\text{tgt}}$  then break
21:   end if
22: end for
23: return  $\sigma$ 

```

Los costes en F1 que alimentan el algoritmo se miden sobre la partición de validación, manteniendo el conjunto de test reservado exclusivamente para la comparación final entre estrategias.

4.4. Técnicas de interpretabilidad mecánica

Se emplearon cinco técnicas complementarias que cubren escalas progresivas de granularidad: capa completa (*probing* y *logit lens*), capa y componente (*activation patching*), cabeza individual (ablación) y neurona individual (análisis de selectividad).

4.4.1. Probing lineal

Para cada una de las 13 capas de BERT (embedding + 12 capas del encoder) y cada una de las 23 emociones se entrena un probe de regresión logística (LogisticRegression de scikit-learn,

$C = 1,0$ sin ajuste de hiperparámetros) sobre la representación del token [CLS]. Fijar $C = 1,0$ sigue a Hewitt y Liang [52]: el probe debe ser deliberadamente simple para medir la calidad de la representación y no la capacidad del clasificador. La contrapartida es que un probe lineal no detecta información codificada de forma no lineal en capas tempranas. Esta limitación se asume al interpretar los resultados (§6.1).

El total nominal de probes es $23 \times 13 = 299$; sin embargo, los probes sobre la capa de embedding producen $F1 = 0$ uniformemente para todas las emociones (el embedding crudo no contiene información emocional separable linealmente), por lo que se descartan del análisis efectivo. El número efectivo de probes que entran en las correlaciones y métricas es de $23 \times 12 = 276$, valor que utilizamos consistentemente en el resto de la memoria.

Se utiliza el vector del token [CLS] en lugar del promediado (mean-pooling) sobre la secuencia, siguiendo la convención de BERT: durante el fine-tuning, [CLS] es el único token cuya representación se conecta directamente al clasificador y, por tanto, concentra la información discriminativa para la tarea.

La métrica de probing es el F1 por probe. Se define la capa de cristalización de una emoción como la primera capa donde su F1 alcanza el 80 % del máximo observado en cualquier capa. Este umbral es una convención; el orden de cristalización es estable con umbrales de 0,7 y 0,9.

4.4.2. Logit lens

El logit lens [58] aplica la cabeza de clasificación entrenada del modelo (BertPooler + clasificador lineal) a la representación del token [CLS] de cada capa intermedia, sin re-entrenamiento. Para cada capa $\ell \in \{0, \dots, 11\}$ y cada ejemplo, se calcula:

$$\hat{p}_\ell = \sigma \left(W_{\text{cls}} \cdot \tanh \left(W_{\text{pool}} \cdot h_\ell^{[\text{CLS}]} \right) + b_{\text{cls}} \right) \in \mathbb{R}^{23} \quad (4.2)$$

donde $h_\ell^{[\text{CLS}]}$ es la representación del token [CLS] en la capa ℓ y σ es la sigmoide aplicada componente a componente. Las predicciones se agregan sobre 2 300 ejemplos del conjunto de test (submuestreo equilibrado entre los tres grupos de cristalización del probing). Las métricas reportadas son la sigmoid media de la emoción correcta (*gold sigmoid*), la sigmoid media de la emoción más probable (*top-1 sigmoid*) y la suma total de las 23 sigmoids.

El logit lens tiene una limitación: los pesos del pooler y del clasificador se optimizaron sobre la última capa tras LayerNorm, así que los valores absolutos en capas intermedias no son comparables al baseline. Se interpreta solo en términos relativos (entre capas o entre grupos emocionales). La limitación se discute con más detalle en §6.2.

4.4.3. Activation patching

El activation patching parte de un modelo colapsado: comprimido con SVD uniforme a rango 64 ($F1 = 0,000$ en las 23 emociones). Es el rango máximo que produce colapso uniforme: rangos inferiores (32) introducen distorsión adicional que podría contaminar el patching; rangos superiores (128) permiten recuperación espontánea en algunas emociones.

La corrupción por SVD truncada introduce una distorsión estructurada, no ruido neutral (a diferencia del *causal tracing* clásico de Meng et al. [9], que usa ruido gaussiano sobre los embeddings). El patching aquí responde, por tanto, a la pregunta “¿qué componente del modelo original basta para que el modelo se recupere del colapso por SVD?”, no a la pregunta más general de localización causal. La discusión completa está en §6.3.

Desde este estado se reemplazan selectivamente los pesos comprimidos por los originales de una capa o componente, y se mide la recuperación del F1 macro. La métrica de interés es el porcentaje de restauración:

$$\text{Restauración}(\%) = \frac{F1_{\text{patched}} - F1_{\text{comprimido}}}{F1_{\text{baseline}} - F1_{\text{comprimido}}} \times 100 \quad (4.3)$$

El patching se realiza a dos niveles de granularidad: (a) capa completa, restaurando las 6 matrices de una capa del encoder; y (b) componente, restaurando solo el bloque de atención o solo el bloque FFN de una capa.

4.4.4. Ablación de cabezas de atención

Se anulan individualmente las 144 cabezas de atención (12×12) poniendo su salida a cero (*zero-out*) y se mide la caída en F1 macro y en F1 por emoción. Se clasifica cada cabeza según dos métricas complementarias:

- Importancia: impacto agregado sobre las emociones individuales al ablacionar la cabeza; correlaciona con la caída en F1 macro global ($r = 0,71$, véase §6.4).
- Selectividad: concentración del impacto en pocas emociones, medida mediante el coeficiente de Gini sobre el vector de caídas por emoción.

Las cuatro categorías resultantes son: Especialista crítica (alta importancia, alta selectividad), Generalista crítica (alta importancia, baja selectividad), Especialista menor (baja importancia, alta selectividad) y Prescindible (baja importancia, baja selectividad).

4.4.5. Análisis de neuronas FFN

Para cada una de las 36.864 neuronas intermedias del modelo ($12 \times 3,072$) se extrae su activación tras la no linealidad GELU (la salida de la capa intermedia del bloque feed-forward), promediada sobre las posiciones de la secuencia. Se procesa el conjunto de test completo.

La selectividad neuronal para una neurona n y una emoción e se define como una puntuación análoga a la d de Cohen:

$$s(n, e) = \frac{\bar{a}_{n,\text{presente}} - \bar{a}_{n,\text{ausente}}}{\sigma_{\text{pooled}}} \quad (4.4)$$

donde $\bar{a}_{n,\text{presente}}$ es la activación media de la neurona n cuando la emoción e está presente en el texto, y $\bar{a}_{n,\text{ausente}}$ cuando está ausente. Se consideran significativas las neuronas con $|s| > 2,0$.

Para conectar la especialización neuronal con la compresión SVD, se investiga una hipótesis concreta: *¿las emociones cuyas neuronas especializadas caen mayoritariamente en el subespacio eliminado*

por la SVD son las más vulnerables a la compresión? Para responder a esta pregunta, se proyecta el vector de selectividad de cada emoción (un vector de 3.072 dimensiones por capa, con la selectividad de cada neurona) sobre los subespacios conservado y eliminado por la SVD a rango 128, y se calcula la fracción de señal emocional que reside en cada subespacio. Si la hipótesis es correcta, las emociones con mayor fracción de señal en el subespacio eliminado deberían mostrar mayor caída de F1 bajo compresión.

4.5. Métricas de evaluación

La evaluación combina métricas a tres escalas: rendimiento global (F1 macro y micro), impacto diferencial por emoción (F1 por emoción, retención de F1) y calidad representacional (*silhouette score*).

- F1 macro: media no ponderada del F1 por emoción; asigna peso igual a todas las clases y es sensible a la degradación de las minoritarias. Es la métrica principal del trabajo.
- F1 micro: F1 calculado sobre el total de predicciones; da mayor peso a las emociones frecuentes.
- F1 por emoción: muestra el impacto diferencial de la compresión sobre cada clase.
- Retención de F1: $F1_{\text{comprimido}}/F1_{\text{baseline}}$, en porcentaje.
- Ratio de parámetros: $\text{params}_{\text{comprimido}}/\text{params}_{\text{original}}$ (< 1 indica compresión real).
- Coeficiente de silueta (*silhouette score*): calidad de los clusters en proyecciones t-SNE de embeddings [CLS].

4.6. Semillas y reproducibilidad

Todos los componentes estocásticos del trabajo (fine-tuning de BERT, inicialización del clasificador, particionado de validación, bootstrap, proyecciones t-SNE, submuestreo del conjunto de test para ablación) se ejecutaron con semillas fijas para garantizar reproducibilidad. La semilla de referencia es 42 para los procesos de análisis estadístico (bootstrap, submuestreo) y para t-SNE; las semillas concretas usadas en cada experimento se documentan en el código asociado.

Para verificar la estabilidad de los resultados frente a la semilla, las configuraciones de referencia (baseline sin comprimir, uniform_r256, uniform_r384, greedy_90) se reevaluaron con semillas alternativas. Las variaciones observadas en F1 macro son de orden inferior a 0,01, lo que confirma que las diferencias reportadas entre estrategias de compresión son estructurales y no artefactos de una semilla particular.

Capítulo 5

Resultados de compresión SVD

Este capítulo analiza el comportamiento de BERT-base fine-tuned sobre GoEmotions bajo distintas estrategias de compresión SVD. El objetivo es doble: primero, determinar cuánta información se puede eliminar sin destruir la capacidad emocional del modelo, y segundo, identificar dónde reside esa información dentro de la arquitectura.

El modelo de referencia (baseline) a lo largo de todo el capítulo es BERT-base fine-tuned sin ninguna compresión, con un F1 macro de 0,577 sobre el conjunto de test. Todas las cifras de retención se calculan sobre este baseline. La configuración estocástica (semillas, replicaciones) se describe en §4.6; las cifras de F1 por configuración son estables a variaciones de semilla (desviaciones < 0,01).

5.1. Análisis espectral de las matrices de peso

5.1.1. Asimetría self-attention vs. feed-forward

El mapa de rangos mínimos k_{95} (definido en §4.3.4: el menor rango que retiene el 95 % de la energía espectral) para cada una de las 72 matrices del encoder, organizadas por capa y tipo de componente, revela una asimetría pronunciada entre los componentes de self-attention y los de feed-forward.

La Tabla 5.1 cuantifica esta diferencia. Las matrices Query y Key requieren un rango medio de aproximadamente 395 para retener el 95 % de la energía espectral, mientras que las matrices FFN Intermediate y Output necesitan rangos superiores a 618. La diferencia media entre Q y FFN Intermediate es de unos 222 rangos, lo que equivale al 29 % del rango completo (768).

Tabla 5.1: Rango medio k_{95} por tipo de componente (media sobre las 12 capas). Fuente: elaboración propia.

Componente	$\mu(k_{95})$	Compresibilidad
Query (Q)	~396	Alta
Key (K)	~394	Alta
Value (V)	~424	Alta
Attn Output	~434	Media-alta
FFN Intermediate	~618	Baja
FFN Output	~625	Baja

Nótese que, pese a sus mayores dimensiones, las matrices FFN tienen el mismo rango máximo que las de atención ($\min(768, 3072) = 768$), por lo que los valores de k_{95} son comparables en escala absoluta; la diferencia observada refleja la estructura del espectro, no el tamaño de la matriz.

Esta asimetría se mantiene en las 12 capas: no es un artefacto de una o dos capas anómalas sino una propiedad estructural del modelo fine-tuned. Las matrices Q y K concentran los patrones de atención en un subespacio de dimensionalidad efectiva muy inferior a 768; las matrices FFN, en cambio, reparten su información de forma más uniforme a lo largo del espectro. La razón es funcional: las FFN almacenan y recombinan asociaciones léxicas y semánticas en un espacio de 3072 dimensiones, lo que requiere usar la mayor parte del rango disponible. Las matrices de atención solo necesitan dar forma a patrones de afinidad entre tokens, una operación que tolera una representación de rango mucho menor.

5.1.2. Perfil de decaimiento espectral

La Figura 5.1 refuerza esta observación desde una perspectiva complementaria. Muestra las curvas de decaimiento de los valores singulares de cada matriz de pesos (media $\pm$ desviación estándar sobre las 12 capas) para cada tipo de componente.




Figura 5.1: Decaimiento espectral por tipo de componente: eje horizontal, índice del valor singular ($i = 1, \dots, 768$); eje vertical, magnitud σ_i normalizada, promediada sobre las 12 capas $\pm$ desviación estándar (banda sombreada). Q y K decaen rápido; FFN Intermediate y Output mantienen valores singulares elevados a lo largo de todo el espectro. Fuente: elaboración propia.

Las matrices Q y K exhiben un decaimiento pronunciado: los primeros componentes principales capturan la mayor parte de la varianza y los restantes contribuyen marginalmente. Las matrices FFN, en cambio, presentan un espectro esencialmente plano, donde cada valor singular adicional aporta una fracción similar de información. Esta diferencia cualitativa en la forma del espectro

explica por qué un mismo rango de truncamiento tiene efectos radicalmente distintos sobre ambos tipos de componente.

5.1.3. Solapamiento de subespacios Q-K-V

Como observación complementaria, analizamos el solapamiento entre los subespacios dominantes de las matrices de pesos Q, K y V dentro de cada capa, medido como la similitud de coseno media entre sus vectores singulares principales (es decir, los vectores singulares de cada matriz de pesos, no de las activaciones).

Tabla 5.2: Rango de solapamiento entre subespacios (top-32 y top-64 vectores singulares). Fuente: elaboración propia.

Par	Top-32	Top-64
Q-K	0,34 – 0,63	0,31 – 0,47
Q-V	0,03 – 0,18	0,06 – 0,25
K-V	0,05 – 0,21	0,08 – 0,27

Q y K comparten un subespacio significativo (solapamiento de hasta 0,63 para los 32 vectores singulares principales), lo cual es esperable dado que su producto $Q \cdot K^T$ genera los pesos de atención. V, en cambio, opera en un subespacio sustancialmente ortogonal a los de Q y K. Este resultado es consistente con la diferencia funcional de ambos bloques: Q y K definen a qué atender, mientras que V define qué información extraer.

El solapamiento alto entre Q y K (hasta 0,63) significa que ambas proyecciones codifican en buena medida la misma información: comprimir una no destruye señal que la otra no tenga ya. Esta redundancia es la razón estructural de que Q y K sean lo primero y más barato de comprimir, como confirman la sensibilidad por componente (§5.3) y la secuencia del algoritmo greedy (§7.3), que las recorta antes que nada con un coste en F1 inferior al 0,5%. No explotamos el solapamiento para una compresión conjunta de Q y K en un subespacio compartido, que queda como extensión natural; aquí lo usamos solo como diagnóstico de por dónde empezar a recortar.

5.1.4. Predicciones a partir del análisis espectral

Los resultados espectrales generan tres predicciones contrastables en las siguientes secciones:

1. Q y K toleran reducción de rango agresiva (hasta $r \approx 128$) con degradación mínima, dado que su dimensionalidad efectiva es muy inferior a 768.
2. Las FFN son el cuello de botella de cualquier estrategia de compresión, al requerir rangos sustancialmente mayores para retener una fracción equivalente de energía.
3. La compresión uniforme será subóptima por ignorar esta heterogeneidad espectral.

Las secciones §5.2 y §5.3 confirman las dos primeras predicciones; §5.4 valida la tercera.

5.2. Compresión uniforme y transición de fase

La estrategia más simple de compresión SVD consiste en aplicar el mismo rango de truncamiento r a todas las matrices lineales del modelo simultáneamente. Esta sección evalúa seis niveles de rango uniforme ($r \in \{512, 384, 256, 128, 64, 32\}$) y documenta una transición de fase abrupta en el rendimiento.

5.2.1. Degradación global

La Tabla 5.3 muestra el F1 macro, el ratio de parámetros y la retención de rendimiento para cada nivel de rango.

Tabla 5.3: Resultados de compresión uniforme sobre el conjunto de test. El ratio de parámetros se define como $\text{params}_{\text{comprimido}}/\text{params}_{\text{original}}$: valores < 1 indican compresión real; valores > 1 , expansión paramétrica. La retención es el cociente $F1_{\text{comprimido}}/F1_{\text{baseline}}$, expresado en porcentaje. Fuente: elaboración propia.

Estrategia	F1 macro	Ratio params.	Retención
Baseline	0,577	1,00	100,0 %
Uniform $r=512$	0,464	1,00	80,5 %
Uniform $r=384$	0,251	0,81	43,5 %
Uniform $r=256$	0,025	0,61	4,3 %
Uniform $r=128$	0,000	0,42	0,0 %
Uniform $r=64$	0,000	0,32	0,0 %
Uniform $r=32$	0,000	0,21	0,0 %

El patrón dominante es una caída abrupta entre $r = 384$ y $r = 256$: el modelo pasa de retener el 43 % del rendimiento a retener apenas el 4 %, una caída de casi 40 puntos porcentuales en un solo salto de rango. El término “transición de fase” se usa aquí de forma descriptiva; con la resolución de muestreo disponible (no se evalúan rangos intermedios entre 256 y 384) no puede afirmarse que la transición sea discontinua en sentido estricto. A partir de $r = 128$, bajo compresión uniforme, el modelo entra en colapso total con $F1 = 0,0$: no es capaz de clasificar correctamente ni una sola emoción. Este colapso es específico de la compresión uniforme; el análisis por componente (§5.3) mostrará que muchos componentes individuales toleran $r = 128$ sin degradación.

La zona útil de compresión uniforme se limita a $r = 512$ (degradación significativa pero funcional) y $r = 384$ (degradación severa pero no total). Cualquier rango inferior destruye la capacidad del modelo de forma irrecuperable.

5.2.2. Vulnerabilidad emocional diferencial

La degradación no afecta a todas las emociones por igual. La Figura 5.2 muestra el F1 por emoción para cada nivel de compresión uniforme, revelando un espectro amplio de resistencia.




Figura 5.2: F1 por emoción para cada nivel de compresión uniforme. Las emociones están ordenadas por su F1 en el baseline. Las emociones frecuentes y léxicamente simples (arriba) sobreviven más que las infrecuentes y semánticamente complejas (abajo). Fuente: elaboración propia.

Las emociones más resistentes comparten características comunes: son frecuentes en el corpus y están asociadas a marcadores léxicos fuertes. *Gratitude*, por ejemplo, retiene un F1 de 0,92 a $r = 384$ y aún mantiene 0,55 a $r = 256$, apoyada por la presencia recurrente de expresiones como “thank you” y “thanks”. *Amusement* (0,74 a $r = 384$) y *love* (0,77 a $r = 384$) siguen un patrón similar.

En el extremo opuesto, *embarrassment* colapsa ya a $r = 512$ (de 0,27 a 0,00), *realization* cae de 0,27 a 0,16 en el mismo nivel, y *disappointment* pasa de 0,28 a 0,06. Estas emociones son infrecuentes en el corpus de entrenamiento, semánticamente ambiguas y carecen de marcadores léxicos distintivos. Su representación depende de dimensiones espectrales de cola, precisamente las primeras en ser eliminadas por la compresión SVD.

Este patrón sugiere una conexión con los resultados de cristalización del Capítulo 6: las emociones que cristalizan temprano en la profundidad del modelo tienden a ser las más resistentes a la compresión, mientras que las que requieren procesamiento profundo son las más vulnerables. La conexión cuantitativa se formaliza en el Capítulo 7.

5.3. Sensibilidad por componente y profundidad

El análisis espectral predijo sensibilidades radicalmente distintas por componente. Esta sección lo verifica con un estudio sistemático de 33 configuraciones que aísla el efecto del tipo de componente (8 tipos $\times$ 3 rangos) y de la profundidad (3 grupos $\times$ 3 rangos).

5.3.1. Sensibilidad por tipo de componente

Para aislar el efecto de cada tipo de componente, comprimimos selectivamente solo las 12 matrices de un tipo dado (por ejemplo, las 12 matrices Query, una por capa) a un rango fijo, manteniendo el resto del modelo intacto. La Tabla 5.4 presenta los resultados al rango $r = 128$, que maximiza el contraste entre componentes.

Tabla 5.4: Sensibilidad por componente a $r = 128$. La sensibilidad normalizada se calcula como $S = (F1_{\text{baseline}} - F1_{\text{comprimido}}) \times 100 / \Delta \% \text{params}$, donde $\Delta \% \text{params}$ es el porcentaje de parámetros eliminados al comprimir solo ese componente (en pp del total del encoder). Fuente: elaboración propia.

Componente	F1 macro	Retención	Sensibilidad
Query (Q)	0,574	99,4 %	0,14
Key (K)	0,568	98,4 %	0,38
Value (V)	0,395	68,5 %	7,31
Attn Output	0,325	56,3 %	10,13
FFN Output	0,128	22,2 %	3,80
FFN Intermediate	0,040	6,9 %	4,55
Attention (todas)	0,027	4,6 %	—
FFN (todas)	0,001	0,1 %	—

El resultado confirma y amplifica la predicción espectral. A rango 128, Query retiene el 99,4 % del rendimiento mientras que FFN Intermediate retiene apenas el 6,9 %: un factor de 14 $\times$ en retención absoluta. Esta caída refleja en parte que comprimir FFN Intermediate elimina cerca de 4,7 veces más parámetros que comprimir Q al mismo rango, lo que amplifica la caída absoluta de F1. Normalizado por la fracción de parámetros eliminados, la diferencia en sensibilidad es de 72 $\times$ (0,14 frente a 10,13 para Attn Output, el componente de atención más sensible), lo que revela que Attn Output es estructuralmente más frágil por parámetro que las propias FFN ($S = 4,55$).

Este resultado valida la primera predicción del análisis espectral: Q y K son efectivamente “inmunes” a la compresión agresiva, porque su información reside en un subespacio de dimensionalidad mucho menor que el rango completo de la matriz.

El presupuesto de compresión debe gastarse donde es barato. Recortar Q y K sale casi gratis; comprimir la FFN Intermediate es ruinoso. La métrica normalizada por parámetros (72 $\times$) señala

qué componentes dan más ahorro por punto de F1 sacrificado. Asignar el mismo rango a todas las matrices, como hace la SVD uniforme, ignora esa jerarquía y deja sin aprovechar la mayor parte de la compresión segura.

5.3.2. Tres regímenes de compresibilidad

Al examinar la evolución de la retención a lo largo de los tres rangos evaluados ($r \in \{256, 128, 64\}$), los seis tipos de componente se agrupan en tres regímenes cualitativamente distintos:

Régimen 1. Inmunes (Q, K): Degradación gradual y casi lineal. Query pierde apenas 1,8 puntos porcentuales entre $r = 256$ y $r = 64$. Estas matrices operan en un subespacio de dimensionalidad efectiva muy inferior a 768.

Régimen 2. Efecto cliff (caída abrupta; V, Attn Output): Sobreviven a $r = 256$ (retención $\sim 93\%$) pero colapsan a $r = 64$ ($\sim 3\text{--}5\%$). Existe un umbral crítico entre $r = 128$ y $r = 64$ por debajo del cual la información no se puede recuperar. Value, por ejemplo, cae 63 puntos porcentuales solo entre $r = 128$ y $r = 64$.

Régimen 3. Frágiles (FFN Inter, FFN Output): Ya gravemente dañados a $r = 256$ (52 % y 75 % de retención respectivamente). El cliff principal se sitúa entre $r = 256$ y $r = 128$. Son matrices de alta dimensionalidad efectiva cuya información está distribuida a lo largo de todo el espectro de valores singulares.




Figura 5.3: Retención de F1 al comprimir solo un tipo de componente a rango $r = 128$ (manteniendo el resto del modelo intacto). Q y K (azules) son casi inmunes (retención $> 98\%$); V y Attn Output (naranjas) sufren una pérdida moderada; las FFN (verdes) presentan pérdidas severas. Las dos últimas filas (Attention all, FFN all) muestran el efecto de comprimir todos los componentes de un bloque a la vez. Fuente: elaboración propia.

Estos tres regímenes corresponden directamente a las tres formas de espectro observadas en la §5.1: decaimiento rápido (Q, K), decaimiento intermedio (V, Attn Output) y espectro plano (FFN). La estructura espectral predice con precisión el comportamiento bajo compresión.

Cada régimen sugiere una pauta distinta. Los componentes inmunes (Q, K) se pueden comprimir libremente hasta $r = 64$ sin apenas coste. Los de cliff (V, Attn Output) son seguros por encima de su umbral crítico ($r = 128$) y catastróficos por debajo, así que admiten compresión moderada

pero no cruzar ese límite. Los frágiles (FFN Intermediate y, en menor medida, FFN Output) conviene dejarlos casi intactos: su información está repartida por todo el espectro y cualquier truncamiento agresivo destruye capacidad funcional. La forma del espectro de cada matriz sirve, por tanto, de diagnóstico previo barato para decidir cuánto rango asignarle.

5.3.3. Sensibilidad por profundidad

Para evaluar el efecto de la profundidad, comprimimos simultáneamente todas las matrices de un grupo de capas (Early: 0–3, Middle: 4–7, Late: 8–11) manteniendo el resto del modelo intacto.

Tabla 5.5: Retención de F1 por grupo de profundidad y rango de compresión. Fuente: elaboración propia.

Grupo	$r = 256$	$r = 128$	$r = 64$
Early (0–3)	85,4 %	62,5 %	37,0 %
Middle (4–7)	82,5 %	46,5 %	25,3 %
Late (8–11)	33,3 %	0,0 %	0,0 %

Las capas tardías (8–11) son catastróficamente sensibles: a $r = 128$, el modelo muere por completo ($F1 = 0,0$). En contraste, las capas tempranas retienen más del 60 % del rendimiento al mismo rango. La Figura 5.4 sintetiza este gradiente.




Figura 5.4: Sensibilidad por grupo de profundidad. Cada barra representa la retención de F1 macro al comprimir todas las matrices de un grupo de capas a un rango dado, manteniendo el resto intacto. Las capas tardías (rojo) son las únicas que colapsan por completo a $r = 128$; las tempranas (verde) y medias (azul) retienen capacidad funcional. Fuente: elaboración propia.

La literatura de interpretabilidad mecánica identifica las capas finales de los Transformers como las responsables de la representación semántica de alto nivel. En clasificación emocional, las capas 8–11 son las que codifican las distinciones finas entre emociones; comprimirlas equivale a destruir la capacidad clasificadora. Esta sensibilidad responde a dos factores concurrentes: la proximidad directa al clasificador (cualquier daño a estas capas se propaga sin mediación al input del clasificador) y la concentración de representaciones específicas de la tarea que el fine-tuning induce en las capas tardías, confirmada por los resultados de *probing* del Capítulo 6. Combinado con el análisis por componente, este resultado revela que la compresión uniforme falla por dos ejes ortogonales: trata igual a Q y a FFN, y trata igual a las capas 0 y a las capas 11.

Una estrategia informada debe respetar ambos.

Nota metodológica. Como métrica complementaria al F1 evaluamos los *silhouette scores* (coeficientes de silueta) sobre proyecciones t-SNE de los embeddings comprimidos. El t-SNE es solo una ilustración visual: las distancias en la proyección no son métricas y no pueden usarse para cuantificar separabilidad; las afirmaciones sobre separabilidad se apoyan en el F1 de probing (§6.1). Observamos además un artefacto sistemático: cuando el modelo colapsa ($F1 = 0$), todos los embeddings convergen a un cluster trivial y el *silhouette* se vuelve anómalamente alto (0,15 para capas tardías a $r = 128$). Recomendamos, por tanto, no interpretar las métricas de clustering geométrico cuando el F1 sea bajo.

5.4. Compresión adaptativa y recetas mixtas

La compresión uniforme es inherentemente subóptima: aplica el mismo rango a componentes cuyas sensibilidades difieren hasta $72\times$ (normalizado por parámetros) y a capas cuya retención va del 0 % al 62 % al mismo rango. La compresión adaptativa (descrita en §4.3) asigna a cada matriz su rango mínimo k_τ según un umbral de energía τ .

5.4.1. Resultados de compresión adaptativa

La Tabla 5.6 presenta los resultados para cinco umbrales de energía y dos recetas mixtas: estrategias que combinan compresión adaptativa con reglas específicas por tipo de componente (*Conservative* comprime Q y K agresivamente mientras protege las FFN; *Aggressive* extiende esa lógica también a V y Attn Output).

Tabla 5.6: Resultados de compresión adaptativa y recetas mixtas. $\text{Ratio params.} = \text{params}_{\text{comprimido}} / \text{params}_{\text{original}}$, donde < 1 es compresión real y > 1 expansión paramétrica (ver §5.4.3). Fuente: elaboración propia.

Estrategia	F1 macro	Ratio params.	Retención
Baseline	0,577	1,00	100,0 %
Adaptive 99 %	0,558	1,20	96,7 %
Mixed Conservative	0,505	1,04	87,5 %
Adaptive 95 %	0,491	1,02	85,1 %
Mixed Aggressive	0,382	0,91	66,3 %
Adaptive 90 %	0,357	0,89	61,8 %
Adaptive 85 %	0,260	0,80	45,1 %
Adaptive 80 %	0,143	0,72	24,7 %

La compresión adaptativa al 99 % de energía retiene el 96,7 % del rendimiento, con una degradación de apenas 1,9 puntos porcentuales de F1 respecto al baseline. Al 95 %, la retención es del 85,1 %, un punto de equilibrio razonable. La receta *Mixed Conservative* (87,5 % de retención) se sitúa entre *Adaptive 95 %* y *99 %*.

5.4.2. Distribución de rangos asignados

La Figura 5.5 ilustra cómo la compresión adaptativa distribuye los rangos entre los distintos tipos de componente para cada umbral de energía.




Figura 5.5: Distribución de rangos asignados por la compresión adaptativa para cada umbral de energía, desglosada por tipo de componente. Q y K reciben rangos consistentemente menores que FFN. Fuente: elaboración propia.

La distribución confirma la lógica espectral: a un umbral del 95 %, Q y K reciben rangos del orden de 390–400, mientras que FFN Intermediate y Output reciben rangos de 610–625. La adaptativa simplemente respeta la estructura natural de las matrices en lugar de forzar un rango uniforme.

5.4.3. Caveat: ratio de compresión y simplificación de rango

Las estrategias *Adaptive 95 %* y *99 %* asignan rangos que superan el *break-even* (punto de equilibrio paramétrico) de las matrices (384 para atención, 614 para FFN; ver §4.3), por lo que la representación factorizada contiene más parámetros que la original. Los ratios de 1,02 y 1,20 de la Tabla 5.6 lo confirman. En rigor, estas estrategias constituyen simplificación de rango, no compresión de parámetros. La compresión real comienza en *Adaptive 90 %* (ratio 0,89); los niveles con compresión significativa (85 % y 80 %) implican degradaciones del 55 % y 75 % respectivamente.

5.5. Síntesis del capítulo

Los resultados de este capítulo dejan dos cosas claras. Las dos estrategias ciegas exploradas fracasan por motivos opuestos: la SVD uniforme no ofrece ningún punto de operación útil (entre $r = 384$ y $r = 256$ el modelo cae del 43,5 % al 4,3 % de retención, sin una región intermedia aprovechable), y la adaptativa por energía apenas comprime (a umbrales del 95–99 % los ratios quedan en 1,02–1,20: simplificación de rango, no reducción de parámetros). Y lo más relevante aparece entre ambos extremos, en la asimetría entre componentes: a igual rango, comprimir unos cuesta hasta 72× más que otros (normalizado por parámetros), y las capas tardías colapsan

donde las tempranas resisten. Esta asimetría, que ninguna regla espectral anticipa, es la que motiva el resto del trabajo: entender por qué unos componentes importan más que otros, y medir cuánto, exige abrir el modelo. Es el objeto del Capítulo 6.

Capítulo 6

Resultados de interpretabilidad mecánica

El capítulo anterior documentó qué ocurre cuando se comprime BERT. Este capítulo aborda la pregunta complementaria: por qué ocurre. Se aplican las cinco técnicas de interpretabilidad mecánica descritas en el Capítulo 4: *probing* lineal (§6.1), *logit lens* (§6.2), *activation patching* (§6.3), ablación de cabezas de atención (§6.4) y análisis neuronal de las FFN (§6.5).

6.1. Probing: cristalización emocional por capas

Siguiendo el diseño de §4.4.1, se entrenaron 276 probes de regresión logística sobre el token [CLS] de cada capa del encoder.

6.1.1. Tres regímenes de cristalización

Las 23 emociones se distribuyen en tres grupos claramente diferenciados según su profundidad de cristalización (Tabla 6.1, Figura 6.1).

Tabla 6.1: Grupos de cristalización emocional. La capa indica la primera capa donde el F1 del probe alcanza el 80 % de su máximo. La columna “F1 en cap.” muestra el F1 del probe en la capa de cristalización. Fuente: elaboración propia.

Grupo	Capas	N	Emociones representativas
Temprano	L0–L3	9	gratitude (L0, 0,922), amusement (L0, 0,827), love (L0, 0,818), curiosity (L0, 0,674), optimism (L0, 0,569), admiration (L2, 0,735), disgust (L2, 0,532), fear (L3, 0,708), sadness (L3, 0,621)
Medio	L4–L7	8	anger (L4, 0,543), remorse (L5, 0,655), embarrassment (L5, 0,406), disapproval (L6, 0,521), caring (L6, 0,502), surprise (L7, 0,558), confusion (L7, 0,502), realization (L7, 0,327)
Tardío	L8–L11	6	joy (L8, 0,601), desire (L8, 0,582), approval (L8, 0,547), excitement (L8, 0,472), annoyance (L8, 0,416), disappointment (L9, 0,361)

La Figura 6.1 muestra la trayectoria completa de F1 a lo largo de todas las capas, donde se aprecia

el patrón de saturación progresiva característico de cada grupo.




Figura 6.1: Heatmap de F1 de los probes (23 emociones × 13 capas). El marcador indica la capa de cristalización de cada emoción. Las emociones se ordenan por profundidad de cristalización creciente. Fuente: elaboración propia.

Las emociones del grupo temprano poseen vocabulario altamente distintivo: *gratitude* se asocia a marcadores léxicos explícitos (“thanks”, “thank you”), *amusement* a indicadores como “lol” o “haha”, *love* a un campo semántico bien delimitado. La primera capa del encoder (L0) ya dispone de suficiente información léxica para que un clasificador lineal alcance un rendimiento cercano al máximo.

Las emociones tardías, en cambio, requieren integración contextual para desambiguarse de categorías vecinas: *annoyance* de *anger*, *approval* de *admiration*, *disappointment* de *sadness*. Estas distinciones no están en el vocabulario de superficie y emergen solo tras múltiples capas de procesamiento atencional. *Embarrassment* lo ilustra desde el grupo medio: tiene cierta señal léxica (“embarrassed”, “awkward”), pero su uso pragmático (a veces autoirónico, a veces genuino) demanda contexto, lo que retrasa su cristalización a L5.

La Figura 6.2 visualiza esta cristalización progresiva proyectando las representaciones del token [CLS] en cuatro capas representativas mediante t-SNE.




Figura 6.2: Proyecciones t-SNE de las representaciones del token [CLS] en cuatro capas del modelo (embedding, L4, L8, L11). Los puntos son ejemplos individuales del conjunto de test; los rombos, centroides por emoción. Los colores agrupan las emociones por similitud semántica. Fuente: elaboración propia.

La progresión es consistente con los grupos de cristalización que la Tabla 6.1 identifica numéricamente. En el embedding ninguna emoción es separable, lo que es esperable: el embedding codifica el significado del token [CLS] antes de procesar la frase. En L4 se observa el comportamiento medio del cluster “Positivas alta energía” (*gratitude, amusement, love*), cuyos centroides ya se desplazan hacia regiones distintivas, anticipando que cristalizan en L0–L2. En L8 emergen las distinciones contextuales: el cluster de “Negativas internas” se concentra en la región superior, el de “Negativas reactivas” en la derecha. En L11 los seis clusters ocupan regiones diferenciadas del plano, lo que cierra la formación representacional documentada por probing.

6.1.2. Ganancia informativa por capa

La contribución incremental de cada capa se cuantifica como la diferencia en F1 macro medio entre capas consecutivas (Figura 6.3). El análisis revela una arquitectura de procesamiento en dos fases.




Figura 6.3: Ganancia informativa incremental por capa, medida como el aumento en F1 macro medio respecto a la capa anterior. La capa L0 absorbe el 61 % de la separabilidad final del modelo. Fuente: elaboración propia.

La capa de embedding no contiene información emocional (F1 medio = 0). La primera capa del encoder (L0) produce un salto de +0,349, capturando el 61 % de la separabilidad lineal final del modelo: extracción de señal léxica bruta. Las capas L1–L7 aportan ganancias modestas y graduales, y L8 produce un segundo pico (+0,033) asociado a la desambiguación contextual de las emociones tardías.

Esta estructura de dos fases, con captura léxica masiva en L0, refinamiento contextual con pico en L8 y consolidación marginal en L10–L11, anticipa un resultado que será clave en el resto del capítulo: la distinción entre crear información emocional y formatearla para el clasificador. Las capas L10–L11 apenas crean información nueva según el probing, pero §6.2 y §6.3 demostrarán que son las únicas capaces de hacer utilizable la información existente para la cabeza de clasificación. Esta distinción se cuantifica directamente en la siguiente sección.

6.1.3. La frecuencia no predice la profundidad

Un análisis de correlaciones (Tabla 6.2, Figura 6.4) descarta la hipótesis de que la profundidad de cristalización esté determinada por el volumen de datos de entrenamiento.

Tabla 6.2: Correlaciones de Spearman entre propiedades de las emociones ($n = 23$). Solo la correlación entre profundidad de cristalización y F1 máximo es significativa. Fuente: elaboración propia.

Par de variables	ρ	p-valor	Sig.
Capa cristalización vs. F1 máximo	-0,673	0,0004	***
Frecuencia vs. capa cristalización	-0,265	0,22	ns.
Frecuencia vs. F1 máximo	+0,33	0,12	ns.




Figura 6.4: Izquierda: capa de cristalización vs. F1 máximo ($\rho = -0,673$, $p < 0,001$). Derecha: frecuencia en el dataset vs. capa de cristalización ($\rho = -0,265$, $p = 0,22$). Fuente: elaboración propia.

La correlación entre profundidad de cristalización y F1 máximo es fuerte y altamente significativa ($\rho = -0,673$, $p = 0,0004$): las emociones que cristalizan antes alcanzan mayor rendimiento. Sin embargo, la frecuencia en el dataset no predice ni la profundidad de cristalización ($p = 0,22$) ni el rendimiento máximo ($p = 0,12$).

El contraste entre *disgust* y *annoyance* lo ilustra: 793 ejemplos de entrenamiento frente a 2 470 (un factor 3×), pero *disgust* cristaliza en L2 y *annoyance* en L8: en este par, al menos, más datos no adelantan la cristalización. La evidencia es consistente con que la profundidad esté determinada principalmente por la naturaleza semántica de la emoción (la complejidad de las distinciones lingüísticas que el modelo necesita construir) más que por el volumen de datos disponible; sin embargo, dado que la correlación frecuencia–cristalización no alcanza significancia ($\rho = -0,265$, $p = 0,22$; IC95 cruza cero), esta interpretación es sugerente, no concluyente con la potencia estadística disponible ($n = 23$).

Esta observación sugiere una implicación práctica para la construcción de datasets de emociones: añadir más ejemplos de emociones contextualmente complejas podría no adelantar su cristalización si la dificultad es de naturaleza semántica, no estadística. El par analizado es consistente con esa hipótesis, aunque un solo contraste no permite generalizarla.

La potencia estadística es limitada por construcción ($n = 23$ emociones). Para acotar la incertidumbre con honestidad, se computa el intervalo de confianza al 95 % de cada coeficiente mediante *bootstrap por emoción* (10 000 réplicas, semilla 42, resampleo de pares emoción con reemplazo): la correlación cristalización–F1 máximo ($\rho = -0,673$) tiene CI95 = $[-0,87, -0,33]$, estrictamente negativo y por tanto significativo; la correlación frecuencia–cristalización ($\rho = -0,265$) tiene CI95 = $[-0,65, +0,19]$, que cruza cero, confirmando estadísticamente que la no significancia ($p = 0,22$) refleja ausencia de evidencia, no evidencia de ausencia. Con $n = 23$, el intervalo es necesariamente amplio; descartar definitivamente la influencia de la frecuencia requeriría un

dataset con más emociones, vía propuesta en §8.3.

6.2. Logit lens: la brecha entre información disponible e información leíble

6.2.1. Diseño experimental y motivación

El probing del apartado anterior establece cuándo la información emocional se vuelve linealmente accesible en las representaciones intermedias del modelo. Sin embargo, el probe es un clasificador entrenado ad hoc sobre cada capa: detecta información que está estructurada linealmente en alguna dirección, pero no necesariamente en la geometría que utiliza la cabeza de clasificación final del modelo. Una representación puede ser linealmente separable según el probe y, simultáneamente, ilegible para el clasificador entrenado, si la dirección de separación no coincide con la base sobre la que opera la cabeza de clasificación.

Para distinguir información disponible de información formateada para el clasificador, se aplica la técnica del logit lens [58]: tomar la representación del token [CLS] de cada capa intermedia y aplicarle directamente la cabeza de clasificación entrenada del modelo, sin re-entrenamiento. Las probabilidades resultantes indican la predicción que el modelo emitiría si tuviera que decidir desde esa capa, utilizando la cabeza ya optimizada para el [CLS] de L11.

Limitación de calibración. La cabeza de clasificación fue entrenada solo sobre representaciones de L11, por lo que aplicarla a capas intermedias produce magnitudes absolutas no comparables al baseline. Las comparaciones relativas entre capas o entre emociones siguen siendo informativas, y son las únicas que se interpretan en este capítulo. Una alternativa más rigurosa es el *tuned lens* [59], que se discute como trabajo futuro en el Capítulo 8.

El experimento se realiza sobre 2 300 ejemplos del conjunto de test (submuestreo equilibrado entre los tres grupos de cristalización), agregando los resultados según los grupos del probing (§6.1, Tabla 6.1).

6.2.2. Patrón agregado: tres regímenes geométricos

La Figura 6.5 muestra la evolución de las tres curvas del logit lens a lo largo de las 13 capas del modelo, promediadas sobre 2 300 ejemplos del conjunto de test.




Figura 6.5: Logit lens agregado sobre 2300 ejemplos del conjunto de test. Tres curvas: top-1 sigmoid (probabilidad media de la emoción más probable), gold sigmoid (probabilidad media de la emoción correcta), y suma de las 23 sigmoids (masa total de probabilidad). El patrón en U distingue tres regímenes geométricos sucesivos. Fuente: elaboración propia.

Promediando sobre los 2300 ejemplos, la probabilidad asignada a la emoción correcta (gold sigmoid) sigue un patrón en forma de U a lo largo del modelo (Figura 6.5): parte de un valor inicial moderado ($\approx 0,24$ en L0), cae a casi cero en capas medias ($\approx 0,02$ en L7–L8) y resurge bruscamente en capas tardías hasta alcanzar 0,44 en L11. Este patrón distingue tres regímenes geométricos cualitativamente distintos:

Régimen léxico (Emb–L2). El [CLS] permanece próximo al embedding crudo y activa difusamente múltiples direcciones del clasificador. La probabilidad media de la top-1 es alta ($\approx 0,6$), pero la masa total de las 23 emociones también lo es ($\approx 5,4$), reflejando una activación distribuida sin discriminación. El clasificador detecta señal léxica sin filtrar, no decisión emocional.

Régimen de transición (L3–L8). Las probabilidades colapsan para todas las emociones simultáneamente, incluida la correcta. Este valle universal indica que el [CLS] reside en una región del espacio representacional desalineada con la base del clasificador: la información que el probing detecta como presente en estas capas (§6.1) existe en una geometría interna del modelo, no proyectable directamente sobre las direcciones de clasificación. Es la fase de cómputo intermedio.

Régimen de cristalización (L9–L11). La probabilidad de la emoción correcta aumenta abruptamente, mientras que la suma total se mantiene moderada ($\approx 1,3$ en L11). El modelo amplifica la señal correcta y suprime activamente las incorrectas. La masa total de las 23 probabilidades es de 1,3, indicando concentración de masa en pocas direcciones. Esta es la fase de proyección sobre la base del clasificador.

6.2.3. Conexión con activation patching

Esta interpretación geométrica explica el resultado principal del activation patching que se presenta a continuación (§6.3): por qué la restauración exclusiva de la capa 11 desde un modelo colapsado recupera el 100 % del rendimiento. La capa 11 no contiene “todo el conocimiento emocional” en sentido literal (el probing muestra que la información se distribuye a lo largo de todas las capas), pero es donde culmina la proyección de esa información sobre la base del clasificador. Restaurar L11 reconstituye la última etapa de alineación geométrica, y la información residual que sobrevive a las capas comprimidas anteriores resulta suficiente para que el clasificador produzca predicciones correctas.

Esto reconcilia tres hallazgos que parecen contradictorios:

1. el probing localiza la formación de información en capas tempranas y medias;
2. el logit lens muestra que esa información no es leíble hasta capas tardías;
3. el activation patching identifica L11 como suficiente para la recuperación.

Las tres mediciones son consistentes si se distingue entre tres conceptos relacionados pero distintos: representación (qué información está presente, medido por probing), alineación (esa información está proyectada sobre la base del clasificador, medido por logit lens) y acceso (qué componentes son suficientes para que el clasificador opere, medido por patching). La distinción entre información presente e información utilizable ya está formalizada en la literatura (amnesic probing [53], V-usable information [54, 55]); la aportación aquí no es el concepto, sino su operacionalización empírica en el dominio emocional combinando tres técnicas sobre un mismo modelo. Así planteada, sugiere que cualquier análisis interpretativo que confunda los tres conceptos producirá conclusiones contradictorias como las que el probing y el patching parecen producir aisladamente. La distinción *presente/legible* depende empíricamente del valle observado en L3–L8; si un tuned lens [59] mostrara que ese valle es un artefacto de la descalibración de la cabeza (entrenada solo sobre L11), la tripartición colapsaría a dos conceptos (presente/suficiente). Esta contingencia se discute en §8.2.

6.3. Activation patching: localización del conocimiento emocional

6.3.1. Diseño experimental

El probing identifica dónde se forma la información emocional; el logit lens identifica dónde se alinea con la base del clasificador; el activation patching identifica qué componentes son funcionalmente necesarios para que el modelo opere. Las tres preguntas son complementarias: una capa puede crear poca información nueva (bajo gain o ganancia en probing) pero ser imprescindible para que la información existente llegue al clasificador en formato utilizable.

El experimento parte del modelo comprimido con SVD uniforme a rango 64, cuyo rendimiento es $F1_{macro} = 0,000$ (colapso total documentado en §5.2). Desde este estado de destrucción completa, se restauran los pesos originales de una capa o componente a la vez y se mide la recuperación del $F1_{macro}$. El porcentaje de restauración se calcula como $F1_{patched}/F1_{baseline} \times 100$, donde

$F1_{\text{baseline}} = 0,577$. El alcance y limitaciones del experimento respecto al *causal tracing* clásico se discuten en §4.4.3.

6.3.2. Patching por capa completa

La restauración capa por capa (Tabla 6.3) revela una concentración extrema de la capacidad funcional en las capas finales.

Tabla 6.3: Restauración del F1 macro al parchear una sola capa del modelo comprimido (rango 64). Se omiten las capas con restauración nula (0–7). Fuente: elaboración propia.

Capa restaurada	F1 Macro	Restauración (%)
0–7	0,000	0,0
8	0,001	0,1
9	0,024	4,1
10	0,139	24,1
11	0,577	100,0

Las capas 0–7 no contribuyen en absoluto a la recuperación. La capa 11 sola es suficiente para restaurar el 100 % del rendimiento baseline. La interpretación correcta de este resultado, anticipada por el logit lens (§6.2), es que L11 es donde culmina la alineación geométrica de la representación con la base del clasificador: restaurar L11 reconstituye la última proyección, y la señal residual que sobrevive a 10 capas comprimidas resulta suficiente para que el clasificador produzca predicciones correctas.

El resultado de L11 no es trivial por cercanía al clasificador. La restauración afecta solo a los pesos de las seis matrices del encoder en L11; la cabeza pooler y el clasificador no estaban comprimidos en el modelo corrupto. Lo que se mide, por tanto, es que L11, tras 10 capas comprimidas, todavía produce señal suficiente para que el clasificador acierte. Parchear L8–L10 produce recuperación parcial pero no completa: la suficiencia de L11 no es un artefacto de localización.

6.3.3. La FFN como componente suficiente para la recuperación

El análisis por componente (Tabla 6.4) desglosa cada capa en sus dos subcomponentes (atención multi-cabeza y red feed-forward) y revela una asimetría funcional de primer orden.

Tabla 6.4: Restauración del F1 macro al parchear un solo componente (atención o FFN) de las capas 8–11 del modelo comprimido. Fuente: elaboración propia.

Capa	Componente	F1 Macro	Restauración (%)
11	FFN	0,577	100,0
11	Atención	0,365	63,3
10	Atención	0,156	27,1
10	FFN	0,139	24,1
9	Atención	0,033	5,6
9	FFN	0,024	4,1
8	Atención	0,000	0,0
8	FFN	0,001	0,1

Restaurar únicamente la FFN de la capa 11 (aproximadamente un tercio de los parámetros de esa capa) recupera el 100 % del rendimiento. La atención de la misma capa alcanza un 63,3 % (cifra considerable, no marginal), con alta variabilidad entre emociones. La FFN, por tanto, es suficiente para recuperar al modelo del colapso por SVD; no se afirma que sea necesaria en sentido absoluto, dado que el experimento no incluye ablación de FFN L11 en el modelo no comprimido (§8.2).

Con esta cautela, el hallazgo es relevante: el peso del 100 % lo lleva la FFN, mientras que la atención por sí sola no basta. Este resultado es coherente con trabajos recientes que identifican las FFN como memorias asociativas del modelo [16], y conecta directamente con el hallazgo del logit lens: la proyección sobre la base del clasificador que documentamos en §6.2 es realizada principalmente por las FFN de las capas tardías, no por la atención.

6.3.4. Restauración diferencial por emoción

La restauración de la atención de la capa 11 presenta una marcada heterogeneidad entre emociones (Tabla 6.5).

Tabla 6.5: Restauración del F1 por emoción al parchear solo la atención de la capa 11. Se muestran las 5 emociones mejor y peor restauradas. Fuente: elaboración propia.

Bien restauradas	Rest. (%)	Mal restauradas	Rest. (%)
gratitude	100,0	remorse	0,0
annoyance	98,8	fear	3,6
admiration	95,4	desire	4,4
anger	94,5	realization	10,0
curiosity	91,1	disappointment	18,8

Las emociones que la atención restaura bien son aquellas con señales léxicas claras: *gratitude* se identifica por marcadores explícitos, *anger* por vocabulario de alta valencia negativa. La atención puede redirigir estas señales al token [CLS] de forma eficaz incluso con FFN comprimidas. En cambio, las emociones que la atención no restaura (*remorse*, *fear*, *desire*) son aquellas que requieren computación contextual más rica, precisamente la función que desempeña la FFN.

Una excepción notable es *annoyance* (98,8 %, segunda posición): el probing la clasifica como contextual (cristalización en L8, cero neuronas selectivas), pero la atención la restaura casi por completo. Una explicación plausible es que su léxico negativo reactivo sea suficientemente discriminativo para que la atención lo capture sin necesitar la computación FFN profunda, aun cuando el probing no detecte neuronas especializadas. Esto matiza la dicotomía léxico/contextual de tendencia general a tendencia con excepciones: la señal léxica de superficie puede compensar en ciertos casos la ausencia de especialización neuronal.

Este patrón refuerza la interpretación de los grupos de cristalización del probing (§6.1) y del logit lens (§6.2): las emociones tempranas son léxicas y dependen menos de la FFN profunda; las emociones tardías son contextuales y necesitan la FFN intacta para completar tanto la formación como la alineación de su representación.

En conjunto, el activation patching establece tres hechos: la capacidad funcional está concentrada en las capas tardías; dentro de ellas, la FFN es el componente suficiente para la recuperación; y esa suficiencia varía según la naturaleza léxica o contextual de la emoción.

Una limitación de diseño debe tenerse en cuenta: la corrupción empleada es SVD-r64 (distorsión estructurada), no ruido gaussiano sobre activaciones (causal tracing clásico de Meng et al. [9]). El experimento responde a “¿qué componente basta para recuperarse del colapso específico de SVD?”; un contraste con ruido gaussiano separaría lo específico de SVD de la localización funcional general, y queda como verificación propuesta en §8.3.

6.4. Ablación de cabezas de atención

6.4.1. Diseño experimental

Los experimentos anteriores operan a nivel de capa completa o de subcomponente (atención vs. FFN). La ablación de cabezas desciende a la granularidad individual: para cada una de las 144 cabezas de atención (12 capas $\times$ 12 cabezas), se anulan sus pesos (*zero-out*) y se mide la caída en F1 macro y en F1 por emoción. Para mantener tractable el coste computacional (144 cabezas $\times$ una pasada de evaluación cada una), la ablación se ejecuta sobre un submuestreo de 2 000 ejemplos del conjunto de test (en lugar del test completo de 5 427). El baseline local sobre este submuestreo es 0,582, ligeramente superior al baseline global de 0,577 del test completo (§4.2); todas las caídas reportadas en esta sección son absolutas respecto a ese baseline local, lo que las mantiene comparables entre sí.

A partir de estas mediciones se construyen dos métricas ortogonales: la importancia, definida como el impacto agregado en F1 a través de todas las emociones, y la selectividad, que mide la concentración de dicho impacto en pocas emociones (valor alto = efecto concentrado en 1–2 emociones; valor bajo = efecto distribuido). La ortogonalidad de ambas dimensiones se verifica empíricamente ($r = -0,055$), lo que justifica una clasificación 2 $\times$ 2 de las cabezas. Su correlación con la caída real de F1 por ablación ($r = 0,71$) es una comprobación de *consistencia interna* (ambas magnitudes están relacionadas por construcción, pues la importancia se define como impacto agregado en F1) y no una validación con un criterio independiente.

6.4.2. Taxonomía funcional

Las 144 cabezas se clasifican en cuatro categorías (Tabla 6.6).

Tabla 6.6: Taxonomía de cabezas de atención basada en importancia y selectividad. La baja correlación entre ambas dimensiones ($r = -0,055$) valida la clasificación. Fuente: elaboración propia.

Categoría	N	Import.	Select.	Rol funcional
Especialista crítica	37	0,282	0,680	Especializada en emociones concretas
Generalista crítica	35	0,265	0,544	Infraestructura emocional general
Especialista menor	35	0,101	0,702	Nicho funcional (1–2 emociones)
Prescindible	37	0,120	0,556	Candidata a poda

6.4.3. Gradiente de criticidad por profundidad

El hallazgo principal de este análisis es que la proporción de cabezas críticas crece monotónicamente con la profundidad (Tabla 6.7, Figura 6.6).

Tabla 6.7: Distribución de cabezas críticas y dispensables por bloque de profundidad. La capa 11 no contiene ninguna cabeza dispensable. Fuente: elaboración propia.

Bloque	Críticas	Dispensables
Capas 0–4	16/60 (27 %)	22/60 (37 %)
Capas 5–7	19/36 (53 %)	10/36 (28 %)
Capas 8–11	37/48 (77 %)	5/48 (10 %)

La capa 11 constituye un caso extremo: ninguna de sus 12 cabezas es prescindible: las 12 son críticas (6 especialistas y 6 generalistas). La importancia media por capa presenta un salto abrupto a partir de la capa 8 ($\sim 0,25$ vs. $\sim 0,15$ en capas anteriores), con la capa 11 alcanzando una importancia media de 0,381. Las 5 cabezas más importantes del modelo pertenecen a las capas 10–11, encabezadas por L11-H11 con una caída de F1 macro de 0,023.




Figura 6.6: Distribución de categorías de cabezas por capa. La proporción de cabezas críticas (especialistas + generalistas) crece con la profundidad. La capa 11 no contiene ninguna cabeza dispensable. Fuente: elaboración propia.

Este resultado proporciona triangulación con cuatro técnicas independientes: el probing (§6.1) muestra que la separabilidad lineal máxima se alcanza en capas finales; el logit lens (§6.2) identifica L9–L11 como la fase de cristalización donde la representación se alinea con el clasificador; el activation patching (§6.3) demuestra que la capa 11 es suficiente para restaurar el rendimiento completo; y la ablación confirma que cada cabeza individual de esa capa es funcionalmente necesaria. Las cuatro técnicas convergen en la misma conclusión: las capas 8–11 son el núcleo funcional del modelo emocional.

En términos de compresión, esta taxonomía deja un presupuesto de poda concreto: las 37 cabezas

prescindibles y las 21 interferentes (§6.4.4) son las candidatas naturales a eliminación directa sin reentrenamiento, y todas caen fuera de la capa 11, donde ninguna cabeza sobra. La granularidad de cabeza es, por tanto, donde una estrategia de poda puede ganar lo que la compresión uniforme por capa deja sobre la mesa.

6.4.4. Cabezas interferentes

Un hallazgo secundario es la existencia de 21 cabezas cuya ablación mejora el rendimiento ($\Delta F1 < -0,003$, umbral conservador sobre el ruido de medición). Su distribución es informativa: 7 en capas tempranas (L0–L4), 9 en intermedias (L5–L7) y solo 5 en tardías (L8–L11). El 76 % se concentra en capas no críticas. La cabeza más interferente es L11-H5 ($\Delta F1 = +0,012$), clasificada como Especialista crítica: probablemente entra en conflicto con otras cabezas de L11, y eliminarla resuelve la interferencia.

Una suma directa de las caídas negativas individuales daría $+0,095$ en F1 macro al ablacionar las 21 simultáneamente, lo que llevaría el modelo a $\sim 0,677$. Este cálculo asume aditividad: una hipótesis fuerte que las interacciones entre cabezas casi seguro violan. La estimación, por tanto, debe leerse solo como cota superior optimista, no como predicción de la ganancia real. La ablación coordinada de las 21 cabezas, que es el experimento que validaría el hallazgo, queda como trabajo futuro (§8.3).

6.4.5. Especialización emocional

Cada emoción depende de cabezas diferentes, concentradas mayoritariamente en las capas 8–11 (Tabla 6.8).

Tabla 6.8: Cabeza más importante para cada emoción (top 10 por magnitud de impacto). La caída de F1 indica cuánto pierde esa emoción al ablacionar su cabeza más crítica. Fuente: elaboración propia.

Emoción	Cabeza crítica	$\Delta F1$
embarrassment	L10-H1	$-0,267$
annoyance	L10-H0	$-0,090$
disappointment	L10-H4	$-0,080$
realization	L11-H6	$-0,064$
fear	L0-H8	$-0,056$
confusion	L9-H2	$-0,044$
sadness	L11-H6	$-0,041$
disgust	L9-H7	$-0,040$
joy	L10-H7	$-0,039$
anger	L8-H8	$-0,031$

El caso de *embarrassment* es extremo: la emoción colapsa a $F1 = 0$ al ablacionar cualquiera de cuatro cabezas equivalentes (L10-H1, L10-H4, L11-H2 y L11-H8, todas con $\Delta F1 = -0,267$ por empate exacto en el ranking). Esta concentración funcional en un puñado pequeño de cabezas redundantes (no en una sola, pero sí en muy pocas) probablemente refleja la baja frecuencia de la emoción en GoEmotions (303 ejemplos), que hace que el modelo aprenda un circuito atencional acotado y replicado por seguridad estadística. Desde la perspectiva de la compresión,

esto implica que la eliminación o degradación coordinada de esas cuatro cabezas destruiría selectivamente la capacidad del modelo para detectar *embarrassment*, un ejemplo de sesgo silencioso por compresión que las métricas agregadas no detectan fácilmente.

Otro patrón relevante es el compartimiento de circuitos: *realization* y *sadness* dependen de la misma cabeza (L11-H6), lo que sugiere un mecanismo atencional común, posiblemente la detección de un patrón contextual de expectativa frustrada que ambas emociones comparten.

6.5. Análisis neuronal de las redes feed-forward

6.5.1. Diseño experimental

El activation patching estableció la FFN de la capa 11 como el locus computacional crítico. El análisis neuronal desciende al nivel de las neuronas individuales dentro de las FFN para examinar dos preguntas: cómo se distribuye la especialización emocional a través de las 36 864 neuronas (12 capas $\times$ 3 072 neuronas), y si la compresión SVD daña selectivamente las neuronas más especializadas.

El diseño detallado del análisis neuronal (métrica de selectividad tipo Cohen's d , extracción de activaciones post-GELU y proyección sobre subespacios SVD) se describe en §4.4.5.

6.5.2. Especialización concentrada en capas profundas

La distribución de neuronas significativas por profundidad (Tabla 6.9) replica el patrón ya observado en probing, patching y ablación de cabezas.

Tabla 6.9: Distribución de neuronas especializadas ($|d| > 2,0$) por bloque de profundidad. El 84 % de las neuronas significativas se concentra en las capas 8–11. Fuente: elaboración propia.

Bloque	Neuronas significativas	Selectividad máx. media
Capas 0–3	11 (0,3 %)	0,91–1,15
Capas 4–7	570 (16 %)	1,50–2,19
Capas 8–11	3 061 (84 %)	3,10–3,92

El 84 % de las neuronas especializadas se concentra en las capas 8–11, con la capa 11 aportando 1 127 neuronas significativas por sí sola. Las capas 0–3 contienen prácticamente ninguna neurona con especialización emocional detectable. Este resultado es coherente con la función de las capas tempranas como procesadores léxicos genéricos: contribuyen a la señal emocional (probing), pero lo hacen a través de representaciones distribuidas, no de neuronas individuales especializadas.

6.5.3. Asimetría radical entre emociones

El número de neuronas significativas varía en órdenes de magnitud entre emociones (Tabla 6.10).

Las emociones mejor codificadas (*gratitude*, *remorse*) disponen de cientos de neuronas dedicadas, mientras que *annoyance*, *disappointment* y *realization* carecen de neuronas individuales significativas. Las neuronas con mayor selectividad de todo el modelo ($d > 7$) pertenecen a *fear* y *remorse*,

Tabla 6.10: Neuronas significativas y selectividad máxima por emoción (selección). Tres emociones no tienen ninguna neurona con $|d| > 2,0$. Fuente: elaboración propia.

Emoción	Neuronas sig.	Selectividad máx.
gratitude	818	6,88
remorse	442	7,75
love	399	5,41
amusement	394	5,90
fear	306	7,71
annoyance	0	1,71
disappointment	0	1,89
realization	0	1,96

ambas en la capa 11.

Esta asimetría sugiere dos estrategias de codificación cualitativamente distintas: emociones con neuronas altamente especializadas (codificación concentrada) y emociones que se reparten en patrones distribuidos sutiles que la selectividad individual no captura (codificación distribuida).

6.5.4. La hipótesis SVD-neuronas: un resultado nulo informativo

La hipótesis inicial era que la SVD dañaría selectivamente las emociones cuyas neuronas especializadas cayeran desproporcionadamente en el subespacio eliminado. No se detecta evidencia de tal correlación: $\rho = -0,004$, $p = 0,99$. El hallazgo de fondo, sin embargo, no es el coeficiente sino la *cuasi-constancia* del predictor: la fracción de señal eliminada es casi idéntica para todas las emociones (rango 0,53–0,56). Con un predictor de varianza casi nula el coeficiente de correlación es estructuralmente poco informativo (no hay variabilidad que pueda explicar la vulnerabilidad diferencial), de modo que es esa uniformidad la que sostiene la disociación. En este trabajo, por tanto, no encontramos discriminación selectiva de la SVD sobre identidades funcionales.

El resultado revela una disociación: la geometría que la SVD optimiza (energía espectral) es ortogonal a la estructura funcional del modelo (especialización emocional). Esto clarifica por qué la compresión SVD informada funciona: no porque dirija el truncamiento a neuronas específicas, sino porque puede asignar más rango a los componentes cuya destrucción causa más daño.

El patrón es consistente con la hipótesis de *superposition* de Elhage et al. [61]: cuando una red necesita representar más características funcionales que dimensiones disponibles, las distribuye en direcciones casi-ortogonales, aceptando interferencias a cambio de capacidad. Las direcciones funcionales (creadas por el optimizador durante el fine-tuning) y las direcciones SVD principales (creadas por la geometría algebraica de los pesos) no tienen por qué coincidir. La implicación práctica es que los métodos de compresión geométrica nunca podrán ser selectivamente funcionales por sí solos: la selectividad debe entrar por la puerta de la sensibilidad empírica medida, como hace el algoritmo greedy del Capítulo 7.

6.5.5. La norma de selectividad como predictor de vulnerabilidad

Si la geometría SVD no explica la vulnerabilidad diferencial, ¿qué la explica? Un análisis sistemático testa seis predictores posibles de la caída de F1 bajo compresión (Tabla 6.11).

Tabla 6.11: Predictores de la vulnerabilidad emocional a compresión SVD ($n = 23$). La norma de selectividad, que mide la intensidad total de codificación neuronal, es el mejor predictor. Fuente: elaboración propia.

Predictor	ρ	p-valor	Sig.
Fracción en subespacio eliminado	-0,004	0,986	ns.
Nº ejemplos de entrenamiento	+0,174	0,427	ns.
Aislamiento representacional	+0,452	0,031	*
Selectividad máxima	+0,517	0,012	*
Nº neuronas significativas	+0,581	0,004	**
Norma de selectividad	+0,639	0,001	***

El mejor predictor es la norma del vector de selectividad ($\rho = 0,639$, $p = 0,001$), que mide la intensidad total con la que el modelo codifica cada emoción a través de sus neuronas FFN. Las emociones con codificación más intensa (*gratitude*: norma 140, *remorse*: 111, *love*: 105) sufren más con la compresión que las de codificación débil (*disappointment*: 42, *realization*: 43).

La SVD no daña selectivamente las neuronas emocionales (la geometría del subespacio eliminado es ortogonal a la especialización funcional). Pero las emociones codificadas con mayor intensidad neuronal son más vulnerables a perturbaciones generales: su representación depende de configuraciones más específicas. La robustez a perturbación general puede estimarse, por tanto, a partir de la intensidad de codificación, una métrica intrínseca al modelo que no requiere experimentos de compresión. Esto la convierte en una herramienta de cribado práctica: se calcula una vez sobre el modelo fine-tuned y anticipa, antes de comprimir, qué clases pagarán el precio más alto. Es un insumo directo para decidir si el sesgo que introduce la compresión es asumible en la aplicación concreta.

6.5.6. Clusters emocionales emergentes

La agrupación jerárquica sobre los vectores de selectividad concatenados produce seis clusters emocionales (Tabla 6.12) que reflejan categorías psicológicas coherentes.

Tabla 6.12: Clusters emocionales emergentes de la estructura neuronal del modelo. Las agrupaciones se obtienen por clustering jerárquico sobre los vectores de selectividad de 36 864 neuronas. Fuente: elaboración propia.

Cluster	Emociones
Positivas de alta energía	admiration, amusement, excitement, gratitude, joy, love
Negativas reactivas	anger, annoyance, disappointment, disapproval, disgust
Negativas internas	embarrassment, fear, remorse, sadness
Cognitivas	confusion, curiosity, surprise
Orientadas al otro	caring, desire, optimism
Baja especificidad	approval, realization

Estos clusters no se imponen a priori sino que emergen directamente de la estructura de activaciones del modelo. Su reproducción de categorías reconocibles de la psicología de las emociones (positivas vs. negativas, reactivas vs. internas, cognitivas vs. afectivas) sugiere que el fine-tuning ha organizado las representaciones internas de BERT de forma psicológicamente coherente, no solo estadísticamente eficaz. El modelo no fue entrenado con información sobre la estructura psicológica de las emociones, pero la recupera implícitamente.

Más allá de la coherencia psicológica, este resultado importa para la comprensión por una vía indirecta: que el fine-tuning haya organizado las representaciones en estructura legible es lo que hace siquiera concebible una comprensión selectiva. Si la señal estuviera repartida sin estructura, no habría componentes “baratos” que recortar.

6.6. Síntesis del capítulo

Las cinco técnicas de este capítulo, pese a medir cosas distintas y con métodos independientes, dibujan el mismo modelo en tres niveles. El probing y el logit lens muestran dónde y cuándo cada emoción se vuelve legible; el activation patching señala qué componentes bastan para sostener esa lectura; y la ablación de cabezas y el análisis neuronal localizan la especialización dentro de cada capa. Todas coinciden en una misma descripción: las capas tempranas extraen señal a partir de las palabras, las intermedias calculan en una representación interna propia que el clasificador todavía no lee, y las tardías reorganizan esa representación para que la cabeza de clasificación pueda interpretarla.

Esa convergencia es lo que da solidez al mapa, porque no depende de un único método ni de una única métrica. Y tiene una consecuencia que el capítulo siguiente aprovecha: si la información emocional está organizada de forma tan estructurada, con unas capas y unos componentes claramente más decisivos que otros, la comprensión no debería tratar a todas las partes por igual. Medir esa estructura es lo que conecta la interpretabilidad de este capítulo con la comprensión informada del Capítulo 7.

Capítulo 7

Síntesis: compresión informada por interpretabilidad

Los dos capítulos anteriores han recorrido caminos complementarios. El Capítulo 5 midió qué se rompe al comprimir BERT con SVD: la sensibilidad varía hasta 72× entre componentes (a rango 128, normalizado por parámetros), presenta una transición de fase abrupta por profundidad (entre rango 384 y 256), y difiere por emoción (*gratitude* retiene el 99 % del F1 a rango 384; *embarrassment* colapsa al 0 % al mismo rango).

El Capítulo 6 investigó por qué. Cinco técnicas convergen en una arquitectura funcional de tres niveles: información léxica en capas tempranas, cómputo de transición en capas medias, y alineación geométrica con la base del clasificador en capas tardías, donde reside el cuello de botella computacional del modelo.

Este capítulo cierra el bucle: usa esos hallazgos para diseñar estrategias de compresión informadas y evalúa si el conocimiento se traduce en ventaja cuantitativa sobre las baselines del Capítulo 5. La progresión que sigue (intuición, fracaso de la intuición, pivote a datos, dominancia) puede ser instructiva para otros trabajos de “compresión informada”.

Las secciones que siguen desarrollan esta progresión: la conexión cuantitativa entre cristalización y vulnerabilidad (§7.1), el fracaso de la estrategia heurística informada (§7.2), la dominancia del algoritmo greedy sobre la frontera de Pareto (§7.3), la recuperación mediante fine-tuning con grupo de control (§7.4) y las implicaciones del conjunto (§7.5).

7.1. La cristalización predice la vulnerabilidad

La primera pregunta de síntesis es si los dos ejes del proyecto (compresión e interpretabilidad) convergen cuantitativamente, no solo metafóricamente. El Capítulo 6 mostró que cada emoción cristaliza a una profundidad distinta: *gratitude* alcanza el 80 % de su F1 máximo en la capa 0, mientras que *disappointment* no lo hace hasta la capa 9. El Capítulo 5 mostró que la compresión SVD uniforme afecta a cada emoción de forma diferencial.

7.1.1. Correlación cristalización-vulnerabilidad

La correlación entre la capa de cristalización y la pérdida relativa de F1 (1–retención) bajo compresión SVD uniforme a rango 384 es positiva y significativa (Spearman $\rho = 0,49$, $p = 0,017$,

$n = 23$; CI95 bootstrap $[0,07, 0,78]$, 10 000 réplicas, semilla 42): las emociones que cristalizan en capas más profundas pierden una fracción mayor de su $F1$ al comprimir. Se evalúa a rango 384 porque es el último nivel uniforme con supervivencia diferencial entre emociones (18 de 23 conservan $F1 > 0$); a rango 256 solo sobreviven 3 y a rango 128 el modelo colapsa por completo ($F1 = 0$ en las 23), de modo que la correlación solo es computable por encima del cliff. El intervalo es amplio y su extremo inferior queda cerca de cero, así que es un predictor moderado, por debajo de la norma de selectividad neuronal (§6.5), y debe leerse como tendencia. Este resultado es coherente con la estructura espectral documentada en §5.1: las matrices de las capas tardías presentan distribuciones de valores singulares menos concentradas (menor redundancia), lo que las hace más frágiles bajo truncamiento SVD.

La conexión, sin embargo, no se agota en una correlación. Tres predictores independientes de la vulnerabilidad emergen del análisis combinado:

- Profundidad de cristalización por *probing* (§6.1): $\rho = 0,49$.
- Aislamiento representacional, distancia media a otras emociones en el espacio de [CLS] de L11 (§6.1): $\rho = 0,45$, $p = 0,031$.
- Norma del vector de selectividad neuronal (§6.5): $\rho = 0,639$, $p = 0,001$.

Estos tres predictores se miden antes de comprimir, así que permiten anticipar qué emociones se degradarán y cuantificar el sesgo que la compresión introducirá. Sirven de cribado previo: señalan dónde el coste funcional será desigual entre clases.

El predictor más fuerte es la norma de selectividad neuronal (§6.5), cuya relación con la vulnerabilidad se analizó en detalle en el capítulo anterior. La Figura 7.1 cruza los dos predictores principales para construir un mapa emocional del modelo.




Figura 7.1: Mapa emocional del modelo. Cada punto representa una de las 23 emociones, situada según su capa de cristalización por probing (eje horizontal en convención 1=L0, 2=L1, ..., 10=L9, derivado del Capítulo 6) y su norma de selectividad neuronal (eje vertical, intensidad total con la que el modelo codifica esa emoción a través de sus neuronas FFN). Los colores agrupan las emociones por cluster semántico. Las bandas verticales sombreadas marcan los tres bloques de profundidad: temprano (L0–L3), medio (L4–L7) y tardío (L8–L11). Las emociones léxicas (*gratitude*, *love*, *amusement*) ocupan la región superior izquierda; las contextuales (*annoyance*, *disappointment*) la inferior derecha. Nota: el cluster etiquetado en la leyenda como “Epistémicas” se denomina “Cognitivas” en el texto (mismo grupo). Fuente: elaboración propia.

La distribución no es uniforme. Las emociones léxicas se concentran en la región superior izquierda del mapa: cristalización temprana y alta intensidad neuronal. *Gratitude* es el caso extremo, con cristalización en L0 y la mayor intensidad de codificación neuronal del dataset. Las emociones contextuales ocupan la región inferior derecha: cristalización tardía y baja intensidad. *Disappointment* y *annoyance* muestran una intensidad de codificación aproximadamente un orden de magnitud inferior a pesar de cristalizar en L9–L10. Los valores absolutos del eje vertical de la Figura 7.1 corresponden a la máxima norma capa a capa del vector de selectividad (resumen visual), mientras que la norma agregada ℓ_2 a través de las 12 capas, reportada en §6.5 y utilizada como predictor cuantitativo ($\rho = 0,639$), produce la misma ordenación entre emociones pero en una escala distinta (*gratitude*: 140; *remorse*: 111; *disappointment*: 42).

Esta correspondencia entre probing y selectividad neuronal, dos magnitudes derivadas de experimentos independientes, no es trivial. Probing mide la separabilidad lineal de la representación; la selectividad neuronal mide la especialización de las neuronas individuales. Su correlación sugiere que ambas son medidas convergentes de la disponibilidad de señal léxica robusta. Las emociones contextuales no son simplemente más difíciles: son representacionalmente más

débiles, y esa debilidad estructural es la que las hace vulnerables a la compresión.

7.1.2. Tres principios de compresión informada

De estos hallazgos se derivan tres principios que orientan el diseño de estrategias de compresión informadas:

1. Proteger las capas tardías. Concentran la especialización funcional (84 % de neuronas significativas, 77 % de cabezas críticas) y tienen menor redundancia espectral. Comprimir capas 8–11 al mismo rango que capas 0–3 es estructuralmente incorrecto.
2. Distinguir componentes dentro de cada capa. La FFN Intermediate es el cuello de botella computacional confirmado por *activation patching* (§6.3); Q y K toleran compresión agresiva con coste despreciable. Aplicar el mismo rango a Q y a FFN Intermediate ignora un factor 14× de diferencia en retención de F1 a rango 128 (que se amplía a 72× cuando se normaliza por parámetros eliminados).
3. Aceptar que la compresión introduce sesgo emocional. Las emociones contextualmente complejas (cristalización tardía, codificación intensa) son penalizadas desproporcionadamente. Este sesgo es inevitable sin intervención selectiva: cualquier estrategia uniforme lo introduce de forma silenciosa.

Los principios son cualitativos. La pregunta abierta, y que motiva el resto del capítulo, es si pueden traducirse directamente en reglas heurísticas o si requieren cuantificación empírica.

7.2. Estrategia heurística: un resultado negativo informativo

El primer intento de traducir la comprensión mecánica en una estrategia de compresión adoptó un enfoque heurístico: asignar rangos SVD a cada componente y capa según reglas cualitativas derivadas de los hallazgos de interpretabilidad. La premisa de partida era razonable: si comprender el modelo permite comprimirlo mejor, las reglas explícitas derivadas de esa comprensión deberían superar a las estrategias ciegas.

7.2.1. Diseño de las tres variantes

Se diseñaron tres niveles de agresividad respetando los principios de §7.1:

- **Informed-light:** compresión conservadora que protege las capas tardías con rangos altos (700 en capa 11) y aplica reducciones moderadas en capas tempranas. Ratio de parámetros: 1,285.
- **Informed-moderate:** compresión intermedia con protección de la capa 11 (rango 512) y rangos entre 170 y 430 en el resto. Ratio: 1,000.
- **Informed-aggressive:** compresión fuerte con rangos entre 86 y 384. Ratio: 0,612.

Las tres variantes respetan el gradiente de criticidad por profundidad (más rango en capas tardías que en tempranas) y la asimetría entre componentes (más rango en FFN que en atención), mediante reglas explícitas derivadas de los hallazgos de interpretabilidad.

7.2.2. Resultados

Los resultados son reveladores (Tabla 7.1):

Tabla 7.1: Rendimiento de las estrategias heurísticas informadas frente a baselines de complejidad comparable. Las tres variantes igualan exactamente al baseline uniforme con el mismo ratio de parámetros (`informed_aggressive` = `uniform_r256`; `informed_moderate` = `uniform_r512`), o requieren más parámetros que el original sin alcanzar la retención de `adaptive_e99` (`informed_light`). Ninguna domina la frontera de Pareto. Fuente: elaboración propia.

Estrategia	Tipo	Ratio params.	F1 macro	Retención
<code>uniform_r256</code>	uniforme	0,612	0,025	4,3 %
<code>informed_aggressive</code>	informada	0,612	0,025	4,3 %
<code>adaptive_e80</code>	adaptativa	0,721	0,143	24,8 %
<code>uniform_r512</code>	uniforme	1,000	0,464	80,4 %
<code>informed_moderate</code>	informada	1,000	0,464	80,4 %
<code>adaptive_e95</code>	adaptativa	1,022	0,491	85,0 %
<code>adaptive_e99</code>	adaptativa	1,202	0,558	96,7 %
<code>informed_light</code>	informada	1,285	0,561	97,2 %

Las tres variantes presentan el mismo patrón estructural: igualan en F1 macro al baseline uniforme de complejidad equivalente, o lo superan solo a costa de un incremento sustancial de parámetros. La variante agresiva, con ratio 0,612 y $F1 = 0,025$, coincide hasta la precisión reportada con `uniform_r256`, y la moderada, con ratio 1,000 y $F1 = 0,464$, alcanza el mismo F1 macro que `uniform_r512`. La coincidencia de F1 se da pese a que las asignaciones de rango por capa de las variantes informadas difieren de las uniformes: no es un empate exacto entre configuraciones idénticas, sino la convergencia de su efecto agregado, cuyo mecanismo se diagnostica en el apartado siguiente (el conservadurismo de la heurística la lleva a un punto de operación efectivamente equivalente al de la uniforme). La variante conservadora alcanza un F1 de 0,561 (ligeramente superior al baseline `adaptive_e99`), pero requiere un 28,5 % más parámetros que el modelo original (ratio 1,285), lo que la sitúa fuera del régimen de compresión efectiva.

Ninguna de las tres variantes informadas aparece en la frontera de Pareto: todas son dominadas por las baselines de complejidad equivalente o por las estrategias adaptativas energéticas.

7.2.3. Diagnóstico del fracaso

Este resultado negativo es instructivo, no anecdótico. La intuición cualitativa derivada de la interpretabilidad (“proteger capas tardías, comprimir agresivamente Q y K, respetar la asimetría componente”) es correcta en su dirección (el algoritmo greedy §7.3 confirma exactamente esa secuencia de decisiones cuando opera con datos cuantitativos), pero traducirla a reglas heurísticas explícitas no produce ganancia alguna sobre las baselines: las `informed` simplemente reproducen la misma frontera que las estrategias ciegas alcanzan sin invocar interpretabilidad.

La razón es la magnitud relativa de las sensibilidades. Saber que Q es más compresible que FFN Intermediate no revela la magnitud de esa diferencia ni la jerarquía exacta de prioridades a distintas profundidades. La regla heurística asigna, por ejemplo, “rango 256 a Q en capas medias”; los datos cuantitativos revelan que Q a rango 128 retiene 99,4 % del F1 (§5.3), por lo

que el rango 256 es innecesariamente conservador. Multiplicado por las 72 matrices del modelo, el conservadurismo acumulado lleva a la heurística a converger exactamente sobre los puntos que la compresión uniforme alcanza sin ninguna información estructural: `informed_aggressive` reproduce `uniform_r256`, `informed_moderate` reproduce `uniform_r512`. La heurística no extrae valor adicional del conocimiento mecanicista que pretende traducir.

La conclusión metodológica es precisa: traducir interpretabilidad mecánica en compresión efectiva requiere datos empíricos de sensibilidad, no solo comprensión arquitectónica. La interpretabilidad cualitativa identifica qué investigar; la sensibilidad cuantitativa determina cuánto comprimir. Que las tres variantes informadas converjan sobre la frontera de las baselines ciegas, en lugar de superarla, es la evidencia más limpia posible de esta separación: el conocimiento cualitativo de la estructura funcional es necesario pero no suficiente para guiar la compresión. Esta distinción motiva el cambio de enfoque hacia el algoritmo greedy data-driven.

7.3. Algoritmo greedy: compresión guiada por datos

El fracaso de la estrategia heurística motivó un cambio de enfoque: en lugar de traducir la intuición mecánica en reglas, utilizar directamente los datos cuantitativos de sensibilidad por componente (§5.3) y por profundidad como entrada para un algoritmo de optimización.

7.3.1. Por qué greedy y no otra estrategia

El problema es seleccionar simultáneamente 18 rangos (6 componentes $\times$ 3 bandas de profundidad) en un menú discreto de 3 valores candidatos cada uno, optimizando el F1 macro bajo una restricción de parámetros máximos. Tres aproximaciones aparecen como candidatas naturales y todas presentan inconvenientes serios.

La búsqueda exhaustiva es inviable: $3^{18} \approx 3,9 \cdot 10^8$ configuraciones, ~ 30 s por evaluación en GPU T4, dan unos 370 años de cómputo. La optimización bayesiana sobre el espacio de rangos discreto es viable conceptualmente, pero exige cientos de evaluaciones del modelo comprimido para construir el *surrogate* (varias horas de GPU) y el espacio discreto degrada la calidad del GP. Los métodos diferenciables (*straight-through estimators*, Gumbel-softmax sobre rangos) requieren relajaciones que cambian la naturaleza del problema y no aprovechan los datos de sensibilidad ya medidos.

El greedy data-driven evita estas tres limitaciones. Es interpretable (la secuencia de movimientos se puede leer y se corresponde con una narrativa funcional que valida cruzadamente los hallazgos del Capítulo 6), lineal en el número de movimientos ($O(|moves|)$) y resuelve el problema en menos de un segundo, sin requerir ninguna evaluación adicional del modelo porque los costes provienen de los datos pre-calculados de sensibilidad. Como contrapartida es sub-óptimo: el algoritmo no explora el espacio combinatorio completo y no garantiza alcanzar el máximo global. Su validación es empírica: 8 de los 9 puntos Pareto-óptimos sobre 21 configuraciones evaluadas son greedy (§7.3), lo que sugiere que la sub-optimalidad real es modesta dentro de la región funcional del espacio compresión–rendimiento.

7.3.2. Diseño del algoritmo

El algoritmo greedy opera sobre 42 movimientos de compresión posibles: cada uno reduce el rango SVD de un componente (Q, K, V, Attn Output, FFN Intermediate, FFN Output) en una de las tres bandas de profundidad (capas 0–3, 4–7, 8–11). Los rangos candidatos se restringen a los que los datos de sensibilidad del Capítulo 5 declaran asumibles: Q y K admiten {256, 128, 64}; FFN Intermediate solo {256}, porque a rango 128 ya retiene el 6,9 % del F1. A cada movimiento se le asigna una eficiencia:

$$\mathcal{E}(\text{movimiento}) = \begin{cases} +\infty & \text{si } \Delta F1 \leq 0 \\ \frac{\text{params_ahorrados}}{\Delta F1 \cdot 100} & \text{en otro caso} \end{cases} \quad (7.1)$$

El algoritmo aplica movimientos en orden decreciente de eficiencia hasta alcanzar el ratio de parámetros objetivo. El pseudocódigo completo está en el Algoritmo 1 (Capítulo 4).

7.3.3. Secuencia de decisiones

La secuencia con que el algoritmo asigna compresión al aplicarse sobre GoEmotions revela una jerarquía de importancia que valida independientemente los hallazgos de interpretabilidad (Tabla 7.2):

Tabla 7.2: Secuencia de decisiones del algoritmo greedy. Cada fila muestra los componentes comprimidos al alcanzar el ratio indicado. El algoritmo opera exclusivamente con datos numéricos de sensibilidad, sin acceso a los hallazgos cualitativos de interpretabilidad. Fuente: elaboración propia.

Config.	Ratio	Componentes comprimidos
greedy_95	0,950	Solo Q y K
greedy_90	0,864	Q, K, FFN Output (capas tempranas)
greedy_85	0,813	Q, K, FFN Output (tempranas + medias)
greedy_80	0,799	Q, K, V (tempranas), FFN Output
greedy_75	0,741	Q, K, V, FFN Inter+Out (tempranas)
greedy_70	0,670	Todos los componentes, mayoritariamente tempranos y medios

Tres observaciones emergen de esta secuencia, cada una con su contraparte en interpretabilidad:

1. Q y K son esencialmente gratuitas de comprimir. El primer 5 % de reducción de parámetros proviene íntegramente de comprimir las proyecciones de Query y Key, con un coste en F1 inferior al 0,5 %. Esto es coherente con el análisis de sensibilidad por componente (§5.3), que documentó retenciones del 99,4 % para Q y 98,4 % para K a rango 128, y con el solapamiento espectral elevado entre subespacios Q-K (hasta 0,63 para los 32 vectores singulares principales, §5.1). Q y K codifican esencialmente redundancia, no información distintiva.
2. La FFN Intermediate no se comprime en capas tardías. Ninguna configuración greedy con retención superior al 30 % toca la FFN Intermediate de las capas 8–11. El algoritmo descubre de forma independiente el cuello de botella identificado por activation patching

(§6.3): restaurar únicamente la FFN de la capa 11 recuperaba el 100 % del rendimiento del modelo. La convergencia entre dos métodos metodológicamente distintos (uno mide sensibilidad puntual, otro mide suficiencia funcional) en el mismo componente como único crítico es una coherencia esperada que refuerza la robustez de la conclusión.

3. Las capas tardías se protegen sistemáticamente. Incluso en las configuraciones más agresivas (*greedy_70*, ratio 0,67), las capas 8–11 retienen rangos sustancialmente mayores que las tempranas. Esto valida el gradiente de criticidad documentado por la ablación de cabezas (§6.4): el 77 % de las cabezas en capas 8–11 son críticas frente al 27 % en capas 0–4.

La convergencia entre la secuencia de decisiones del algoritmo (que opera solo con datos numéricos de sensibilidad por componente y profundidad) y los hallazgos cualitativos de interpretabilidad (que explican por qué esos componentes son sensibles) constituye una validación cruzada de ambas líneas de análisis. Si interpretabilidad y compresión llegan a las mismas conclusiones por caminos metodológicamente distintos, la probabilidad de que ambas estén sistemáticamente sesgadas en la misma dirección es baja.

7.3.4. Dominancia en la frontera de Pareto

La Figura 7.2 presenta la comparación completa de las 21 configuraciones evaluadas en el espacio ratio de parámetros vs. F1 macro. El conjunto está formado por 6 uniformes (rangos {32, 64, 128, 256, 384, 512}, exhaustivo), 4 adaptativas (umbrales de energía 80 %, 90 %, 95 %, 99 %; el umbral 85 %, reportado en la Tabla 5.6, queda fuera de este conjunto por estar dominado), 3 heurísticas informadas (*light*, *moderate*, *aggressive*) y 8 greedy (ratios objetivo $\rho \in \{0,58, 0,65, 0,70, 0,75, 0,80, 0,86, 0,90, 0,95\}$, muestreando la frontera con resolución uniforme). La densidad de muestreo no es la misma entre familias, por lo que la dominancia en términos absolutos (8 de 9 puntos Pareto) debe interpretarse en conjunto con esta diferencia.

De los 9 puntos Pareto-óptimos en sentido estricto, 8 son estrategias greedy. El algoritmo basado en datos empíricos domina la frontera completa en la región funcional ($F1 > 0$), desde un ratio de 0,58 hasta 0,95. La Tabla 7.3 cuantifica las ventajas en comparaciones directas a ratios de parámetros similares:

Tabla 7.3: Comparaciones directas entre estrategias greedy y alternativas a ratios de parámetros comparables. Los intervalos de confianza al 95 % se obtienen mediante bootstrap por emoción (10 000 réplicas, $n = 23$); el p -valor en la columna $\Delta F1$ corresponde a un test *paired bootstrap* sobre la diferencia por emoción cuando se dispone de datos por emoción para ambas estrategias. Fuente: elaboración propia.

Comparación a ratio similar	Greedy F1 [CI95]	Alt. F1 [CI95]	$\Delta F1$	Sig.
greedy_80 ($\rho = 0,80$) vs uniform_r384 ($\rho = 0,81$)	0,502 [†]	0,251 [0,151; 0,365]	+0,251	—
greedy_90 ($\rho = 0,86$) vs adaptive_e90 ($\rho = 0,89$)	0,539 [0,467; 0,613]	0,357 [0,255; 0,466]	+0,181 [+0,130; +0,241]	$p < 0,001$
greedy_95 ($\rho = 0,95$) vs adaptive_e95 ($\rho = 1,02$)	0,575 [†]	0,491 [0,400; 0,581]	+0,084	—

[†] Solo se dispone del F1 macro agregado, sin desglose por emoción, por lo que no es posible construir el intervalo de confianza ni el test pareado. La comparación *greedy_90* vs *adaptive_e90* es la evidencia estadística más limpia disponible.

El resultado más llamativo se da en el rango intermedio: a un ratio de $\sim 0,80$, la estrategia greedy retiene el 87,0 % del F1 original, mientras que la uniforme a rango 384 solo retiene el 43,5 %: una ventaja superior al doble en retención. La comparación *greedy_90* vs *adaptive_e90*,




Figura 7.2: Frontera de Pareto para las cuatro familias de estrategias de compresión. Los puntos sobre la curva envolvente representan configuraciones Pareto-óptimas. 8 de los 9 puntos Pareto-óptimos corresponden a estrategias greedy. La única estrategia no-greedy en la frontera es `uniform_r32`, que aparece solo por tener el menor ratio absoluto pero con $F1 = 0$ (el modelo está colapsado). Fuente: elaboración propia.

donde sí se dispone de datos por emoción para ambas, permite cuantificar formalmente la ventaja: $\Delta F1 = +0,181$ con intervalo de confianza al 95 % [$+0,130$; $+0,241$] (paired bootstrap sobre las 23 emociones, 10 000 réplicas, $p < 0,001$). El intervalo está estrictamente alejado de cero, descartando la posibilidad de que la ventaja del greedy sea atribuible a variabilidad muestral entre emociones. Nótese que la comparación con `adaptive_e95` es particularmente reveladora: el algoritmo greedy obtiene un F1 superior con un 7 % menos de parámetros, dado que la estrategia adaptativa al 95 % de energía produce un ratio de 1,02 (es decir, incrementa los parámetros, como se discutió en §5.4).

A ratio 0,95, la estrategia `greedy_95` alcanza una retención del 99,6 % del F1 baseline (sin pérdida medible) con una reducción del 5 % en parámetros que viene íntegramente de comprimir Q y K. Existe, por tanto, una región de compresión de bajo coste (Q y K a rango 128) que las estrategias uniformes no identifican.

Para un ingeniero que fija un presupuesto de parámetros, esto se traduce en dos ganancias concretas. En el extremo conservador, el greedy reduce un ~5 % sin coste medible, una región que la SVD uniforme no detecta. En la franja moderada (ratios 0,80–0,90), donde caen los puntos de operación realistas, el greedy duplica la retención de F1 frente a la uniforme: 87,0 % contra 43,5 % a ratio ~0,80. Misma cantidad de parámetros, el doble de rendimiento conservado. Esa es la ganancia de medir la sensibilidad por componente antes de asignar los rangos.

7.3.5. Comparación cualitativa con destilación

DistilBERT [39] reduce BERT-base a 6 capas (66 M parámetros, ratio 0,60) reteniendo el 97 % del rendimiento en GLUE. Esta cifra corresponde a GLUE, no a GoEmotions; re-evaluar DistilBERT en GoEmotions multi-etiqueta queda como trabajo futuro (§8.3). La comparación que sigue es por tanto indicativa de orden de magnitud, no una medición directa.

En compresión agresiva ($\rho \approx 0,60$), la destilación domina: *greedy_60* retiene apenas el 5,5 % del F1, porque la SVD opera sobre los pesos existentes sin re-entrenamiento, mientras que la destilación reentrena un modelo más pequeño desde cero. En compresión moderada ($\rho \in [0,80, 0,90]$) la SVD *greedy* es competitiva sin re-entrenar, y *greedy + fine-tuning* (§7.4) supera al baseline sin comprimir, un resultado que la destilación no alcanza a este ratio.

Las dos familias son complementarias. La SVD informada ocupa una zona ortogonal a la destilación: ratios 0,80–0,95 con intervención posterior sobre un modelo ya fine-tuned, sin pasar por el ciclo de entrenamiento. Su combinación (destilar y luego aplicar SVD *greedy* sobre el destilado) es un experimento natural derivado de este trabajo.

7.4. Recuperación mediante fine-tuning

La compresión SVD perturba los pesos del modelo. Esta sección investiga si un breve re-entrenamiento recupera el rendimiento original y, mediante un grupo de control adecuado, qué parte de cualquier mejora observada es atribuible a la compresión y qué parte al entrenamiento adicional.

Se seleccionó la configuración *greedy_90* (86,4 % de los parámetros, F1 macro = 0,539) como candidata para fine-tuning, por situarse en la frontera de Pareto. El re-entrenamiento consistió en 3 épocas sobre GoEmotions con los hiperparámetros estándar (tasa de aprendizaje 2×10^{-5} , warmup 10 %, batch size 32, idénticos a los del fine-tuning original). Como grupo de control se ejecutó el mismo procedimiento sobre el baseline sin comprimir.

7.4.1. Resultado agregado

Tabla 7.4: Rendimiento del modelo comprimido (*greedy_90*) antes y después de fine-tuning, comparado con el baseline sin comprimir y con el grupo de control (baseline + 3 épocas adicionales). Fuente: elaboración propia.

Modelo	Parámetros	F1 macro	vs. baseline
Baseline (sin compresión)	100,0 %	0,577	—
Baseline + 3 épocas (control)	100,0 %	0,595	+3,2 %
<i>greedy_90</i> (comprimido)	86,4 %	0,539	−6,7 %
<i>greedy_90</i> (fine-tuned)	86,4 %	0,591	+2,4 %

El grupo de control resulta decisivo. El baseline reentrenado tres épocas alcanza F1 macro = 0,595, cifra ligeramente superior a la del modelo comprimido reentrenado (0,591). La mejora observada al reentrenar el modelo comprimido proviene, por tanto, del entrenamiento adicional y no de un efecto regularizador específico de la SVD: la hipótesis de regularización implícita,

sugerida por el primer resultado agregado, no se sostiene cuando se introduce el control.

Lo que sí queda establecido es un resultado aplicado claro: el modelo *greedy_90* reentrenado alcanza $F1 = 0,591$ con el 86,4 % de los parámetros originales (13,6 % menos), una diferencia de únicamente 0,004 puntos respecto al baseline reentrenado a igualdad de épocas. La compresión guiada por sensibilidad, seguida de un fine-tuning corto, produce un modelo prácticamente equivalente al baseline con menos parámetros. Esta es la lectura defendible del experimento: compresión casi sin pérdida tras un coste de re-entrenamiento bajo.

7.4.2. Análisis por emoción

El control permite descomponer la mejora por emoción en tres condiciones: baseline original, baseline + 3 épocas (control), y *greedy_90* + 3 épocas. La diferencia entre las dos últimas aísla el efecto específico de la compresión SVD (Tabla 7.5).

Tabla 7.5: Mejora atribuible específicamente a la compresión SVD, por emoción. La columna *baseline+FT* es el control (baseline + 3 épocas); *comprimido+FT* es *greedy_90* + 3 épocas. La columna Δ SVD es la diferencia: positivo significa que la SVD ayuda; negativo, que perjudica. Fuente: elaboración propia.

Emoción	F1 base	F1 base+FT	F1 comp.+FT	Δ SVD
La SVD ayuda (5 de 23)				
desire	0,535	0,576	0,621	+0,045
joy	0,635	0,599	0,641	+0,043
approval	0,555	0,528	0,557	+0,028
curiosity	0,707	0,674	0,701	+0,027
sadness	0,632	0,604	0,621	+0,016
La SVD perjudica (mayores pérdidas)				
fear	0,710	0,736	0,691	-0,045
disappointment	0,275	0,332	0,301	-0,031
optimism	0,573	0,607	0,579	-0,028
realization	0,271	0,326	0,298	-0,028
love	0,816	0,836	0,813	-0,024
Caso paradigmático				
embarrassment	0,267	0,509	0,509	0,000

El caso de *embarrassment* ilustra el papel del control con especial claridad. La mejora absoluta (de 0,267 a 0,509, +0,242) podría interpretarse como evidencia de un efecto regularizador específico de la SVD; el control muestra que el baseline reentrenado alcanza exactamente el mismo $F1 = 0,509$. La mejora viene íntegramente del entrenamiento adicional, no de la compresión.

El patrón se repite en otras emociones infrarrepresentadas (*realization*, *disappointment*): el baseline reentrenado las mejora más que el modelo comprimido reentrenado. La hipótesis inicial (la SVD ayuda especialmente a las clases raras) no queda respaldada por el control.

En conjunto, la SVD ayuda en 5 de 23 emociones y perjudica ligeramente en las restantes; el promedio del efecto específico de la SVD es de -0,004 en $F1$ macro, lo que coincide con la diferencia agregada entre *greedy_90+FT* y *baseline+FT* (0,591 vs 0,595). La compresión no introduce un sesgo sistemático hacia ninguna familia de emociones, y su impacto promedio neto es modesto y ligeramente negativo. Lo defendible es, por tanto, la equivalencia funcional con

menos parámetros, no un efecto de regularización selectiva.

7.5. Discusión y síntesis de hallazgos

Tres conclusiones integran los resultados de compresión e interpretabilidad.

7.5.1. La interpretabilidad mecánica tiene valor aplicado, pero requiere cuantificación

El resultado negativo de las estrategias heurísticas (§7.2) y el éxito del algoritmo greedy (§7.3) establecen un matiz importante para la literatura de compresión informada: la interpretabilidad mecánica no genera valor mediante la intuición cualitativa, sino a través de la medición sistemática de sensibilidades. Las heurísticas informed convergen exactamente sobre la frontera de las baselines ciegas ($\text{informed_aggressive} \equiv \text{uniform_r256}$, $\text{informed_moderate} \equiv \text{uniform_r512}$), evidencia limpia de que el conocimiento cualitativo no extrae ganancia adicional sobre lo que la compresión uniforme alcanza sin invocar interpretabilidad. Saber que “la FFN es más importante que la atención” no basta; lo que permite diseñar estrategias superiores es cuantificar que Q a rango 256 retiene el 100,4 % del F1 (un valor $\geq 100\%$ es indistinguible de cero pérdida dentro del ruido de evaluación) mientras que FFN Intermediate a rango 64 colapsa al 0 %.

Esto no invalida la interpretabilidad cualitativa: los hallazgos de probing, *logit lens*, activation patching y ablación siguen siendo esenciales para explicar el modelo. Pero delimita su alcance en la ingeniería de compresión: la interpretabilidad identifica qué investigar; la sensibilidad empírica decide cuánto comprimir. La distinción orienta el diseño de futuras estrategias de compresión informada: su éxito dependerá de si se basan en mediciones cuantitativas o solo en heurísticas cualitativas.

7.5.2. Convergencia entre compresión e interpretabilidad

La Tabla 7.6 resume la convergencia entre los diferentes métodos experimentales del proyecto respecto a las tres conclusiones estructurales principales:

Los cinco métodos son distintos en su diseño experimental: el análisis de sensibilidad mide F1 bajo perturbación de pesos; la ablación de cabezas mide F1 bajo anulación de componentes; el probing mide separabilidad lineal de representaciones; el logit lens mide alineación con la base del clasificador; y el activation patching mide restauración funcional. No son, sin embargo, completamente independientes: todos se aplican sobre el mismo modelo, dataset y tarea, por lo que sesgos compartidos (por ejemplo, una propensión estructural del Transformer encoder a concentrar capacidad en capas tardías) afectarían a todos. Con esa cautela, la convergencia direccional en cinco análisis distintos refuerza la robustez de las conclusiones estructurales sin garantizar ausencia de sesgo común.

7.5.3. La regularización implícita: hipótesis no respaldada por el control

El F1 = 0,591 del modelo comprimido reentrenado (superior al baseline original de 0,577) podía sugerir un efecto regularizador de la SVD. El grupo de control (§7.4) no deja efecto atribuible a la

Tabla 7.6: Triangulación de hallazgos: la compresión y las cinco técnicas de interpretabilidad convergen en las mismas conclusiones estructurales. Fuente: elaboración propia.

Conclusión	Compresión	Interpretabilidad	Síntesis
Q/K son redundantes	Retención >99 % a rango 128 (§5.3)	Solapamiento espectral 0,63 con K (§5.1); bajo impacto en ablación (§6.4)	Primeros en comprimirse en greedy (§7.3)
FFN es el cuello de botella	Asimetría 14× Q vs. FFN Intermediate (§5.3)	Restaurar FFN L11 = 100 % (§6.3); 84 % neuronas significativas en L8–11 (§6.5)	Nunca comprimida en capas tardías (§7.3)
Capas tardías son críticas	Colapso total a $r = 128$ (§5.2)	77 % cabezas críticas en L8–11 (§6.4); cristalización tardía predice F1 (§6.1); cristalización geométrica L9–L11 (§6.2)	Protegidas sistemáticamente (§7.3)

SVD: el baseline reentrenado las mismas épocas alcanza $F1 = 0,595$, y la diferencia es de $-0,004$ en promedio, valor indistinguible del ruido de semilla ($< 0,01$). No hay regularización implícita detectable con este diseño; la mejora proviene del entrenamiento adicional, no de la compresión.

Lo que sí queda establecido es el resultado aplicado: la compresión greedy seguida de fine-tuning corto produce un modelo prácticamente equivalente al baseline reentrenado con el 86,4 % de los parámetros. Ese es el valor práctico de la metodología.

Capítulo 8

Conclusiones y trabajo futuro

Antes de detallar las contribuciones y sus límites, conviene volver a las tres preguntas con que se abrió la memoria (§1.1) y responderlas de forma directa.

P1: cómo afecta la compresión selectiva. La compresión SVD afecta al modelo de forma muy desigual. Aplicar el mismo recorte a todas las capas no funciona, porque la compresión uniforme no tiene un punto intermedio aprovechable: o conserva casi todos los parámetros, o hunde el modelo de golpe. En cuanto se comprime cada parte por separado, en cambio, aparece un mapa de fragilidades muy marcado. Hay componentes que toleran recortes fuertes sin apenas perder rendimiento, y otros, sobre todo las redes feed-forward de las capas finales, cuya compresión basta por sí sola para colapsar el modelo.

P2: qué explica esa fragilidad desigual. Las cinco técnicas de interpretabilidad coinciden en una misma imagen del modelo, organizada en tres niveles. Las capas tempranas extraen señal a partir de las palabras; las intermedias trabajan en una representación interna propia, todavía desalineada con el clasificador; y las finales reorganizan esa información para que la cabeza de clasificación pueda leerla. Esa reorganización final es lo que explica la fragilidad de P1: comprimir las capas tardías rompe el punto donde la representación se alinea con el clasificador, y por eso es ahí donde la compresión resulta más costosa.

P3: si todo esto sirve para comprimir mejor. La respuesta tiene un matiz que resultó ser el hallazgo más instructivo del trabajo. Traducir la interpretabilidad a reglas por intuición no aporta ninguna ventaja, y las estrategias diseñadas a mano a partir de los hallazgos no superan a la SVD ciega. Solo cuando ese conocimiento se convierte en mediciones de sensibilidad por componente, y se deja que un algoritmo sencillo decida con esos números, la compresión informada gana con claridad. Entender el modelo ayuda a comprimirlo, pero únicamente si esa comprensión se traduce en números.

El resto del capítulo desarrolla estas respuestas: la Sección 8.1 detalla las contribuciones, la Sección 8.2 acota su alcance, y las Secciones 8.3 y 8.4 indican cómo continuar el trabajo.

8.1. Contribuciones principales

Este trabajo ha producido un mapa funcional de cómo BERT-base fine-tuned organiza internamente la información emocional sobre GoEmotions (23 emociones), usando la compresión SVD selectiva como instrumento experimental y triangulando con cinco técnicas de interpretabilidad mecánica. La aportación principal es ese mapa funcional y la lección metodológica que conlleva; la compresión real obtenida es modesta (13,6 % de parámetros en *greedy_90*) y no compite con métodos como destilación o cuantización, que logran reducciones del 40 %.

La Tabla 8.1 resume el cumplimiento de los 12 sub-objetivos del plan de gestión (SO1–SO12, detallados en §2.2), que concretan operativamente los cinco objetivos conceptuales del proyecto (O1–O5, §1.2). Los 11 objetivos del núcleo se alcanzaron; el SO12 (originalmente opcional) se promovió a tarea principal y se evaluó con grupo de control en §7.4.

Tabla 8.1: Cumplimiento de los sub-objetivos planteados en el plan inicial. Sección indica dónde se desarrolla el resultado; evidencia, la métrica clave que documenta el cumplimiento. Fuente: elaboración propia.

Obj.	Descripción	Sección	Evidencia
SO1	Baseline competitivo (BERT 23 emociones)	§4.2	F1 macro 0,577 sobre test
SO2	Módulo SVD reutilizable	§4.3	Implementación modular aplicada a las 72 matrices del encoder
SO3	Compromiso compresión–rendimiento	§5.2	Cliff entre $r=384$ y $r=256$
SO4	Visualización degradación	§6.1	Fig. 6.2
SO5	Sensibilidad por componente	§5.3	Asimetría $14 \times a$ a $r=128$
SO6	Sensibilidad por profundidad	§5.3	Late catastrófica a $r=128$
SO7	Compresión adaptativa por energía	§5.4	Adaptive 90 %: 61 % retención, ratio 0,89
SO8	Localizar cristalización emocional	§6.1	276 probes; 9/8/6 emociones por banda
SO9	Evidencia funcional de localización	§6.2, §6.3	FFN L11 sola = 100 % restauración
SO10	Mapear cabezas y neuronas	§6.4, §6.5	144 cabezas + 36 864 neuronas
SO11	Compresión informada	§7.3	8/9 puntos Pareto-óptimos greedy
SO12	Recuperación por fine-tuning	§7.4	0,591 vs control 0,595 con 86,4 % params (control incluido)

8.1.1. Cartografía funcional del modelo

Las cinco técnicas de interpretabilidad convergen en un mapa coherente con cuatro hallazgos:

- **El modelo procesa la emoción en tres niveles.** La primera capa concentra ya la mayor parte de la separabilidad lineal (un 61 %) extrayendo señal a partir de las palabras; las capas intermedias trabajan en una geometría interna que el clasificador todavía no puede leer; y las finales realinean esa representación con la cabeza de clasificación. Esas capas

finales son, además, el cuello de botella bajo compresión.

- **Cada emoción se vuelve legible a una profundidad distinta, y esa profundidad importa.** Las emociones se reparten en tres bandas según la capa en que el modelo las separa con claridad. Lo determinante no es de cuántos ejemplos dispone cada emoción, sino lo profundo que hay que llegar: cuanto más tarde cristaliza una emoción, peor es el rendimiento que el modelo alcanza con ella ($\rho = -0,673$).
- **Un solo componente basta para resucitar al modelo colapsado.** Si se comprime el modelo hasta romperlo y luego se restaura únicamente la red feed-forward de la última capa, el rendimiento vuelve por completo al del baseline; restaurar en su lugar la atención de esa misma capa no llega ni a dos tercios. Es la FFN tardía la que coloca la representación en la base que el clasificador entiende. Esto demuestra que ese componente es suficiente para la recuperación, no que sea imprescindible en el modelo intacto (§8.2).
- **La importancia de las cabezas de atención crece con la profundidad.** La proporción de cabezas críticas pasa de cerca de un cuarto en las capas iniciales a más de tres cuartos en las finales, y en la última capa ninguna sobra. El análisis descubre además un grupo de cabezas que estorban: anularlas mejora ligeramente el rendimiento.

8.1.2. Compresión como instrumento de diagnóstico

La compresión SVD sistemática, más allá de su finalidad aplicada, ha funcionado como diagnóstico estructural complementario a la interpretabilidad:

- **El presupuesto de compresión no se reparte por igual.** A un mismo rango, unos componentes pierden casi todo el rendimiento y otros casi nada: las proyecciones Query y Key apenas cuestan F1, mientras que truncar la red feed-forward de las capas tardías hunde el modelo. Medida por parámetro eliminado, la distancia entre comprimir lo barato y lo caro llega a casi dos órdenes de magnitud. Una SVD que asigna el mismo rango a todas las matrices ignora esa asimetría, que es justo donde está el ahorro.
- **La compresión uniforme no tiene término medio.** Por encima de cierto rango conserva el rendimiento casi intacto; por debajo, el modelo colapsa de golpe, sin una zona intermedia útil. Como vía de compresión por sí sola no ofrece ningún punto de operación que merezca la pena.
- **Se puede anticipar qué emociones se degradarán antes de comprimir.** Tres propiedades medibles sobre el modelo intacto, y en especial la intensidad con que sus neuronas codifican cada emoción, predicen qué clases caerán más al comprimir ($\rho = 0,64$). Esto permite un cribado previo, útil cuando degradar ciertas emociones, las raras o las críticas para la aplicación, no es aceptable.
- **Lo que la SVD optimiza no coincide con lo que importa para la tarea.** La SVD elimina prácticamente la misma fracción de señal en todas las emociones, sin relación con cuánto cae el rendimiento de cada una. Dicho de otro modo, minimizar el error de reconstrucción no es lo mismo que minimizar la pérdida de F1. De ahí una advertencia práctica: el criterio habitual de retener el 95 % de la energía de cada matriz es ciego a la función, y conviene medir el impacto sobre la tarea en lugar de fiarse del umbral de energía.

8.1.3. Compresión informada por interpretabilidad

- **Medir la sensibilidad y dejar decidir a un algoritmo sencillo gana con claridad.** Un algoritmo greedy alimentado con los datos de sensibilidad domina la frontera entre tamaño y rendimiento: copa casi todos los puntos óptimos. En el nivel de compresión donde las estrategias ciegas ya han perdido más de la mitad del rendimiento, el greedy conserva en torno al 87 %.
- **Sin saber nada de interpretabilidad, el algoritmo redescubre sus conclusiones.** Operando solo con números, el greedy comprime primero las proyecciones Query y Key, luego la salida feed-forward de las capas tempranas, y nunca toca la red feed-forward de las capas finales. Es exactamente la jerarquía que habían dibujado las técnicas de interpretabilidad, alcanzada por un camino independiente.
- **La intuición cualitativa, por sí sola, no aporta nada.** Las tres estrategias diseñadas a mano a partir de los hallazgos reproducen exactamente las baselines ciegas correspondientes. Saber en qué dirección comprimir no da ventaja; lo que recorta parámetros es medir cuánto aguanta cada componente y fijar los rangos con esos números. La interpretabilidad dice dónde mirar; la medición decide cuánto cortar.
- **Un reentrenamiento corto deja el modelo comprimido a la par del original.** Tras tres épocas de fine-tuning, el modelo greedy con un 13 % menos de parámetros iguala en la práctica al baseline reentrenado el mismo tiempo. Un grupo de control resultó decisivo: la mejora viene del entrenamiento adicional y no de la compresión, de modo que la hipótesis de una regularización implícita por la SVD no se sostiene.

En conjunto, estos hallazgos dan una receta para quien quiera comprimir con SVD un encoder fine-tuned sobre una tarea de clasificación parecida. Primero, gastar el presupuesto donde es barato: comprimir Q y K de forma agresiva, porque reducen parámetros casi sin coste. Segundo, proteger las capas tardías (8–11), donde está el cuello de botella geométrico. Tercero, no truncar nunca la FFN Intermediate de esas capas finales. Cuarto, no asignar los rangos por energía espectral, sino medir el F1 por componente y profundidad y pasar esos números a un asignador simple; el greedy de §7.3 basta. Quinto, si hay cómputo disponible, un fine-tuning corto recupera la pérdida restante y deja el modelo casi equivalente al original con menos parámetros. La aportación de esta memoria a esa receta no es un algoritmo de compresión nuevo, sino el mapa de qué medir y dónde para que la SVD, una técnica clásica, deje de tratar todas las matrices por igual.

8.2. Limitaciones

Los resultados deben interpretarse dentro de un alcance experimental delimitado.

8.2.1. Generalización: un modelo, una tarea

Todos los experimentos se realizan sobre BERT-base (110 M parámetros) y GoEmotions. No es posible afirmar que los patrones observados se mantengan en otros modelos o tareas. La

arquitectura encoder-only con cabeza sobre [CLS] podría favorecer la concentración funcional en capas finales de un modo no replicable en arquitecturas decoder-only o encoder-decoder.

8.2.2. Sesgos del dataset

GoEmotions presenta desequilibrios notables. Cinco emociones se excluyeron: *neutral* (no es emoción y dominaba el dataset con >14 000 ejemplos) y *grief*, *nervousness*, *pride*, *relief* ($F1 = 0$ en el baseline por frecuencia <100). Las 23 restantes varían entre 303 (*embarrassment*) y 4 130 (*admiration*) ejemplos: factor 13×. Aunque la frecuencia no predice la profundidad de cristalización, sí puede afectar la robustez estadística de los análisis neuronales.

Dos implicaciones adicionales del filtrado merecen explicitarse. Primera: el baseline $F1 = 0,577$ se obtiene sobre 23 emociones y **no es directamente comparable** con los resultados reportados en la literatura para GoEmotions con 27 o 28 clases. Segunda: las cuatro emociones excluidas por $F1$ nulo son justamente las raras/contextuales que la narrativa de vulnerabilidad diferencial señala como más frágiles a la compresión. Al descartarlas de partida, el análisis se realiza sobre el subconjunto donde la fragilidad diferencial es más moderada; los efectos observados podrían estar atenuados respecto a un dataset completo.

8.2.3. Compresión post-hoc

La compresión se limita a SVD aplicada después del fine-tuning, sin re-entrenamiento durante la compresión ni combinación con otras técnicas. Poda estructurada, cuantización o destilación podrían interactuar de forma distinta con la estructura funcional del modelo.

8.2.4. Limitaciones de las técnicas de interpretabilidad

Probes lineales. Información codificada de forma no lineal en capas tempranas no sería detectada por probes logísticos.

Logit lens y calibración. La cabeza se entrenó solo sobre L11, así que las magnitudes absolutas a capas intermedias no son directamente comparables. Las comparaciones relativas sí son informativas, y el patrón cualitativo en U se corrobora con *probing* y *patching*.

Activation patching y efecto cadena. La contribución medida de una capa depende del estado de las capas no restauradas: las capas tempranas muestran recuperación nula porque su señal se degrada al atravesar 10 capas comprimidas. Las conclusiones tienen naturaleza funcional (qué componente basta para recuperar al modelo del colapso por SVD) y no deben interpretarse como localización del conocimiento emocional.

Suficiencia vs. necesidad de FFN L11. El experimento de *activation patching* demuestra que la FFN de L11 es suficiente para que el modelo se recupere del colapso por SVD, pero no que sea necesaria en el modelo no comprimido. Una validación complementaria sería ablacionar la FFN de L11 sobre el baseline limpio y medir la caída de $F1$; este experimento se propone en §8.3.

Sesgo de muestreo en la frontera de Pareto. Las 21 configuraciones evaluadas no se distribuyen uniformemente entre familias (6 uniformes, 4 adaptativas, 3 heurísticas, 8 greedy). El claim de “8 de los 9 puntos Pareto-óptimos son greedy” (§7.3) debe leerse con esta cautela: una densidad de muestreo mayor en una familia incrementa su probabilidad de aparecer en la frontera. La dominancia cualitativa del greedy en la región funcional ($F1 > 0$, $\text{ratio} < 1$) es robusta, pero la magnitud exacta del cociente está sesgada por el diseño de evaluación.

Validación cruzada en otra tarea. El algoritmo greedy se alimenta de datos de sensibilidad medidos en GoEmotions y se evalúa sobre GoEmotions. No se ha verificado si la jerarquía de sensibilidad se transfiere a otra tarea de clasificación (sentimiento, NLI). La extensión a otras tareas se propone como verificación principal en §8.3.

8.2.5. Potencia estadística

Varias correlaciones centrales del trabajo se calculan sobre $n = 23$ puntos. Con $\alpha = 0,05$ y potencia 0,80, la mínima correlación de Spearman detectable es $|\rho_{\min}| \approx 0,556$. Las correlaciones fuertes documentadas ($\rho = -0,673$ para cristalización vs. F1; $\rho = +0,639$ para selectividad neuronal vs. caída de F1) están dentro del rango detectable ($p < 0,001$), pero correlaciones moderadas como frecuencia–cristalización ($\rho = -0,265$) requerirían $n \geq 85$ para ser distinguibles. Los intervalos de confianza bootstrap al 95 % reportados en §6.1 reflejan esta limitación.

8.3. Trabajo futuro

Las limitaciones identificadas sugieren cinco líneas concretas de trabajo futuro, ordenadas por prioridad metodológica.

Generalización a otros modelos y tareas. Replicar el estudio sobre BERT-large, RoBERTa-large y arquitecturas decoder-only (GPT-2, LLaMA) permitiría distinguir qué hallazgos son propiedades universales de la arquitectura Transformer y cuáles son específicos de BERT-base o de la tarea emocional. De especial interés es la dominancia funcional de la FFN sobre la atención.

Compresión a granularidad de cabeza individual. El greedy actual opera a granularidad de componente y banda. Una extensión natural asignaría rangos SVD por cabeza, combinándolo con poda directa de las 37 cabezas dispensables y las 21 interferentes identificadas en §6.4.

Tuned lens para corregir la calibración del logit lens. Belrose et al. [59] proponen entrenar una transformación lineal por capa que minimice la divergencia KL con la predicción real del modelo. Aplicarla permitiría verificar si el valle observado en L4–L8 es robusto a la corrección de calibración.

Combinación de técnicas de compresión. Un pipeline en cascada poda de cabezas $\rightarrow$ SVD greedy $\rightarrow$ cuantización post-SVD $\rightarrow$ fine-tuning. La pregunta abierta es si las reducciones se

acumulan multiplicativamente o si las técnicas compiten por la misma redundancia.

Validación en producción. Medir latencia, rendimiento (muestras por segundo) y uso de memoria en hardware real (CPU, GPU, dispositivos embebidos) determinaría si las ventajas teóricas de la compresión informada se traducen en beneficios prácticos de despliegue. Los experimentos de este trabajo se ejecutaron en Google Colab (GPU T4/A100), un entorno compartido que no permite mediciones de latencia reproducibles, por lo que esta validación queda como línea de trabajo futuro de ingeniería.

8.4. Predicciones falsables del framework

El framework descrito en esta memoria genera cuatro predicciones contrastables sobre escenarios fuera del alcance experimental original. Replicarlas o refutarlas en otros modelos y tareas permitiría delimitar empíricamente qué hallazgos son específicos de BERT-base sobre GoEmotions y cuáles son estructurales.

- PR1. Asimetría espectral en BERT-large.** El cociente $k_{95}(Q)/k_{95}(\text{FFN})$ (con k_{95} definido en §4.3.4) debería estar en $[0,55, 0,75]$ (BERT-base: 0,64). Un cociente ≈ 1 indicaría que la asimetría es específica del régimen de baja capacidad.
- PR2. Encoder vs. decoder.** En modelos decoder-only (GPT-2, LLaMA), el patching debería distribuirse más uniformemente entre las capas tardías que en BERT, dado que no existe la geometría de clasificación vía [CLS].
- PR3. Cristalización en RoBERTa-base.** La distribución 9/8/6 y la correlación $\rho = -0,673$ entre profundidad y F1 deberían replicarse cualitativamente. Si el orden cambia, la profundidad dependería del corpus de pre-entrenamiento.
- PR4. Convergencia de la heurística cualitativa.** En otros dominios, las traducciones *puramente cualitativas* de la interpretabilidad a reglas de compresión (sin medición empírica de sensibilidad por componente, como las tres variantes probadas en §7.2) convergerán sobre las baselines ciegas; solo la incorporación de datos numéricos de sensibilidad permite superarlas. La predicción no se extiende a heurísticas calibradas con mediciones piloto, que ocuparían un punto intermedio.

8.5. Consideración final

El recorrido de esta memoria empezó con una pregunta sencilla: qué deja de funcionar primero cuando se comprime un modelo, y qué enseña eso sobre cómo organiza por dentro lo que ha aprendido. La respuesta es un mapa funcional de BERT sobre la tarea emocional, en el que la compresión ha servido menos para ahorrar parámetros que para medir qué partes del modelo importan y por qué. De ese mapa sale una idea que va más allá del caso estudiado: entender un modelo y comprimirlo bien no son lo mismo. La interpretabilidad señala dónde mirar, pero solo ayuda a comprimir cuando esa comprensión se convierte en números concretos. Esa traducción,

de la intuición a la medida, es la que separa una comprensión informada de una que solo lo aparenta.

Capítulo 9

Análisis de sostenibilidad e implicaciones éticas

9.1. Autoevaluación

Como **puntos fuertes**, dispongo de sensibilidad hacia el impacto ambiental de la computación: el propio tema del TFG (compresión de modelos) está motivado en parte por la reducción del coste energético de la inferencia, y he incorporado referencias a Strubell et al. [4] y Schwartz et al. [5] sobre Green AI desde la definición del proyecto. A nivel económico, he estimado el presupuesto con detalle, diferenciando perfiles y justificando cada partida.

Como **puntos débiles**, mi formación en sostenibilidad ha sido más teórica que práctica: no había realizado anteriormente un análisis de ciclo de vida energético de un proyecto informático y mi conocimiento sobre normativas ambientales aplicables a centros de datos es limitado. La dimensión social (más allá de la accesibilidad) requiere reflexión más profunda sobre sesgos en los datos de emociones y sobre quién se beneficia realmente de estas tecnologías.

9.2. Dimensión económica

PPP — Coste estimado del proyecto. El presupuesto total de 12.911 € es razonable para un proyecto académico de 492 h ejecutadas (507 h planificadas). El coste está dominado por el recurso humano (83,7 %), lo que refleja un proyecto de investigación aplicada sin necesidad de infraestructura costosa. El uso de herramientas open source y servicios gratuitos o de bajo coste (Google Colab Pro, GitHub, Overleaf) mantiene los costes genéricos en mínimos.

VU — ¿Cómo se resuelven actualmente los costes del problema? Desplegar modelos Transformer de gran tamaño requiere GPUs costosas (A100, H100) con consumos energéticos elevados. Empresas y centros de investigación invierten miles de euros mensuales en infraestructura cloud para servir estos modelos. Las técnicas de compresión existentes (destilación, cuantización) requieren re-entrenamiento costoso o hardware especializado.

¿En qué mejorará económicamente la solución? La compresión SVD tras el entrenamiento que estudia este proyecto no requiere re-entrenamiento ni hardware especial. El mapa de sensibilidad permite a ingenieros comprimir selectivamente solo los componentes menos críticos, maximizando la reducción de parámetros con mínima pérdida de calidad y, por tanto, reduciendo

costes de inferencia sin inversión adicional en entrenamiento.

9.3. Dimensión ambiental

PPP — Impacto ambiental de la realización del proyecto. El principal impacto proviene del consumo eléctrico de las GPUs durante los experimentos. Estimamos un uso de GPU de ~80–100 horas. Con un consumo típico de una GPU T4 en Colab de ~70 W, esto supone ~7 kWh. Sumando el PC personal ($492 \text{ h} \times 0,1 \text{ kW} = 49 \text{ kWh}$), el consumo total estimado es de ~56 kWh, equivalente a ~12 kg de CO₂ (factor de emisión medio en España: 0,22 kg CO₂/kWh). Es un impacto modesto comparado con el entrenamiento de modelos grandes.

¿Te has planteado minimizar el impacto? Sí. Se reutiliza un modelo BERT-base ya pre-entrenado por Google, evitando el coste enorme del pre-entrenamiento. La compresión SVD se aplica sobre el modelo fine-tuned tras el entrenamiento, sin requerir entrenamiento adicional para la mayoría de experimentos. Se liberan copias del modelo de memoria tras cada evaluación y se utiliza subsampling para visualizaciones (1.500 muestras en t-SNE).

VU — Mejora ambiental. La contribución ambiental del proyecto es indirecta: los mapas de sensibilidad reducen el tamaño y el consumo energético del modelo durante la inferencia. Como la inferencia consume más energía que el entrenamiento en un modelo desplegado, guiar la compresión con criterios cuantitativos tiene un impacto positivo acumulativo, en línea con Green AI [5].

9.4. Dimensión social

PPP — Aportación personal. El proyecto me permite profundizar en tres áreas relevantes para mi desarrollo profesional: la arquitectura Transformer y sus mecanismos internos; el álgebra lineal aplicada y el análisis numérico, que conecta teoría matemática y aplicaciones; y el diseño y ejecución de estudios experimentales sistemáticos.

VU — Mejora social. Hoy, los modelos de lenguaje grandes son accesibles sobre todo para empresas con recursos computacionales significativos, lo que genera una brecha tecnológica. La compresión eficiente facilita el acceso a estos modelos en dispositivos con restricciones (móviles, sistemas embebidos) y en organizaciones pequeñas (universidades, ONG). Un modelo de clasificación de emociones comprimido podría usarse en aplicaciones de salud mental, moderación de contenido o análisis de opinión en contextos donde antes era inviable.

VU — Necesidad real. Sí. La tendencia hacia modelos cada vez más grandes exige la compresión para que su uso se generalice. La clasificación de emociones tiene aplicaciones reales en salud mental, educación y moderación de plataformas. Este proyecto demuestra cómo comprimir y, sobre todo, dónde hacerlo de forma segura.

9.5. Vinculación con los Objetivos de Desarrollo Sostenible

El proyecto se alinea con varios Objetivos de Desarrollo Sostenible (ODS) de la Agenda 2030 de Naciones Unidas, principalmente a través de su orientación hacia la eficiencia computacional (*Green AI*) y la democratización del acceso a modelos de lenguaje.

- **ODS 9 — Industria, innovación e infraestructura.** El trabajo contribuye a una infraestructura de IA más sostenible: el mapa de sensibilidad por componente permite comprimir modelos Transformer reduciendo su huella de cómputo en inferencia sin re-entrenamiento ni hardware especializado.
- **ODS 12 — Producción y consumo responsables.** La compresión informada por interpretabilidad optimiza el uso de recursos computacionales: asignar el rango justo a cada matriz evita el sobredimensionamiento de modelos desplegados, reduciendo el consumo de memoria y energía por predicción.
- **ODS 13 — Acción por el clima.** Al disminuir el coste energético de la inferencia (la fase que domina el consumo a lo largo de la vida útil de un modelo desplegado), el proyecto reduce indirectamente las emisiones de CO₂ asociadas, en línea con la dimensión ambiental analizada en este mismo capítulo.
- **ODS 10 — Reducción de las desigualdades y ODS 3 — Salud y bienestar.** La compresión eficiente facilita desplegar modelos de clasificación emocional en hardware modesto y en organizaciones con pocos recursos (universidades, ONG), contrarrestando parcialmente la concentración de capacidad de cómputo y habilitando aplicaciones en salud mental, educación o moderación de contenido en contextos antes inviables.

La contribución a estos objetivos es, en su mayor parte, *indirecta y habilitadora*: el trabajo no despliega una solución de impacto directo, sino que genera el conocimiento metodológico (dónde y cuánto comprimir) que hace más eficientes y accesibles los sistemas que sí se desplegarán.

9.6. Implicaciones éticas

El proyecto se inscribe en el ámbito de la interpretabilidad mecánica de modelos de lenguaje. A continuación se documentan tres consideraciones éticas derivadas directamente del diseño y los datos empleados.

Sesgos del dataset. GoEmotions [11] se construyó a partir de comentarios de Reddit anotados por evaluadores humanos. Esta fuente impone sesgos demográficos conocidos: predominio de hablantes angloparlantes, sesgo hacia comunidades específicas, y composición demográfica no representativa de la población general. Las conclusiones sobre cristalización emocional y compresión derivadas en este trabajo se refieren, en rigor, al modelo entrenado sobre esa distribución específica. La extrapolación a otros contextos lingüísticos o demográficos requeriría verificación empírica adicional.

Uso dual de la interpretabilidad. Las técnicas de interpretabilidad mecánica aplicadas en este trabajo, en particular el *probing* capa a capa y la ablación de cabezas, pueden utilizarse tanto para comprender modelos como para identificar individuos emocionalmente vulnerables a partir de su comunicación escrita. El conocimiento generado es por tanto de doble uso: facilita aplicaciones beneficiosas (asistencia en salud mental, moderación informada de contenido) y simultáneamente herramientas potencialmente intrusivas (perfilado emocional sin consentimiento, manipulación dirigida). El proyecto se posiciona del lado de la transparencia: publicar los hallazgos sobre dónde y cómo se codifican las emociones contribuye a que estos riesgos sean identificables y auditables, en lugar de quedar como ventaja informativa de actores con acceso privilegiado al modelo.

Compresión y democratización. La línea aplicada del trabajo (compresión informada que produce modelos más pequeños sin pérdida de rendimiento) tiene una implicación ética positiva: reduce la barrera de acceso computacional a tareas de clasificación emocional. Universidades, ONGs y pequeñas organizaciones pueden desplegar modelos de análisis emocional en hardware modesto. Esto contrarresta parcialmente la concentración de capacidad de cómputo en grandes corporaciones, un sesgo estructural del campo señalado en la literatura sobre Green AI [5].

Limitaciones del análisis ético. Este análisis se limita a los aspectos identificables a priori. Otros riesgos (uso del modelo comprimido en contextos clínicos sin validación adicional, agregación de predicciones emocionales con datos personales, etc.) dependen del despliegue concreto y quedan fuera del alcance del proyecto, que se limita a la investigación sobre la estructura interna del modelo.

Referencias

- [1] Ashish Vaswani et al. "Attention Is All You Need". En: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30. Curran Associates, Inc., 2017.
- [2] Jacob Devlin et al. "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding". En: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)*. Association for Computational Linguistics, 2019, págs. 4171-4186.
- [3] Tom B. Brown et al. "Language Models are Few-Shot Learners". En: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 33. 2020, págs. 1877-1901.
- [4] Emma Strubell, Ananya Ganesh y Andrew McCallum. "Energy and Policy Considerations for Deep Learning in NLP". En: *arXiv preprint arXiv:1906.02243* (2019).
- [5] Roy Schwartz et al. "Green AI". En: *Communications of the ACM* 63.12 (2020), págs. 54-63.
- [6] Prakhar Ganesh et al. "Compressing Large-Scale Transformer-Based Models: A Case Study on BERT". En: *Transactions of the Association for Computational Linguistics* 9 (2021), págs. 1061-1080.
- [7] Carl Eckart y Gale Young. "The Approximation of One Matrix by Another of Lower Rank". En: *Psychometrika* 1.3 (1936), págs. 211-218.
- [8] Nelson Elhage et al. "A Mathematical Framework for Transformer Circuits". En: *Transformer Circuits Thread, Anthropic* (2021).
- [9] Kevin Meng et al. "Locating and Editing Factual Associations in GPT". En: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 35. 2022.
- [10] Arthur Conmy et al. "Towards Automated Circuit Discovery for Mechanistic Interpretability". En: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 36. 2023.
- [11] Dorottya Demszky et al. "GoEmotions: A Dataset of Fine-Grained Emotions". En: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*. Association for Computational Linguistics, 2020, págs. 4040-4054.
- [12] Matan Ben Noach y Yoav Goldberg. "Compressing Pre-trained Language Models by Matrix Decomposition". En: *arXiv preprint arXiv:2002.02682* (2020).
- [13] Yen-Chang Hsu et al. "Language Model Compression with Weighted Low-Rank Factorization". En: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2022.
- [14] Ian Tenney, Dipanjan Das y Ellie Pavlick. "BERT Rediscovered the Classical NLP Pipeline". En: *arXiv preprint arXiv:1905.05950* (2019).
- [15] Ganesh Jawahar, Benoît Sagot y Djamé Seddah. "What Does BERT Learn about the Structure of Language?" En: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)*. 2019, págs. 3651-3657.

- [16] Mor Geva et al. "Transformer Feed-Forward Layers Are Key-Value Memories". En: *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2021, págs. 5484-5495.
- [17] Elena Voita et al. "Analyzing Multi-Head Self-Attention: Specialized Heads Do the Heavy Lifting, the Rest Can Be Pruned". En: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)*. 2019, págs. 5797-5808.
- [18] Thomas Wolf et al. "Transformers: State-of-the-Art Natural Language Processing". En: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. 2020, págs. 38-45.
- [19] Jeffrey L. Elman. "Finding Structure in Time". En: *Cognitive Science* 14.2 (1990), págs. 179-211.
- [20] Yoshua Bengio, Patrice Simard y Paolo Frasconi. "Learning Long-Term Dependencies with Gradient Descent is Difficult". En: *IEEE Transactions on Neural Networks* 5.2 (1994), págs. 157-166.
- [21] Sepp Hochreiter y Jürgen Schmidhuber. "Long Short-Term Memory". En: *Neural Computation* 9.8 (1997), págs. 1735-1780.
- [22] Dzmitry Bahdanau, Kyunghyun Cho y Yoshua Bengio. "Neural Machine Translation by Jointly Learning to Align and Translate". En: *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*. 2015.
- [23] Alec Radford et al. "Improving Language Understanding by Generative Pre-Training". En: *OpenAI Technical Report* (2018).
- [24] Colin Raffel et al. "Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer". En: *Journal of Machine Learning Research* 21.140 (2020), págs. 1-67.
- [25] Kevin Clark et al. "What Does BERT Look At? An Analysis of BERT's Attention". En: *Proceedings of the 2019 ACL Workshop BlackboxNLP: Analyzing and Interpreting Neural Networks for NLP*. 2019, págs. 276-286.
- [26] Dan Hendrycks y Kevin Gimpel. "Gaussian Error Linear Units (GELUs)". En: *arXiv preprint arXiv:1606.08415* (2016).
- [27] Kaiming He et al. "Deep Residual Learning for Image Recognition". En: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, págs. 770-778.
- [28] Jimmy Lei Ba, Jamie Ryan Kiros y Geoffrey E. Hinton. "Layer Normalization". En: *arXiv preprint arXiv:1607.06450* (2016).
- [29] Yinhan Liu et al. "RoBERTa: A Robustly Optimized BERT Pretraining Approach". En: *arXiv preprint arXiv:1907.11692* (2019).
- [30] Bo Pang y Lillian Lee. "Opinion Mining and Sentiment Analysis". En: *Foundations and Trends in Information Retrieval* 2.1-2 (2008), págs. 1-135.
- [31] Paul Ekman. "An Argument for Basic Emotions". En: *Cognition and Emotion* 6.3-4 (1992), págs. 169-200.
- [32] Robert Plutchik. "A General Psychoevolutionary Theory of Emotion". En: *Theories of Emotion*. Academic Press, 1980, págs. 3-33.
- [33] Song Han et al. "Learning both Weights and Connections for Efficient Neural Networks". En: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 28. 2015.

- [34] Ziheng Wang, Jeremy Wohlwend y Tao Lei. "Structured Pruning of Large Language Models". En: *arXiv preprint arXiv:1910.04732* (2019).
- [35] Paul Michel, Omer Levy y Graham Neubig. "Are Sixteen Heads Really Better than One?". En: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 32. 2019.
- [36] Benoit Jacob et al. "Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference". En: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2018, págs. 2704-2713.
- [37] Tim Dettmers et al. "QLoRA: Efficient Finetuning of Quantized Language Models". En: *arXiv preprint arXiv:2305.14314* (2023).
- [38] Geoffrey Hinton, Oriol Vinyals y Jeff Dean. "Distilling the Knowledge in a Neural Network". En: *arXiv preprint arXiv:1503.02531* (2015).
- [39] Victor Sanh et al. "DistilBERT, a Distilled Version of BERT: Smaller, Faster, Cheaper and Lighter". En: *5th Workshop on Energy Efficient Machine Learning and Cognitive Computing (NeurIPS)*. 2019.
- [40] Xiaoqi Jiao et al. "TinyBERT: Distilling BERT for Natural Language Understanding". En: *Findings of the Association for Computational Linguistics: EMNLP 2020*. 2020, págs. 4163-4174.
- [41] Edward J. Hu et al. "LoRA: Low-Rank Adaptation of Large Language Models". En: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2022.
- [42] Srinadh Bhojanapalli et al. "Low-Rank Bottleneck in Multi-head Attention Models". En: *Proceedings of the 37th International Conference on Machine Learning (ICML)*. 2020, págs. 864-873.
- [43] Sinong Wang et al. "Linformer: Self-Attention with Linear Complexity". En: *arXiv preprint arXiv:2006.04768* (2020).
- [44] Zhihang Yuan et al. "ASVD: Activation-aware Singular Value Decomposition for Compressing Large Language Models". En: *arXiv preprint arXiv:2312.05821* (2023).
- [45] Xin Wang et al. "SVD-LLM: Truncation-aware Singular Value Decomposition for Large Language Model Compression". En: *Proceedings of the International Conference on Learning Representations (ICLR)*. arXiv:2403.07378. 2025.
- [46] Xin Men et al. "ShortGPT: Layers in Large Language Models are More Redundant Than You Expect". En: *arXiv preprint arXiv:2403.03853* (2024).
- [47] Elias Frantar y Dan Alistarh. "SparseGPT: Massive Language Models Can Be Accurately Pruned in One-Shot". En: *Proceedings of the 40th International Conference on Machine Learning (ICML)*. 2023, págs. 10323-10337.
- [48] Marco Tulio Ribeiro, Sameer Singh y Carlos Guestrin. "'Why Should I Trust You?': Explaining the Predictions of Any Classifier". En: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, págs. 1135-1144.
- [49] Scott M. Lundberg y Su-In Lee. "A Unified Approach to Interpreting Model Predictions". En: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30. 2017.
- [50] Alexis Conneau et al. "What You Can Cram into a Single $\mathbb{R}^d$ Vector: Probing Sentence Embeddings for Linguistic Properties". En: *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL)*. 2018, págs. 2126-2136.

- [51] John Hewitt y Christopher D. Manning. “A Structural Probe for Finding Syntax in Word Representations”. En: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)*. 2019, págs. 4129-4138.
- [52] John Hewitt y Percy Liang. “Designing and Interpreting Probes with Control Tasks”. En: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2019, págs. 2733-2743.
- [53] Yanai Elazar et al. “Amnesic Probing: Behavioral Explanation with Amnesic Counterfactuals”. En: *Transactions of the Association for Computational Linguistics (TACL)* 9 (2021), págs. 160-175.
- [54] Yilun Xu et al. “A Theory of Usable Information Under Computational Constraints”. En: *International Conference on Learning Representations (ICLR)*. 2020.
- [55] Kawin Ethayarajh, Yejin Choi y Swabha Swayamdipta. “Understanding Dataset Difficulty with $\mathcal{V}$ -Usable Information”. En: *Proceedings of the 39th International Conference on Machine Learning (ICML)*. PMLR, 2022, págs. 5988-6008.
- [56] Yonatan Belinkov. “Probing Classifiers: Promises, Shortcomings, and Advances”. En: *Computational Linguistics* 48.1 (2022), págs. 207-219.
- [57] Jesse Vig et al. “Investigating Gender Bias in Language Models Using Causal Mediation Analysis”. En: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 33. 2020.
- [58] nostalgebraist. *Interpreting GPT: the Logit Lens*. LessWrong. Accessed: 2026. 2020. URL: <https://www.lesswrong.com/posts/AcKRB8wDpdaN6v6ru/interpreting-gpt-the-logit-lens>.
- [59] Nora Belrose et al. “Eliciting Latent Predictions from Transformers with the Tuned Lens”. En: *arXiv preprint arXiv:2303.08112* (2023).
- [60] Damai Dai et al. “Knowledge Neurons in Pretrained Transformers”. En: *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (ACL)*. 2022, págs. 8493-8502.
- [61] Nelson Elhage et al. “Toy Models of Superposition”. En: *Transformer Circuits Thread, Anthropic* (2022).